



ΧΑΡΟΚΟΠΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

ΣΧΟΛΗ ΨΗΦΙΑΚΗΣ ΤΕΧΝΟΛΟΓΙΑΣ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΤΗΛΕΜΑΤΙΚΗΣ

ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ
ΤΗΛΕΜΑΤΙΚΗΣ

ΚΑΤΕΥΘΥΝΣΗ ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΕΦΑΡΜΟΓΕΣ ΙΣΤΟΥ

Τίτλος Εργασίας

**Πειραματική αξιολόγηση αλγορίθμων ενισχυτικής μάθησης σε περιβάλλοντα
Stable Baselines και Gym**

Μεταπτυχιακή εργασία

Κυριάκος Ναβροζίδης

Αθήνα, 2023



HAROKOPIO UNIVERSITY

SCHOOL DIGITAL TECHNOLOGY

DEPARTMENT INFORMATICS AND TELEMATICS

POSTGRADUATE PROGRAMME INFORMATICS AND TELEMATICS

COURSE WEB TECHNOLOGIES AND APPLICATIONS

Title

**Experimental Evaluation of Reinforcement Learning Algorithms in Stable
Baselines and Gym Environments**

Master Thesis

Kiriakos Navrozidis

Athens, 2023



ΧΑΡΟΚΟΠΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ

ΣΧΟΛΗ ΨΗΦΙΑΚΗΣ ΤΕΧΝΟΛΟΓΙΑΣ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΤΗΛΕΜΑΤΙΚΗΣ

**ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ
ΤΗΛΕΜΑΤΙΚΗΣ**

ΚΑΤΕΥΘΥΝΣΗ ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΕΦΑΡΜΟΓΕΣ ΙΣΤΟΥ

Τριμελής Εξεταστική Επιτροπή

**Δίου Χρήστος – Επιβλέπων Καθηγητής
Επίκουρος Καθηγητής, Τμήμα Πληροφορικής και Τηλεματικής,
Χαροκόπειο Πανεπιστήμιο**

**Βαρλάμης Ηρακλής
Αναπληρωτής Καθηγητής, Τμήμα Πληροφορικής και Τηλεματικής,
Χαροκόπειο Πανεπιστήμιο**

**Μιχαήλ Δημήτριος
Αναπληρωτής Καθηγητής, Τμήμα Πληροφορικής και Τηλεματικής,
Χαροκόπειο Πανεπιστήμιο**

Ο/Η Κυριάκος Ναβροζίδης δηλώνω υπεύθυνα ότι:

- 1)** Είμαι ο κάτοχος των πνευματικών δικαιωμάτων της πρωτότυπης αυτής εργασίας και από όσο γνωρίζω η εργασία μου δε συκοφαντεί πρόσωπα, ούτε προσβάλλει τα πνευματικά δικαιώματα τρίτων.
- 2)** Αποδέχομαι ότι η ΒΚΠ μπορεί, χωρίς να αλλάξει το περιεχόμενο της εργασίας μου, να τη διαθέσει σε ηλεκτρονική μορφή μέσα από τη ψηφιακή Βιβλιοθήκη της, να την αντιγράψει σε οποιοδήποτε μέσο ή/και σε οποιοδήποτε μορφότυπο καθώς και να κρατά περισσότερα από ένα αντίγραφα για λόγους συντήρησης και ασφάλειας.
- 3)** Όπου υφίστανται δικαιώματα άλλων δημιουργών έχουν διασφαλιστεί όλες οι αναγκαίες άδειες χρήσης ενώ το αντίστοιχο υλικό είναι ευδιάκριτο στην υποβληθείσα εργασία.

Αφιέρωση

Αφιερώνω την παρούσα εργασία στην φίλη μου Άννα και στην οικογένεια μου.

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω τον φίλο μου Βασίλη για την προτροπή του να παρακολουθήσω το συγκεκριμένο πρόγραμμα.

Θα ήθελα επίσης να ευχαριστήσω τον επιβλέπων καθηγητή μου, Χρήστο Δίου, για την άψογη συνεργασία μας κατά την διάρκεια της συγγραφής της διπλωματικής εργασίας και την άμεση ανταπόκριση.

Τέλος θα ήθελα να ευχαριστήσω όλους τους καθηγητές του τμήματος για την πολύ καλή συνεργασία μας και για τις πολύτιμες γνώσεις που αποκόμισα μέσα από τα μαθήματά τους.

Περιεχόμενα

Κατάλογος Εικονων	10
Κατάλογος Πινάκων	11
Περίληψη	12
Abstract:	13
Κεφάλαιο 1ο Εισαγωγή	14
1.1 Παρουσίαση Προβλήματος	14
1.2 Πως λειτουργούν οι Αλγόριθμοι της Ενισχυτικής Μάθησης στο παιχνίδι σε περιβάλλοντα Gym.	16
Κεφάλαιο 2ο Μηχανική μάθηση	20
2.1 Ιστορική αναδρομή	20
2.2 Ορισμός μηχανικής μάθησης	21
2.3 Είδη Μηχανικής Μάθησης	24
2.3.1 Μάθηση χωρίς Επίβλεψη ή Μάθηση από παρατήρηση	25
2.3.2 Μάθηση με επίβλεψη ή μάθηση με παραδείγματα	26
2.3.3 Ενισχυτική Μηχανική Μάθηση	27
2.4 Κατηγοριοποίηση και Αλγόριθμοι Ταξινόμησης	28
Κεφάλαιο 3ο Ενισχυτική Μάθηση και η σημασία της στην Τεχνητή Νοημοσύνη	30
3.1.1 Markov Decision Process	36
3.1.2 Monte Carlo method	40
3.1.3 TD Temporal Difference Learning algorithms	41
3.1.4 SARSA	42
3.1.5 Q Learning	42

3.2 Επεξήγηση Όρων πριν την Εισαγωγή στους Αλγορίθμους	43
3.3 Αλγόριθμοι Ενισχυτικής Μάθησης	47
3.3.1 Ο αλγόριθμος Actor-Critic (A2C)	47
3.3.2 Ο αλγόριθμος Proximal Policy Optimization (PPO)	50
3.3.3 Ο αλγόριθμος TD3	55
3.3.4 Ο αλγόριθμος DDPG	63
3.4 Πλεονεκτήματα της Ενισχυτικής Μάθησης	69
3.5 Μειονεκτήματά της Ενισχυτικής Μάθησης	70
3.6 Βασικές Προκλήσεις και Ερευνητικά ερωτήματα στη Μάθηση Ενίσχυσης	71
Κεφάλαιο 4ο Εφαρμογές που χρησιμοποιούν αλγορίθμους Ενισχυτικής Μάθησης	74
4.1 Εργαλεία και περιβάλλοντα που χρησιμοποιήθηκαν	74
4.2 Κριτήρια Επιλογής Αλγορίθμων	75
4.2.1 Κριτήρια Επιλογής περιβάλλοντος (Environment)	75
4.2.2 Κριτήρια Επιλογής του Κατάλληλου Αλγορίθμου για την Εκπαίδευση του Μοντέλου	77
4.2.3 Κριτήρια Επιλογής του Κατάλληλου Μοντέλου	79
4.2.4 Κριτήρια Αξιολόγησης Αλγορίθμου	81
4.3 Περιβάλλοντα Πειραματισμού	83
4.3.1 Atari game “breakout”	83
4.3.2 Gym game “LunarLanderContinuous-v2”	85
4.3.2 Atari game “Atlantis-v4”	86
Κεφάλαιο 5ο Πειράματα και Αξιολογήσεις	88
5.1 Περιγραφή βοηθητικής βιβλιοθήκης για την αξιολόγηση των αλγορίθμων	88

5.2 Αξιολόγηση μοντέλων	90
5.2.1 Ο Αλγόριθμος A2C στο παιχνίδι Atari	90
5.2.2 Ο Αλγόριθμος PPO στο παιχνίδι Atari “Breakout”	93
5.2.3 Ο Αλγόριθμος TD3	97
5.2.4 Ο Αλγόριθμος DDPG	99
5.2.5 Συγκριση μοντέλων	100
5.3 Εφαρμογή εκπαιδευμένων μοντέλων σε διαφορετικά περιβάλλοντα	105
Κεφάλαιο 6ο Συμπεράσματα	107
6.1 Συμπεράσματα	107
6.2 Μελλοντικές Προβλέψεις	108
Βιβλιογραφία	111

Κατάλογος Εικονων

Εικόνα 1 Τύποι Μηχανικής Μάθησης	24
Εικόνα 2 MDP model	36
Εικόνα 3 Training cycle A2C	47
Εικόνα 4 Value function A2C	48
Εικόνα 5 Διαγραμματική αναπαράστασή της συνάρτησης Lclip	52
Εικόνα 6 Πίνακας	54
Εικόνα 7 Actor Critic Model of TD3	56
Εικόνα 8 Explain double Q-Learning of TD3	57
Εικόνα 9 Explain Delayed Policy TD3	58
Εικόνα 10 Target Policy Smoothing TD3	60
Εικόνα 11 Update value of the actor TD3	61
Εικόνα 12 DQN vs DDPG	64
Εικόνα 13 Actor critic DDPG	65
Εικόνα 14 Training and Testing DDPG	66
Εικόνα 15 Suitability of Algorithms proven by StableBaselines	76
Εικόνα 16 Atari Breakout environment	84
Εικόνα 17 LunarLander Gym Environment	85
Εικόνα 18 Code Block for example of analyze, training and evaluate Model	89
Εικόνα 19 Πίνακας αποτελεσμάτων αξιολόγησης A2C	90
Εικόνα 20 Γραφήματα μοντέλων A2C (αριστερά) σε MlpPolicy και (δεξιά) σε CnnPolicy	90
Εικόνα 21 Γραφήματα μοντέλων A2C με διαφορετικούς παραμέτρους	91
Εικόνα 22 Γραφήματα μοντέλων απόδοσης A2C 1.000.000 εποχές	92
Εικόνα 23 Πίνακας αποτελεσμάτων αξιολόγησης PPO	93
Εικόνα 24 Γράφημα μοντέλων απόδοσης PPO 300.000 εποχές	93
	10

<u>Εικόνα 25 Γράφημα time μοντέλων PPO</u>	94
<u>Εικόνα 26 Γραφήματα μοντέλων διάφορων μετρικών PPO</u>	94
<u>Εικόνα 27 Γραφήματα μοντέλων PPO</u>	95
<u>Εικόνα 28 Γραφήματα απόδοσης μοντέλων TD3</u>	96
<u>Εικόνα 29 Γραφήματα time (αριστερά) και actor loss (δεξιά) μοντέλων TD3</u>	97
<u>Εικόνα 30 Γραφήματα απόδοσης μοντέλων DDPG</u>	97
<u>Εικόνα 31 Γράφημα απόδοσης χρόνου DDPG</u>	98
<u>Εικόνα 32 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C και PPO</u>	99
<u>Εικόνα 33 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C και PPO σε περιβάλλον PACMAN</u>	100
<u>Εικόνα 34 Γραφήματα αποτελεσμάτων σύγκρισης μοντέλων A2C, PPO, DDPG, TD3</u>	101
<u>Εικόνα 35 Γράφημα απόδοσης PPO μετά από επανεκπαίδευση</u>	102
<u>Εικόνα 36 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C,PPO,DDPG,TD3 σε περιβάλλον Pendulum</u>	102

Κατάλογος Πινάκων

<u>Πίνακας 1 Αποτελέσματα σύγκρισης A2C και PPO</u>	99
<u>Πίνακας 2 Πίνακας αποτελεσμάτων σύγκρισης μοντέλων A2C, PPO, DDPG, TD3</u>	100
<u>Πίνακας 3 Πίνακας απόδοσης μοντέλων A2C, PPO, TD3,DDPG</u>	104

Περίληψη

Η ενισχυτική μάθηση (RL) έχει αναδειχθεί ως μια ισχυρή τεχνική στον τομέα της τεχνητής νοημοσύνης, επιτρέποντας στους πράκτορες να μαθαίνουν βέλτιστες συμπεριφορές μέσω αλληλεπιδράσεων με ένα περιβάλλον. Με τον πολλαπλασιασμό των αλγορίθμων RL, καθίσταται απαραίτητη η αξιολόγηση και η σύγκριση της απόδοσής τους σε διάφορα περιβάλλοντα. Σε αυτό το πλαίσιο, το Stable Baselines και το OpenAI Gym παρέχουν πολύτιμα εργαλεία και περιβάλλοντα για πειραματική αξιολόγηση. Η παρούσα εργασία έχει ως στόχο να διερευνήσει την πειραματική αξιολόγηση αλγορίθμων ενισχυτικής μάθησης με τη χρήση των περιβαλλόντων Stable Baselines και Gym, αναδεικνύοντας τις προκλήσεις, τις εφαρμογές και τις πιθανές λύσεις καθώς επίσης να διερευνήσει και να αξιολογήσει την απόδοση τεσσάρων κύριων αλγορίθμων ενισχυτικής μάθησης: Advantage Actor-Critic (A2C), Proximal Policy Optimization (PPO), Twin Delayed DDPG (TD3), Deep Deterministic Policy Gradient (DDPG).

Σε αυτή την εργασία αναπτύσσονται και παρουσιάζονται προσεγγίσεις ενισχυτικής μάθησης με ολοκληρωμένες δοκιμές, αξιολόγηση απόδοσης και συγκριτική ανάλυση.

Λέξεις Κλειδιά: Ενισχυτική Μάθηση (RL) ,Αξιολόγηση, Σύγκριση, Stable Baselines, Gym, Advantage Actor-Critic (A2C), Proximal Policy Optimization (PPO), Twin Delayed DDPG (TD3), Deep Deterministic Policy Gradient (DDPG).

Abstract:

Reinforcement learning (RL) has emerged as a powerful technique in the field of artificial intelligence, enabling agents to learn optimal behaviors through interactions with an environment. With the proliferation of RL algorithms, it becomes essential to evaluate and compare their performance across various environments. In this context, Stable Baselines and OpenAI Gym provide valuable tools and environments for experimental evaluation. This paper aims to explore the experimental evaluation of reinforcement learning algorithms using Stable Baselines and Gym environments, highlighting the challenges, applications, and potential solutions, as well as researching and assessing these algorithms is to have a thorough understanding of their capabilities, limitations, and usefulness in diverse situations.

Reinforcement learning methodologies are created and described in this work, together with integrated testing, performance evaluation, and comparison analysis.

Key words: Reinforcement Learning (RL) ,Evaluation, Comparison, Stable Baselines, Gym, Advantage Actor-Critic (A2C), Proximal Policy Optimization (PPO), Twin Delayd *DDPG* (TD3), Deep Deterministic Policy Gradient (DDPG).

Κεφάλαιο 1^ο Εισαγωγή

1.1 Παρουσίαση Προβλήματος

Η τεχνητή νοημοσύνη (AI) είναι ένας τομέας που προσπαθεί να διαμορφώσει συστήματα υπολογιστών ικανά να εκτελούν εργασίες που παραδοσιακά απαιτούν την ανθρώπινη νοημοσύνη, περιλαμβάνοντας την αντίληψη, τη μάθηση, τη συλλογιστική, την επίλυση προβλημάτων και τη λήψη αποφάσεων, αξιοποιώντας αλγορίθμους και υπολογιστικά μοντέλα (Sutton, 2018).

Ο τομέας της τεχνητής νοημοσύνης θα μπορούσαμε να πούμε πως καθιερώθηκε στη δεκαετία του 1950. Στα αρχικά της στάδια, η AI επικεντρώθηκε στη συμβολική AI, προσπαθώντας να κατασκευάσει συστήματα ικανά να αναλογίζονται και να επιλύουν προβλήματα μέσω της εφαρμογής συμβολικής λογικής και κανόνων. Η προσέγγιση αυτή αντιμετώπισε περιορισμούς λόγω της περίπλοκης φύσης και της ασάφειας των προβλημάτων του πραγματικού κόσμου. Με την πάροδο των χρόνων και τις τεχνολογικές εξελίξεις, η AI υπέστη σημαντικές αλλαγές σε διάφορα πεδία της, όπως η μηχανική μάθηση, η επεξεργασία φυσικής γλώσσας, και η ρομποτική (Mnih V. e., 2015). Μεταξύ αυτών των εξελίξεων, ξεχωρίζει η εμφάνιση της μηχανικής μάθησης, η οποία δίνει τη δυνατότητα στους υπολογιστές να μαθαίνουν από δεδομένα και να βελτιώνουν τις επιδόσεις τους χωρίς ρητό προγραμματισμό.

Στο πεδίο της μηχανικής μάθησης, η ενισχυτική μάθηση (RL) αντιπροσωπεύει ένα παράδειγμα που επικεντρώνεται στην ικανότητα ενός πράκτορα να μαθαίνει μέσω της αλληλεπίδρασης με το περιβάλλον, με στόχο τη μεγιστοποίηση των ανταμοιβών ή την ελαχιστοποίηση του κόστους. Αυτό το παράδειγμα αντλεί έμπνευση από την έννοια της μάθησης με δοκιμή και σφάλμα, αντικατοπτρίζοντας τον τρόπο με τον οποίο οι άνθρωποι

και τα ζώα αποκτούν γνώση μέσω της εμπλοκής τους με το περιβάλλον τους. Η ενισχυτική μάθηση έχει αποσπάσει σημαντική προβολή τον τελευταίο καιρό, γεγονός που αποδίδεται στα επιτεύγματά της στην αντιμετώπιση περίπλοκων καθηκόντων όπως το παίξιμο παιχνιδιών (π.χ. AlphaGo, AlphaZero) και ο έλεγχος ρομποτικών συστημάτων (Silver D. e., 2017). Η εφαρμογή της επεκτείνεται σε διάφορους τομείς, όπως η αυτόνομη οδήγηση, η ρομποτική, τα συστήματα συστάσεων, η χρηματοδότηση και η υγειονομική περίθαλψη.

Η RL παρουσιάζει μοναδικές προκλήσεις λόγω της δυναμικής διαδικασίας μάθησης από τις ενέργειες και τις ανταμοιβές και της απουσίας ρητών κανόνων ή σημασίας χαρακτηριστικών. Ωστόσο παρά τις προκλήσεις, οι ερευνητές διερευνούν ενεργά τεχνικές για την ερμηνεία των μοντέλων RL. Η ανάλυση των κλίσεων του δικτύου πολιτικής RL σε σχέση με τις καταστάσεις εισόδου μπορεί να παράσχει πληροφορίες για τις καταστάσεις που συμβάλλουν σημαντικά στη διαδικασία λήψης αποφάσεων. Η ερμηνεία των εκτιμήσεων της συνάρτησης αξίας ρίχνει φως στις προτιμήσεις του μοντέλου και στην αντίληψή του για τις μακροπρόθεσμες ανταμοιβές που συνδέονται με διαφορετικές καταστάσεις και ενέργειες (Sutton, 2018).

Η ερμηνεία των μοντέλων τεχνητής νοημοσύνης, συμπεριλαμβανομένων των μοντέλων RL, είναι ζωτικής σημασίας για τη διασφάλιση της διαφάνειας, της εμπιστοσύνης και της λογοδοσίας στις διαδικασίες λήψης αποφάσεων τους. Ενώ έχουν αναπτυχθεί τεχνικές ερμηνευσιμότητας για παραδοσιακά μοντέλα AI, τα μοντέλα RL παρουσιάζουν μοναδικές προκλήσεις λόγω της μάθησης δοκιμής και λάθους, των πολύπλοκων χώρων καταστάσεων και των καθυστερημένων ανταμοιβών (Koltun, 2018). Η υπέρβαση αυτών των προκλήσεων και η ανάπτυξη αποτελεσματικών προσεγγίσεων ερμηνείας για τα μοντέλα RL παραμένουν ενεργά πεδία έρευνας, συμβάλλοντας στην υπεύθυνη ανάπτυξη της RL σε πραγματικές εφαρμογές.

Στόχος της παρούσας εργασίας είναι η διερεύνηση και αξιολόγηση των αλγορίθμων ενισχυτικής μάθησης με την χρήση Stable Baselines και Gym περιβάλλοντων. Πιο αναλυτικά ακολουθεί η αξιολόγηση της απόδοσής μέσω πειρασμάτων, τεσσάρων αλγορίθμων Advantage Actor-Critic (A2C), Proximal Policy Optimization (PPO), Twin Delayed DDPG (TD3), Deep Deterministic Policy Gradient (DDPG).

Οι παραπάνω αλγόριθμοι χρησιμοποιούνται συνήθως στην ρομποτική, στην αυτόνομη οδήγηση, διαφήμιση, διαχείριση πόρων και παιχνίδια. Αξίζει να σημειωθεί πως από τις πιο διάσημες χρήσεις του RL και συγκεκριμένα του PPO είναι η αξιοποίηση του στην εφαρμογή ChatGPT.

1.2 Πως λειτουργούν οι Αλγόριθμοι της Ενισχυτικής Μάθησης στο παιχνίδι σε περιβάλλοντα Gym.

Η ενισχυτική μάθηση (RL) ενισχύει τα αυτόνομα συστήματα και τους πράκτορες δίνοντάς τους τη δυνατότητα να μαθαίνουν και να βελτιώνουν τις ικανότητές τους στη λήψη αποφάσεων μέσω της αλληλεπίδρασης με το περιβάλλον τους. Η RL έχει επιδείξει αξιοσημείωτα επιτεύγματα σε διάφορους τομείς, περιλαμβάνοντας τη ρομποτική, τα αυτόνομα οχήματα, τα παιχνίδια και τα συστήματα συστάσεων.

Οι αλγόριθμοι RL έχουν αποδειχθεί καθοριστικοί στην εκπαίδευση ρομπότ για την εκτέλεση περίπλοκων εργασιών, όπως ο χειρισμός αντικειμένων, η σύλληψη και η πλοήγηση. Με την ενεργή εμπλοκή με το περιβάλλον, τα ρομπότ μπορούν να αποκτήσουν βέλτιστες πολιτικές που επιτρέπουν την επίτευξη στόχων (Kolton, 2018).

Επιπλέον η RL έχει εφαρμοστεί με επιτυχία στην ανάπτυξη συστημάτων αυτόνομης οδήγησης, δίνοντάς τους τη δυνατότητα να προηγούνται σε περίπλοκα σενάρια κυκλοφορίας και να λαμβάνουν ορθές αποφάσεις οδήγησης (Leonard, 2019) Τέλος η RL

έχει επιτύχει πρωτοφανή ορόσημα στην αναπαραγωγή παιχνιδιών, ξεπερνώντας τις επιδόσεις σε ανθρώπινο επίπεδο σε παιχνίδια όπως το σκάκι, το Go και το Dota 2. Οι αλγόριθμοι RL αποκτούν στρατηγικές και βέλτιστες πολιτικές ανταγωνιζόμενοι τον εαυτό τους ή ανθρώπινους παίκτες.

Οι αλγόριθμοι ενισχυτικής μάθησης (RL), όπως οι A2C (Advantage Actor-Critic), PPO (Proximal Policy Optimization), Deep Deterministic Policy Gradient (DDPG) και TD3 (Twin Delayed DDPG), έχουν συμβάλει καθοριστικά στη βελτίωση της απόδοσης αυτόνομων συστημάτων και πρακτόρων σε παιχνίδια.

Ο A2C (Advantage Actor-Critic) συνδυάζει τα πλεονεκτήματα τόσο των μεθόδων actor-critic όσο και των μεθόδων policy gradient, επιτρέποντας αποτελεσματική και σταθερή μάθηση. Έχει επιτύχει στην εκπαίδευση πρακτόρων για την επίτευξη υψηλών βαθμολογιών σε διάφορα περιβάλλοντα παιχνιδιών. Ωστόσο, αυτές οι εκτιμήσεις μπορεί να παρουσιάζουν υψηλή μεταβλητότητα, οδηγώντας σε ασυνεπείς ενημερώσεις του δράστη και του κριτικού. Ως αποτέλεσμα, η διαδικασία μάθησης γίνεται λιγότερο σταθερή και η σύγκλιση του αλγορίθμου επιβραδύνεται (Volodymyr M. e., 2016).

Ο αλγόριθμος PPO προσφέρει ένα σταθερό και στιβαρό πλαίσιο μάθησης με ισχυρή δειγματοληπτική αποτελεσματικότητα. Εξισορροπεί αποτελεσματικά τον συμβιβασμό μεταξύ εξερεύνησης και εκμετάλλευσης. Ενώ ο PPO είναι γνωστός για τη σταθερότητα και την ευχρηστία του, είναι σημαντικό να γνωρίζουμε ότι η επίτευξη πλήρους σύγκλισης μπορεί να απαιτήσει πολλές επαναλήψεις, ιδίως σε πολύπλοκα περιβάλλοντα ή με μεγάλες αρχιτεκτονικές νευρωνικών δικτύων (OpenAI Five, 2018) .

Το TD3 εισήγαγε την ιδέα της χρήσης νευρωνικών δικτύων για την προσέγγιση της συνάρτησης δράσης-αξίας, επιτρέποντας την επιτυχή μάθηση από ακατέργαστες

αισθητηριακές εισόδους. Πέτυχε πρωτοποριακά αποτελέσματα, ξεπερνώντας τις επιδόσεις σε ανθρώπινο επίπεδο σε διάφορα παιχνίδια Atari 2600. Ωστόσο μπορεί να είναι επιρρεπές στην υπερεκτίμηση των τιμών δράσης σε ορισμένα σενάρια. Έχουν παρατηρηθεί δυσκολίες και προβλήματα σε περιβάλλοντα που έχουν μεγάλους χώρους συνεχόμενων καταστάσεων ή απαιτούν μακροπρόθεσμο σχεδιασμό (Volodymyr M. e., 2015).

Ο DDPG (Deep Deterministic Policy Gradient) είναι κατάλληλος για συνεχείς χώρους δράσης και έχει εφαρμοστεί με επιτυχία στη ρομποτική και σε τομείς παιχνιδιών. Μπορεί να μάθει ντετερμινιστικές πολιτικές, γεγονός που του δίνει πλεονέκτημα σε σχέση με άλλους αλγορίθμους, σε ορισμένα σενάρια όπου απαιτούνται ακριβείς ενέργειες. Είναι γνωστός για τη σταθερότητά του και την ικανότητά του να χειρίζεται χώρους καταστάσεων και δράσεων υψηλών διαστάσεων. Ωστόσο βασίζεται σε διάφορες υπερπαραμέτρους που πρέπει να συντονίζονται προσεκτικά για να επιτευχθεί η βέλτιστη απόδοση. Η επιλογή των υπερπαραμέτρων, όπως οι ρυθμοί μάθησης, ο θόρυβος διερεύνησης και οι αρχιτεκτονικές δικτύων, μπορεί να επηρεάσει σημαντικά τη σύγκλιση και τη σταθερότητα του αλγορίθμου. Η εύρεση του σωστού συνόλου υπερπαραμέτρων για μια συγκεκριμένη εργασία μπορεί να αποτελέσει πρόκληση και συχνά απαιτεί εκτεταμένο πειραματισμό και συντονισμό (Timothy P, 2015).

Πιο αναλυτικά, στη εργασία αυτή θα παρουσιαστούν και θα μελετηθούν, στο 2^ο Κεφάλαιο γίνεται μια εισαγωγή στη μηχανική μάθηση. Αναλύονται ορισμοί που είναι απαραίτητοι για την συνέχεια και πραγματοποιείται διαχωρισμός της Ενισχυτικής Μάθησης (RL) από τους άλλους τύπους μηχανικής μάθησης.

Στο 3^ο Κεφάλαιο μελετώνται η σημασία της ενισχυτικής μάθησης στην ανάπτυξη της τεχνητής νοημοσύνης. Αναφέρονται οι δυο κύριες κατηγορίες της ενισχυτικής μάθησης και

ακολουθεί μια αναλυτική περιγραφή των βασικών ορισμών της RL βασισμένη στη ανάλυση των μαθηματικών τύπων. Επιπλέον παρουσιάζονται αναλυτικά οι τέσσερις (4) αλγόριθμοι με τους οποίους θα γίνουν οι πειραματισμοί .

Στο 4^ο Κεφάλαιο παρουσιάζονται οι εφαρμογές και τα εργαλεία που χρησιμοποιήθηκαν κατά την εκτέλεση των πειραματισμών, καθώς και τα κριτήρια με τα οποία επιλέχθηκαν οι τέσσερις προαναφερθέντας αλγόριθμοι προς ερευνά.

Στο 5^ο Κεφάλαιο αναλύονται τα αποτελέσματα των πειραμάτων, για τον κάθε αλγόριθμο ξεχωριστά. Και τέλος στο 6^ο Κεφάλαιο καταγράφονται τα συμπεράσματα της εργασίας καθώς και προτάσεις για μελλοντικές μελέτες πάνω στο αντικείμενο αυτό.

Κεφάλαιο 2° Μηχανική μάθηση

2.1 Ιστορική αναδρομή

Η ιστορία της μαθησιακής μηχανικής μπορεί να αναχθεί στις αρχές του 20ού αιώνα, όταν οι εξελίξεις στην τεχνολογία και την ψυχολογία άνοιξαν το δρόμο για μια πιο συστηματική προσέγγιση του εκπαιδευτικού σχεδιασμού. Η μαθησιακή μηχανική, γνωστή και ως εκπαιδευτική μηχανική ή εκπαιδευτική μηχανική, είναι ένας διεπιστημονικός τομέας που συνδυάζει αρχές από την ψυχολογία, τις επιστήμες μάθησης και τη μηχανική για τη δημιουργία αποτελεσματικών και αποδοτικών μαθησιακών εμπειριών.

Ένας από τους πρωτοπόρους της μαθησιακής μηχανικής ήταν ο B.F. Skinner, ένας Αμερικανός ψυχολόγος που ανέπτυξε την έννοια της προγραμματισμένης διδασκαλίας τη δεκαετία του 1950 (Skinner, 1958). Ο Σκίνερ πίστευε ότι η μάθηση μπορεί να αναλυθεί σε μικρά, διαδοχικά βήματα και ότι τα βήματα αυτά μπορούν να παρουσιαστούν στους εκπαιδευόμενους με δομημένο τρόπο. Το έργο του έθεσε τα θεμέλια για τη χρήση της διδακτικής τεχνολογίας και των προγραμμάτων μάθησης που βασίζονται σε υπολογιστές.

Στη δεκαετία του 1970, η έλευση των προσωπικών υπολογιστών οδήγησε στην εμφάνιση της διδασκαλίας που βασίζεται σε υπολογιστή (CBI). Το σύστημα PLATO (Programmed Logic for Automatic Teaching Operations), που αναπτύχθηκε στο Πανεπιστήμιο του Ιλινόις, ήταν μια από τις πρώτες εφαρμογές μεγάλης κλίμακας του CBI. Προσέφερε διαδραστικά μαθήματα και αξιολογήσεις, επιτρέποντας στους μαθητές να προοδεύουν με το δικό τους ρυθμό.

Ο τομέας της μηχανικής μάθησης απέκτησε περαιτέρω δυναμική τη δεκαετία του 1990 με την άνοδο του διαδικτύου και της διαδικτυακής μάθησης. Η ανάπτυξη των συστημάτων διαχείρισης μάθησης (LMS) παρείχε μια πλατφόρμα για την παροχή εκπαιδευτικού περιεχομένου και την παρακολούθηση της προόδου των εκπαιδευομένων (Reiser, 2012). Η

έννοια των μαθησιακών αντικειμένων, των αρθρωτών μονάδων διδασκαλίας που μπορούν να επαναχρησιμοποιηθούν και να επαναπροσδιοριστούν, έγινε δημοφιλής κατά τη διάρκεια αυτής της περιόδου.

Τα τελευταία χρόνια, ο τομέας της μηχανικής μάθησης γνώρισε μια αναζωπύρωση λόγω των εξελίξεων στην ανάλυση δεδομένων και την τεχνητή νοημοσύνη. Οι μηχανικοί μάθησης αξιοποιούν πλέον αυτές τις τεχνολογίες για να αναλύουν τεράστιες ποσότητες δεδομένων που παράγονται από τους εκπαιδευόμενους και να βελτιώνουν το σχεδιασμό και την παροχή εκπαιδευτικού υλικού. Χρησιμοποιούν την αναλυτική μάθησης για τον εντοπισμό μοτίβων και τάσεων, την εξατομίκευση της διδασκαλίας και την παροχή έγκαιρης ανατροφοδότησης στους εκπαιδευόμενους (Siemens, 2012).

Η μηχανική μάθησης έχει επίσης αποκτήσει αναγνώριση ως επάγγελμα. Οργανισμοί όπως η Διεθνής Εταιρεία για την Τεχνολογία στην Εκπαίδευση (ISTE) και η Εταιρεία για την Έρευνα της Μαθησιακής Αναλυτικής (SoLAR) έχουν συμβάλει καθοριστικά στην προώθηση του τομέα και στην καθιέρωση προτύπων και βέλτιστων πρακτικών.

Η ιστορία της μαθησιακής μηχανικής είναι συνυφασμένη με τις εξελίξεις στην τεχνολογία και την ψυχολογία. Από την προγραμματισμένη διδασκαλία του Skinner μέχρι την ανάπτυξη της μάθησης μέσω υπολογιστή και της διαδικτυακής εκπαίδευσης, η μηχανική μάθησης έχει εξελιχθεί σε ένα διεπιστημονικό πεδίο που χρησιμοποιεί την ανάλυση δεδομένων και την τεχνητή νοημοσύνη για να βελτιώσει τη μαθησιακή εμπειρία (Siemens G, 2013). Με την εστίασή της στον σχεδιασμό βάσει αποδείξεων και την εφαρμογή των αρχών της μηχανικής, η μαθησιακή μηχανική συνεχίζει να διαμορφώνει το μέλλον της εκπαίδευσης.

2.2 Ορισμός μηχανικής μάθησης

Η μηχανική μάθηση είναι ένας τομέας της τεχνητής νοημοσύνης (AI) που επικεντρώνεται στην ανάπτυξη αλγορίθμων και μοντέλων που επιτρέπουν στους υπολογιστές να μαθαίνουν από δεδομένα και να κάνουν προβλέψεις ή αποφάσεις χωρίς να είναι ρητά προγραμματισμένοι. Περιλαμβάνει τη μελέτη στατιστικών και υπολογιστικών τεχνικών που επιτρέπουν στις μηχανές να βελτιώνουν αυτόματα την απόδοσή τους σε μια συγκεκριμένη εργασία (Bishop, 2006).

Γενικότερα, ο σκοπός της μάθησης δεν είναι η παραδοσιακή απομνημόνευση γεγονότων που επιτυγχάνεται με τη χρήση ενός βασικού πίνακα αποθήκευσης. Αντίθετα, είναι η ικανότητα παραγωγής ορθών εκτιμήσεων για δεδομένα που το σύστημα συναντά για πρώτη φορά. Η σημασία της μηχανικής μάθησης έγκειται ακριβώς σε αυτή την ιδιότητα, καθώς είναι κρίσιμο να μπορεί να προβλέπει, να εκτιμά άγνωστα προηγουμένως δεδομένα και να προβλέπει πόσο συναφή είναι χωρίς να τα έχει δει προηγουμένως (Mitchell T. M., 1997). Για να μπορέσει να χρησιμοποιηθεί αυτή η συλλογιστική, πρέπει να παρουσιαστούν παρόμοια στοιχεία ή δεδομένα, ώστε να αποκαλυφθεί η κρυφή σχέση μεταξύ των μεταβλητών.

Χρησιμοποιείται για μια ποικιλία υπολογιστικών εργασιών όπου η δημιουργία και η εφαρμογή αλγορίθμων θα ήταν απαγορευτική. Χρησιμοποιείται σε εφαρμογές που περιλαμβάνουν φίλτρα ανεπιθύμητης αλληλογραφίας, OCR χαρτιών και καρτών, μηχανές αναζήτησης και όραση υπολογιστών. Τέλος, θα μπορούσαμε να ορίσουμε τη μηχανική μάθηση ως τη συλλογή μεθοδολογιών για την ανάπτυξη κατάλληλων μοντέλων και αλγορίθμων ικανών να οδηγήσουν σε προβλέψεις (Hastie T. T., 2009).

Τα βασικά χαρακτηριστικά της μηχανικής μάθησης μπορούν να συνοψιστούν ως εξής:

- Προσέγγιση με βάση τα δεδομένα: Οι αλγόριθμοι μηχανικής μάθησης βασίζονται στα δεδομένα ως κύρια πηγή γνώσης. Μαθαίνουν μοτίβα και σχέσεις μέσα στα

δεδομένα για να κάνουν προβλέψεις ή αποφάσεις. Η διαθεσιμότητα μεγάλων συνόλων δεδομένων έχει συμβάλει καθοριστικά στην πρόοδο του πεδίου και στη βελτίωση της ακρίβειας των μοντέλων μηχανικής μάθησης.

- Μάθηση από την εμπειρία: Οι αλγόριθμοι μηχανικής μάθησης μαθαίνουν από την εμπειρία βελτιώνοντας επαναληπτικά τα μοντέλα τους με βάση την ανατροφοδότηση που λαμβάνουν από τα δεδομένα. Προσαρμόζονται και βελτιώνουν την απόδοσή τους καθώς συναντούν νέα παραδείγματα ή περιπτώσεις. Η εκπαίδευση με δεδομένα συνήθως αναφέρεται στην εποπτευόμενη μάθηση, όπου τα μοντέλα μαθαίνουν από παραδείγματα με ετικέτα, ενώ η εκπαίδευση με εμπειρία συνδέεται συχνά με την ενισχυτική μάθηση, όπου οι πράκτορες μαθαίνουν μέσω αλληλεπιδράσεων με ένα περιβάλλον, λαμβάνοντας ανταμοιβές ή ποινές με βάση τις ενέργειές τους.
- Ικανότητα γενίκευσης: Η μηχανική μάθηση στοχεύει στην ανάπτυξη μοντέλων που μπορούν να γενικεύουν καλά σε αθέατα δεδομένα. Ο στόχος είναι η εκμάθηση υποκείμενων προτύπων και σχέσεων που ισχύουν πέρα από τα δεδομένα εκπαίδευσης, επιτρέποντας ακριβείς προβλέψεις ή αποφάσεις σε νέα, προηγουμένως αθέατα δεδομένα.
- Αυτοματοποίηση: Η μηχανική μάθηση αυτοματοποιεί τη διαδικασία εξαγωγής γνώσης και διορατικότητας από τα δεδομένα. Μόλις τα μοντέλα εκπαιδευτούν, μπορούν να χρησιμοποιηθούν για να κάνουν προβλέψεις ή αποφάσεις χωρίς ρητή ανθρώπινη παρέμβαση, επιτρέποντας αποτελεσματικές και επεκτάσιμες λύσεις.
- Προσαρμοστικότητα και ευελιξία: Τα μοντέλα μηχανικής μάθησης έχουν σχεδιαστεί για να προσαρμόζονται και να προσαρμόζονται στα μεταβαλλόμενα δεδομένα και τις συνθήκες. Μπορούν να μαθαίνουν από νέες πληροφορίες και να ενημερώνουν

τις γνώσεις τους, διασφαλίζοντας ότι παραμένουν συναφή και αποτελεσματικά σε δυναμικά περιβάλλοντα (Goodfellow, 2016).

2.3 Είδη Μηχανικής Μάθησης


Υπάρχουν διάφοροι τύποι αλγορίθμων μηχανικής μάθησης με βάση την προσέγγιση μάθησης και το πρόβλημα που στοχεύουν να λύσουν.

Επιβλεπόμενη μάθηση: Στην εποπτευόμενη μάθηση, το μοντέλο μαθαίνει από παραδείγματα με ετικέτα όπου παρέχονται δεδομένα εισόδου και εξόδου. Στόχος του είναι να μάθει μια αντιστοίχιση μεταξύ των εισόδων και των αντίστοιχων εξόδων. Τα παραδείγματα περιλαμβάνουν αλγόριθμους ταξινόμησης και παλινδρόμησης.

Εκμάθηση χωρίς επίβλεψη: Στη μάθηση χωρίς επίβλεψη, το μοντέλο μαθαίνει από δεδομένα χωρίς ετικέτα χωρίς συγκεκριμένη μεταβλητή εξόδου ή στόχο. Ο στόχος είναι να ανακαλύψετε υποκείμενα μοτίβα, δομές ή σχέσεις στα δεδομένα. Οι αλγόριθμοι ομαδοποίησης, μείωσης διαστάσεων και ανίχνευσης ανωμαλιών είναι παραδείγματα μάθησης χωρίς επίβλεψη.

Ενισχυτική μάθηση: Η ενισχυτική μάθηση περιλαμβάνει έναν πράκτορα που μαθαίνει να αλληλοεπιδρά με ένα περιβάλλον για να μεγιστοποιήσει τις σωρευτικές ανταμοιβές. Ο πράκτορας αναλαμβάνει ενέργειες στο περιβάλλον, λαμβάνει ανατροφοδότηση με τη μορφή ανταμοιβών ή κυρώσεων και μαθαίνει να παίρνει καλύτερες αποφάσεις με την πάροδο του χρόνου. Χρησιμοποιείται συνήθως στη ρομποτική, στο παιχνίδι και στα αυτόνομα συστήματα. (Siemen, 2011)

Types of Machine Learning



Εικόνα 1 Τύποι Μηχανικής Μάθησης

2.3.1 Μάθηση χωρίς Επίβλεψη ή Μάθηση από παρατήρηση

Η επιβλεπόμενη μηχανική μάθηση είναι ένα υποπεδίο της μηχανικής μάθησης που περιλαμβάνει την εκπαίδευση αλγορίθμων σε επισημασμένα δεδομένα για την πραγματοποίηση προβλέψεων ή ταξινομήσεων. Στην επιβλεπόμενη μάθηση, ο αλγόριθμος μαθαίνει από παραδείγματα όπου τα δεδομένα εισόδου αντιστοιχίζονται με αντίστοιχες ετικέτες-στόχους ή εξόδους. Στόχος της είναι να μάθει μια συνάρτηση αντιστοίχισης που μπορεί να προβλέψει με ακρίβεια την έξοδο για νέα, αόρατα δεδομένα εισόδου (Bishop, 2006).

Η διαδικασία της μάθησης με επίβλεψη περιλαμβάνει συνήθως δύο κύρια βήματα: την εκπαίδευση και την εξαγωγή συμπερασμάτων. Κατά τη διάρκεια της εκπαίδευσης, ο αλγόριθμος μαθαίνει από τα επισημασμένα δεδομένα προσαρμόζοντας τις εσωτερικές του παραμέτρους ή τη δομή του μοντέλου του ώστε να ελαχιστοποιήσει το σφάλμα μεταξύ των προβλεπόμενων εξόδων και των πραγματικών ετικετών. Στη φάση εξαγωγής

συμπερασμάτων, το εκπαιδευμένο μοντέλο χρησιμοποιείται για να κάνει προβλέψεις σε νέα, μη επισημασμένα δεδομένα (Hastie T. T., 2009).

Οι αλγόριθμοι επιβλεπόμενης μάθησης μπορούν να λάβουν διάφορες μορφές, όπως τα δέντρα αποφάσεων, οι μηχανές διανυσμάτων υποστήριξης (SVM) και τα νευρωνικά δίκτυα. Χρησιμοποιούνται ευρέως σε εφαρμογές όπως η ταξινόμηση εικόνων, η επεξεργασία φυσικής γλώσσας και η ανάλυση παλινδρόμησης (Alpaydin, 2010).

2.3.2 Μάθηση με επίβλεψη ή μάθηση με παραδείγματα

Η μάθηση με επίβλεψη, γνωστή και ως μάθηση μέσω παραδειγμάτων ή μάθηση από παραδείγματα, είναι μια θεμελιώδης προσέγγιση στη μηχανική μάθηση, όπου οι αλγόριθμοι μαθαίνουν μοτίβα και σχέσεις μεταξύ των δεδομένων εισόδου και των αντίστοιχων ετικετών εξόδου. Σε αυτή τη διαδικασία, στον αλγόριθμο παρέχεται ένα σύνολο δεδομένων με ετικέτες, το οποίο αποτελείται από ζεύγη εισόδου-εξόδου, και ο στόχος του είναι να γενικεύσει από τα παραδείγματα για να κάνει ακριβείς προβλέψεις ή ταξινομήσεις σε νέα, αθέατα δεδομένα (Bishop, 2006).

Η βασική ιδέα της μάθησης με επίβλεψη είναι η εκμάθηση μιας συνάρτησης αντιστοίχισης που μπορεί να μετασχηματίσει τα χαρακτηριστικά εισόδου στις αντίστοιχες εξόδους-στόχους τους. Ο αλγόριθμος εξετάζει τα παρεχόμενα παραδείγματα, αναλύει τα χαρακτηριστικά τους και εντοπίζει μοτίβα για τη δημιουργία ενός μοντέλου ικανού να κάνει προβλέψεις σε νέα, αθέατα παραδείγματα.

Οι δημοφιλείς αλγόριθμοι που χρησιμοποιούνται στην επιβλεπόμενη μάθηση περιλαμβάνουν τα δέντρα αποφάσεων, τις μηχανές διανυσμάτων υποστήριξης (SVM), τη λογιστική παλινδρόμηση και τα νευρωνικά δίκτυα. Αυτοί οι αλγόριθμοι χρησιμοποιούν διάφορες τεχνικές για τη γενίκευση από τα παρεχόμενα παραδείγματα, όπως η

προσαρμογή των βαρών και των σταθερών συντελεστών, η βελτιστοποίηση των παραμέτρων ή η κατασκευή ορίων απόφασης (Hastie T. T., 2009).

Η επιβλεπόμενη μάθηση βρίσκει εκτεταμένη εφαρμογή σε διάφορους τομείς, όπως η ταξινόμηση εικόνων, η αναγνώριση ομιλίας, η επεξεργασία φυσικής γλώσσας και τα συστήματα συστάσεων. Επιτρέπει στις μηχανές να αναγνωρίζουν αυτόματα μοτίβα, να ταξινομούν δεδομένα σε διάφορες κατηγορίες και να λαμβάνουν τεκμηριωμένες αποφάσεις με βάση τη γνώση που έχουν μάθει (Alpaydin, 2010).

2.3.3 Ενισχυτική Μηχανική Μάθηση

Η ενισχυτική μάθηση είναι ένα υποπεδίο της μηχανικής μάθησης που επικεντρώνεται στην ανάπτυξη αλγορίθμων και μοντέλων για έναν πράκτορα που μαθαίνει τις βέλτιστες ενέργειες μέσω δοκιμής και σφάλματος σε ένα περιβάλλον. Σε αντίθεση με την επιβλεπόμενη μάθηση, η ενισχυτική μάθηση δεν απαιτεί επισημειωμένα παραδείγματα, αλλά βασίζεται στην ανατροφοδότηση με τη μορφή ανταμοιβών ή τιμωριών για την καθοδήγηση της διαδικασίας μάθησης (Sutton, 2018).

Η βασική ιδέα της ενισχυτικής μάθησης είναι να δοθεί η δυνατότητα σε έναν πράκτορα να μάθει αλληλεπιδρώντας με ένα περιβάλλον. Ο πράκτορας αναλαμβάνει δράσεις και με βάση την ανατροφοδότηση που λαμβάνει, προσαρμόζει τη συμπεριφορά του ώστε να μεγιστοποιεί τη σωρευτική ανταμοιβή με την πάροδο του χρόνου. Ο στόχος είναι ο πράκτορας να μάθει μια βέλτιστη πολιτική που καθορίζει την καλύτερη ενέργεια που πρέπει να λάβει σε κάθε δεδομένη κατάσταση (Kaelbling, 1996).

Οι αλγόριθμοι ενισχυτικής μάθησης συχνά χρησιμοποιούν έννοιες όπως συναρτήσεις αξίας, κλίσεις πολιτικής και συμβιβασμούς εξερεύνησης-εκμετάλλευσης για τη λήψη αποφάσεων μάθησης. Αυτοί οι αλγόριθμοι μπορούν να χειριστούν πολύπλοκα προβλήματα λήψης διαδοχικών αποφάσεων και έχουν εφαρμοστεί με επιτυχία σε ένα

ευρύ φάσμα τομέων, όπως η ρομποτική, τα παιχνίδια και τα αυτόνομα συστήματα (Silver D. e., 2018).

2.4 Κατηγοριοποίηση και Αλγόριθμοι Ταξινόμησης

Η κατηγοριοποίηση είναι μια γνωστική διαδικασία μέσω της οποίας αντικείμενα, ιδέες ή γεγονότα ομαδοποιούνται σε σημαντικές κατηγορίες με βάση τα κοινά χαρακτηριστικά τους. Διαδραματίζει θεμελιώδη ρόλο στην ανθρώπινη νόηση και εφαρμόζεται επίσης σε διάφορους τομείς της επιστήμης των υπολογιστών και της μηχανικής μάθησης (Murphy, 2012).

Η κατηγοριοποίηση αναφέρεται στη νοητική ή υπολογιστική διαδικασία οργάνωσης πληροφοριών σε ομάδες με νόημα με βάση κοινά χαρακτηριστικά ή ιδιότητες. Περιλαμβάνει τον εντοπισμό ομοιοτήτων και διαφορών μεταξύ των αντικειμένων και τη δημιουργία εννοιολογικών κατηγοριών για την απλούστευση και τη δόμηση της κατανόησης του κόσμου.

Οι αλγόριθμοι ταξινόμησης είναι τεχνικές μηχανικής μάθησης που χρησιμοποιούνται για την κατηγοριοποίηση ή την ανάθεση προκαθορισμένων ετικετών ή κλάσεων σε νέες, μη επισημασμένες περιπτώσεις με βάση τα χαρακτηριστικά ή τις ιδιότητές τους (Hastie T. T., 2009). Ακολουθούν ορισμένοι συνήθεις αλγόριθμοι ταξινόμησης:

- Δέντρα απόφασης: Τα δέντρα αποφάσεων χρησιμοποιούν μια δενδροειδή δομή για να λαμβάνουν διαδοχικές αποφάσεις με βάση τις τιμές των χαρακτηριστικών και να δημιουργούν κανόνες ταξινόμησης.
- Naive Bayes: Οι ταξινομητές Naive Bayes εφαρμόζουν το θεώρημα του Bayes με την υπόθεση της ανεξαρτησίας μεταξύ των χαρακτηριστικών για να υπολογίσουν την πιθανότητα κάθε κλάσης.

- Μηχανές διανυσμάτων υποστήριξης (SVM): Οι SVM στοχεύουν στην εύρεση ενός βέλτιστου υπερεπιπέδου που διαχωρίζει τις διάφορες κλάσεις μεγιστοποιώντας το περιθώριο μεταξύ τους.
- k-κοντινότεροι γείτονες (k-NN): Το k-NN ταξινομεί τις περιπτώσεις αναθέτοντάς τους την ετικέτα της πλειοψηφικής κλάσης μεταξύ των k κοντινότερων γειτόνων τους στο χώρο των χαρακτηριστικών.
- Random Forest: Το Random Forest συνδυάζει πολλαπλά δέντρα απόφασης για να κάνει προβλέψεις αθροίζοντας τις επιμέρους εξόδους τους (Mitchell T. , 1997).

Μερικά παραδείγματα ταξινόμησης που βρίσκουν εφαρμογή στην καθημερινότητα είναι:

- Φιλτράρισμα ανεπιθύμητων μηνυμάτων ηλεκτρονικού ταχυδρομείου: Οι αλγόριθμοι ταξινόμησης μπορούν να χρησιμοποιηθούν για τη διάκριση μεταξύ ανεπιθύμητων και νόμιμων μηνυμάτων ηλεκτρονικού ταχυδρομείου με βάση διάφορα χαρακτηριστικά, όπως η γραμμή θέματος, ο αποστολέας και το περιεχόμενο.
- Αναγνώριση εικόνων: Οι αλγόριθμοι ταξινόμησης μπορούν να αναγνωρίσουν αντικείμενα σε εικόνες, όπως η αναγνώριση διαφορετικών ειδών ζώων ή η ταξινόμηση χειρόγραφων ψηφίων.
- Διάγνωση ασθενειών: Οι ιατρικές εφαρμογές χρησιμοποιούν αλγορίθμους ταξινόμησης για να βοηθήσουν στη διάγνωση ασθενειών με βάση τα συμπτώματα του ασθενούς, τα αποτελέσματα των εξετάσεων και το ιατρικό ιστορικό.
-

Κεφάλαιο 3° Ενισχυτική Μάθηση και η σημασία της στην Τεχνητή Νοημοσύνη

Η ενισχυτική μάθηση (RL) είναι ένας κλάδος της μηχανικής μάθησης που επικεντρώνεται στην εκπαίδευση ευφυών πόρων για τη λήψη διαδοχικών αποφάσεων σε αβέβαια και δυναμικά περιβάλλοντα. Σε αντίθεση με την επιβλεπόμενη μάθηση, όπου παρέχονται σαφείς ετικέτες, και την μη επιβλεπόμενη μάθηση, η οποία στοχεύει στην ανακάλυψη μοτίβων σε δεδομένα χωρίς ετικέτες, η ενισχυτική μάθηση περιλαμβάνει έναν πράκτορα που αλληλεπιδρά με ένα περιβάλλον, μαθαίνει από σήματα ανατροφοδότησης και βελτιστοποιεί τις ενέργειές του για να μεγιστοποιήσει τις μακροπρόθεσμες ανταμοιβές (Sutton, 2018). Αυτό το παράδειγμα έχει αποκτήσει σημαντική σημασία στον τομέα της τεχνητής νοημοσύνης λόγω της ικανότητάς του να αντιμετωπίζει σύνθετα προβλήματα λήψης αποφάσεων. Η ενισχυτική μάθηση υπόσχεται πολλά σε διάφορους τομείς, όπως η ρομποτική, τα τυχερά παιχνίδια, τα χρηματοοικονομικά, η υγειονομική περίθαλψη και τα αυτόνομα συστήματα (Kaelbling, 1996). Η βασική σημασία της ενισχυτικής μάθησης στην τεχνητή νοημοσύνη μπορεί να συνοψιστεί ως εξής:

- Μάθηση από την αλληλεπίδραση: Η RL επιτρέπει στους πράκτορες να μαθαίνουν από τη δοκιμή και το σφάλμα αλληλεπιδρώντας με το περιβάλλον τους. Αυτή η ικανότητα είναι ζωτικής σημασίας σε σενάρια όπου η απόκτηση επισημασμένων δεδομένων εκπαίδευσης είναι δύσκολη ή δαπανηρή.
- Προσαρμοστική λήψη αποφάσεων: Οι αλγόριθμοι RL μαθαίνουν να προσαρμόζουν τις ενέργειές τους με βάση τις μεταβαλλόμενες περιβαλλοντικές συνθήκες και τα σήματα ανατροφοδότησης. Αυτή η προσαρμοστική ικανότητα λήψης αποφάσεων είναι πολύτιμη σε δυναμικά και αβέβαια περιβάλλοντα (Mnih V. e., 2015).

- Χειρισμός πολύπλοκων περιβαλλόντων: Η RL είναι ιδιαίτερα αποτελεσματική στο χειρισμό πολύπλοκων και μεγάλων χώρων καταστάσεων και δράσεων. Επιτρέπει στους πράκτορες να μαθαίνουν εξελιγμένες στρατηγικές εξερευνώντας και εκμεταλλευόμενοι το περιβάλλον με την πάροδο του χρόνου.
- Βέλτιστος έλεγχος: Η RL παρέχει ένα πλαίσιο για την εύρεση βέλτιστων πολιτικών ελέγχου που μεγιστοποιούν τις σωρευτικές ανταμοιβές. Αυτό είναι ζωτικής σημασίας σε τομείς όπου ο στόχος είναι η βελτιστοποίηση μακροπρόθεσμων στόχων.
- Συμβιβασμός εξερεύνησης και εκμετάλλευσης: Οι αλγόριθμοι ενισχυτικής μάθησης αντιμετωπίζουν το δίλημμα εξερεύνησης-εκμετάλλευσης, εξισορροπώντας μεταξύ της ανακάλυψης νέων ενεργειών και της εκμετάλλευσης γνωστών ενεργειών. Αυτός ο συμβιβασμός είναι απαραίτητος για την εκμάθηση βέλτιστων πολιτικών.
- Μάθηση μεταφοράς: Οι αλγόριθμοι RL μπορούν να μεταφέρουν τη γνώση που μαθαίνουν από μια εργασία ή ένα περιβάλλον σε μια άλλη. Αυτή η ικανότητα αξιοποίησης της προηγούμενης γνώσης ενισχύει την αποτελεσματικότητα της μάθησης και τη γενίκευση σε διαφορετικά σενάρια (Arulkumaran, 2017).
- Πραγματικές εφαρμογές: Η RL έχει επιδείξει σημαντική επιτυχία σε διάφορες εφαρμογές του πραγματικού κόσμου, όπως η αυτόνομη οδήγηση, τα παιχνίδια (π.χ. AlphaGo), ο ρομποτικός έλεγχος, τα συστήματα συστάσεων και η λήψη αποφάσεων στον τομέα της υγειονομικής περίθαλψης.

Η RL χωρίζεται σε 2 κατηγορίες, την Model-Free και Model-based

- **Model-Based**: βασίζεται σε μοντέλα και χρησιμοποιεί την εμπειρία για να δημιουργήσει ένα εσωτερικό μοντέλο των μεταβάσεων και των άμεσων

αποτελεσμάτων στο περιβάλλον. Στη συνέχεια επιλέγονται οι κατάλληλες ενέργειες με αναζήτηση ή σχεδιασμό σε αυτό το παγκόσμιο μοντέλο.

- **Model- Free**: βασίζεται χωρίς μοντέλα, από την άλλη πλευρά, χρησιμοποιεί την εμπειρία για να μάθει απευθείας ένα ή και τα δύο από δύο απλούστερες ποσότητες (state/ action values or policies) που μπορούν να επιτύχουν την ίδια βέλτιστη συμπεριφορά αλλά χωρίς εκτίμηση ή χρήση ενός μοντέλου. Δεδομένης μιας πολιτικής, ένα state έχει μια αξία, που ορίζεται ως προς τη μελλοντική χρησιμότητα που αναμένεται να προκύψει ξεκινώντας από αυτήν την κατάσταση.

Η Ενισχυτική Μάθηση μας βοηθά να μάθουμε μια βέλτιστη ακολουθία βημάτων για να πετύχουμε τον τελικό μας στόχο (φτάσουμε στον προορισμό μας) χρησιμοποιώντας δοκιμή και σφάλμα. Παρακάτω θα δούμε τις βασικές ορολογίες οι οποίες θα μας βοηθήσουν να κατανοήσουμε καλύτερα το τι πραγματεύεται η ενισχυτική μάθηση:

- Environment (περιβάλλον): Είναι το μέρος όπου υπάρχει όλη η εγκατάσταση. Για εμάς, μπορεί να είναι οι δρόμοι Αυτοκινήτων & Πόλης, ένας λαβύρινθος, το περιβάλλον ενός παιχνιδιού (super mario) κλπ.
- Agent (πράκτορας): Ο πράκτορας είναι αυτός που αλληλεπιδρά με το Περιβάλλον. Ο οδηγός του αυτοκινήτου, το ανθρωπάκι που κινείται στον λαβύρινθο, ο χαρακτήρας που κινείται μέσα σε ένα παιχνίδι.
- Action (ενέργειες): Οι ενέργειες έγιναν από τον πράκτορα στο περιβάλλον (αυτοκίνητο). Το (φρένο, γκάζι, στροφή αριστερά) είναι μια ενέργεια.
- State (κατάσταση) : Όταν γίνεται μια ενέργεια (ενίσχυση φρένων), παρατηρούνται αλλαγές. Το κινούμενο αυτοκίνητο(State_1) αλλάζει στο σταματημένο αυτοκίνητο(State_2). Αυτή η πληροφορία

- Reward (ανταμοιβή) :Η ανταμοιβή είναι το άμεσο επιβράβευση που δίνεται όταν εκτελείται μια ενέργεια. Αυτή η ανταμοιβή μπορεί να είναι θετική (όταν ο πράκτορας φτάσει στην τελική κατάσταση, ή αρνητική (δεν έχει φτάσει ακόμα στον προορισμό).Το σύστημα ανταμοιβής μπορεί επίσης να τροποποιηθεί ανάλογα με το σύστημα. Μπορούμε να δώσουμε μικρές ανταμοιβές όταν ο πράκτορας βρίσκεται πιο κοντά στον προορισμό, μια μεγαλύτερη ανταμοιβή όταν φτάσετε στον προορισμό και καμία ανταμοιβή/αρνητική ανταμοιβή όταν απομακρύνεσαι από τον προορισμό.
- Policy (Πολιτική): Μια πολιτική ορίζει τον τρόπο συμπεριφοράς και εκπαίδευσης του πράκτορα σε μια δεδομένη στιγμή. Είναι ο κανόνας/αλγόριθμος που ακολουθούμε για να επιλέξουμε το επόμενο βήμα όταν σε οποιαδήποτε κατάσταση το S. E-Greedy μπορεί να ληφθεί ως παράδειγμα πολιτικής (τελικό σημείο).
- Episode (επεισόδιο): Ολόκληρος ο κύκλος όπου ξεκινά ένας πράκτορας και με κάποιο τρόπο, κάνοντας πολλές ενέργειες και αλλαγές καταστάσεων να φτάνει στην τερματική κατάσταση ονομάζεται ένα επεισόδιο. Για να διερευνηθεί μια βέλτιστη διαδρομή εκτελούνται πολλά τέτοια επεισόδια ξανά και ξανά. Είναι παρόμοιο με τις εποχές στη βαθιά μάθηση. Το RL μπορεί να ταξινομηθεί σε δύο μεγάλες κατηγορίες με βάση το εάν η εργασία τελειώνει ποτέ (discrete) , δηλαδή επεισοδιακή ή συνεχόμενη για πάντα (continuous), δηλαδή δεν έχει τερματική κατάσταση.
- Exploit (εκμετάλλευση): Όταν αναλαμβάνουμε την καλύτερη ενέργεια με την υψηλότερη ανταμοιβή, πιο γνωστή στο μοντέλο σε εκείνο το σημείο εκπαίδευσης, δεδομένης της κατάστασης, την ονομάζουμε Εκμετάλλευση. Ας υποθέσουμε ότι είμαστε στο Road_A(State_1). Ο πράκτορας οδηγός γνωρίζει ένα πιο σύντομο δρόμο που είναι μέσω ενός δρόμου, ROAD_B στα δεξιά. Επομένως, κάνοντας μια

δεξιά στροφή (Ενέργεια), θα φτάσουμε στον προορισμό πιο γρήγορα από το συνηθισμένο.

- Explore (Εξερεύνηση): Όταν επιλέγουμε τυχαία μια ενέργεια (χωρίς να υπολογίζουμε τις ανταμοιβές) στην οποία δίνεται μια κατάσταση, την ονομάζουμε Εξερεύνηση. Μπορεί να υπάρχει μια ακόμη πιο σύντομη διαδρομή για να φτάσουμε στον προορισμό που είναι άγνωστος στον πράκτορα. Εάν κάθε φορά που ακολουθούμε τη γνωστή συντόμευση, ενδέχεται να μην μπορούμε να την ανακαλύψουμε. Ως εκ τούτου, υπάρχει μια ανταλλαγή Exploit-Explore.
- Stateless Reinforcement Learning: Μερικές φορές, σε ορισμένες περιπτώσεις, η δήλωση προβλήματος δεν απαιτεί να συμβεί καμία κατάσταση (οποιαδήποτε ακολουθία γεγονότων) για να επιτευχθεί ο στόχος. Σε τέτοιες περιπτώσεις, η έννοια των κρατών παραλείπεται. Το καλύτερο παράδειγμα είναι αυτό ενός προβλήματος Multi-Armed Bandit.
- Temporal difference (TD) learning (Εκμάθηση χρονικής διαφοράς): Είναι μια προσέγγιση για την εκμάθηση τ που εξαρτάται από τις μελλοντικές τιμές ενός δεδομένου σήματος. Στο RL, οι μελλοντικές ανταμοιβές πρέπει να λαμβάνονται υπόψη όταν πρέπει να διαμορφώσουμε μια ισχυρή πολιτική, ώστε να βεβαιωθούμε ότι εκτελώντας αυτήν την ενέργεια σε μια δεδομένη κατάσταση, μπορούμε να φτάσουμε στον τελικό προορισμό ή όχι. Ως εκ τούτου, η μάθηση TD είναι αναπόσπαστο μέρος της ενισχυτικής μάθησης. Παράδειγμα: Όταν ο πράκτορας οδηγός πατάει φρένο (ενέργεια), το κινούμενο αυτοκίνητο (κατάσταση) σταματά. Άρα δεν μπορούμε να φτάσουμε στον προορισμό μας. Θα θέλαμε το σύστημά μας να μην επαναλάβει τέτοιες ενέργειες που δεν μπορούν να μας οδηγήσουν στον τελικό στόχο. Πρέπει να το προβλέψουμε χρησιμοποιώντας μελλοντικές

ανταμοιβές. Σε τέτοιες περιπτώσεις, η εκμάθηση TD μας βοηθά να προβλέψουμε τη σωστή δράση για τις μελλοντικές καταστάσεις.

- Markov property: Δηλώνει ότι η μελλοντική κατάσταση εξαρτάται μόνο από την παρούσα κατάσταση και όχι από τις προηγούμενες καταστάσεις του παράγοντα.
- Markov process: Είναι μια διαδικασία που έχει μια ακολουθία τυχαίων καταστάσεων που έχουν την ιδιότητα Markov. Πρέπει να σημειωθεί ότι η διαδικασία Markov έχει άπειρες καταστάσεις.
- Markov chain: Είναι παρόμοιο με τη Markov process αλλά με έναν πεπερασμένο αριθμό καταστάσεων.
- Markov decision process: Ένα MDP είναι ένα περιβάλλον όπου ικανοποιούνται όλες οι παραπάνω συνθήκες Markov. Αυτό το περιβάλλον έχει κάποιες ειδικές ιδιότητες (S, A, P, R, γ) όπου το S είναι ένα σύνολο πεπερασμένων καταστάσεων (όπως στο παραπάνω παράδειγμα). Το A είναι ένα σύνολο ενεργειών που μπορούν να γίνουν. P είναι η πιθανότητα μεταφοράς από τη μια κατάσταση στην άλλη. Το R αντιπροσωπεύει τις ανταμοιβές κατά τη μετάβαση από τη μια κατάσταση στην άλλη. Το γ είναι ο παράγοντας έκπτωσης.
- Discount Factor (γ): Το γ είναι ένα σταθερό κλάσμα μεταξύ 0-1 που μας βοηθά να ορίσουμε μια ισορροπία σχετικά με το πόσο ρόλο θα πρέπει να διαδραματίσουν οι μελλοντικές ανταμοιβές στον καθορισμό της πολιτικής σε μια δεδομένη κατάσταση όταν επαναλαμβάνεται μια ενέργεια. Πρέπει να καταλάβουμε ότι ο κύριος στόχος είναι η μεγιστοποίηση της συνολικής συσσωρευμένης ανταμοιβής από τον χρόνο T (όταν ληφθούν μέτρα) στο $T+K$ (όταν επιτευχθεί η τερματική κατάσταση, Εκμάθηση TD). Αλλά οι ανταμοιβές που προϋποτίθενται από μελλοντικές καταστάσεις δεν θα πρέπει να θεωρηθεί ορθές λόγω της αβεβαιότητας και θα πρέπει να έχει μικρή


επιρροή στην τρέχουσα λήψη αποφάσεων. Ως εκ τούτου, κάθε φορά που εξετάζουμε μελλοντικές ανταμοιβές για να ενημερώσουμε την πολιτική, προεξοφλούνται χρησιμοποιώντας τον παράγοντα έκπτωσης.

- Epsilon-greedy approach: Είναι μια μεθοδολογία για να αποφασιστεί η δράση που πρέπει να γίνει για το δεδομένο state. Εδώ το έψιλον είναι ένα σταθερό κλάσμα μεταξύ 0-1. Αυτή η προσέγγιση μας βοηθά να διατηρήσουμε το Explore-Exploit Tradeoff. Αυτό που συμβαίνει είναι ότι δημιουργείται ένας τυχαίος αριθμός, εάν πέσει κάτω από το έψιλον, πραγματοποιείται τυχαία ενέργεια.
- Value Functions: Είναι η τιμή/κατάσταση που συνεχίζουμε να ενημερώνουμε τον πράκτορα για να γνωρίζει πόσο πρέπει να προτιμάμε την παρούσα κατάσταση. Αυτή η «προτίμηση» γίνεται γενικά με την εκτίμηση της μελλοντικής ανταμοιβής που μπορεί να λάβουμε εάν βρεθούμε σε αυτήν την κατάσταση.

3.1.1 Markov Decision Process

Το μοντέλο MDP λειτουργεί χρησιμοποιώντας βασικά στοιχεία όπως ο πράκτορας, καταστάσεις, ενέργειες, ανταμοιβές και οι βέλτιστες πολιτικές. Ο πράκτορας αναφέρεται σε ένα σύστημα υπεύθυνο για τη λήψη αποφάσεων και την εκτέλεση ενεργειών. Λειτουργεί σε ένα περιβάλλον που περιγράφει λεπτομερώς τις διάφορες καταστάσεις στις οποίες βρίσκεται ο πράκτορας ενώ μεταβαίνει από τη μια κατάσταση στην άλλη. Το MDP ορίζει τον μηχανισμό του τρόπου με τον οποίο ορισμένες καταστάσεις και οι ενέργειες ενός πράκτορα οδηγούν στις άλλες καταστάσεις. Επιπλέον, ο πράκτορας λαμβάνει ανταμοιβές ανάλογα με τη δράση που εκτελεί και την κατάσταση που επιτυγχάνει (τρέχουσα κατάσταση). Η πολιτική για το μοντέλο MDP αποκαλύπτει την ακόλουθη ενέργεια του πράκτορα ανάλογα με την τρέχουσα

κατάστασή του. Στην παρακάτω εικόνα βλέπουμε την γραφική αναπαράσταση ενός MDP μοντέλου.



Εικόνα 2 MDP model

Το μοντέλο MDP χρησιμοποιεί την Markov Property, η οποία δηλώνει ότι το μέλλον μπορεί να προσδιοριστεί μόνο από την παρούσα κατάσταση που ενσωματώνει όλες τις απαραίτητες πληροφορίες από το παρελθόν. Η Markov Property μπορεί να αξιολογηθεί χρησιμοποιώντας αυτήν την εξίσωση:

Όπου η πιθανότητα του της επόμενης κατάστασης ($P[S_{t+1}]$) δεδομένης της παρούσας κατάστασης (S_t) δίνεται από την πιθανότητα της επόμενης κατάστασης ($P[S_{t+1}]$) λαμβάνοντας υπόψη όλες τις προηγούμενες καταστάσεις ($S_1, S_2, S_3, \dots, S_t$).

Αυτό σημαίνει ότι το MDP χρησιμοποιεί μόνο την παρούσα/τρέχουσα κατάσταση για να αξιολογήσει τις επόμενες ενέργειες χωρίς καμία εξάρτηση από προηγούμενες καταστάσεις ή ενέργειες.

Η πολιτική ξεκινά με τη δημιουργία ενός τυχαίου αριθμού. Εάν είναι μεγαλύτερη από κάποια τιμή (όριο, δηλαδή έψιλον που ορίσαμε εμείς), θα επιλέξει την ενέργεια που επιστρέφει τη μέγιστη παρούσα ανταμοιβή (exploit) διαφορετικά κάνει μια τυχαία

ενέργεια (εξερεύνηση). Ακολουθείται μια τέτοια προσέγγιση για να διατηρήσει την ανταλλαγή εξερεύνησης-εκμετάλλευσης .

Η Διαδικασία Αποφάσεων Markov (MDP) είναι ένα μαθηματικό πλαίσιο που χρησιμοποιείται για τη μοντελοποίηση προβλημάτων λήψης αποφάσεων σε καταστάσεις όπου τα αποτελέσματα επηρεάζονται τόσο από τυχαία γεγονότα όσο και από τις ενέργειες που γίνονται από έναν πράκτορα. Μια κοινή χρήση ενός MDP είναι το πρόβλημα Multi-Armed Bandit, το οποίο είναι ένα κλασικό πρόβλημα ενισχυτικής μάθησης.

Στο πρόβλημα του Multi-Armed Bandit, ένας πράκτορας έρχεται αντιμέτωπος με ένα σύνολο κουλοχέρηδων, όπου ως γνωστόν έχουν ένα μοχλό που μπορεί να τραβηχτεί. Κάθε κουλοχέρης έχει μια σχετική άγνωστη κατανομή πιθανοτήτων ανταμοιβών. Ο στόχος του πράκτορα είναι να μεγιστοποιήσει τη συνολική του ανταμοιβή σε μια σειρά ενεργειών επιλέγοντας τους πιο αποδοτικούς κουλοχέρηδες για παιχνίδι. Σε κάθε χρονικό βήμα, ο πράκτορας επιλέγει έναν κουλοχέρη για να παίξει με βάση τις τρέχουσες γνώσεις και τη στρατηγική του. Ο πράκτορας λαμβάνει την ανταμοιβή, ενημερώνει τις γνώσεις του σχετικά με την κατανομή ανταμοιβής του μηχανήματος και, στη συνέχεια, αποφασίζει ποιο μηχανήμα θα παίξει στη συνέχεια.

Η επίλυση ενός MAB λύνεται ως εξής: Αρχικοποιούμε έναν πίνακα $M[x]$ όπου x =συνολικός αριθμός κουλοχέρηδων. Επιλέγουμε μια ενέργεια (ανάλογα με την πολιτική), Εάν είναι η πρώτη φορά που επιλέγεται ένας συγκεκριμένος κουλοχέρης, ενημερώνουμε το $M[x]$ =Ανταμοιβή αλλιώς ενημερώνουμε το $M[x]$ με μέσο όρο όλων των προηγούμενων ανταμοιβών.

Συστήματα όπου τα states ανήκουν στην Markov Property (εξάρτηση της μελλοντικής τιμής μόνο από την παρούσα κατάσταση και όχι από οποιαδήποτε προηγούμενη

κατάσταση) είναι αυτό που ονομάζουμε Διαδικασία Αποφάσεων Markov (Markov Decision Process) . Τα MDP είναι παραδείγματα προβλημάτων ενίσχυσης κατάστασης, καθώς έχουμε περισσότερες από 2 καταστάσεις στο σύστημα, δηλαδή έχουμε ενδιάμεσες καταστάσεις όπως 20, 30, 40 κ.λπ., εκτός από την αρχική κατάσταση (1) & την τελική κατάσταση (50) και την ολόκληρο το ταξίδι δεν μπορεί να τελειώσει χωρίς να φτάσετε σε ενδιάμεσες καταστάσεις. Όταν εκπαιδεύσουμε έναν πράκτορα να ενεργεί (παίζει) σε ένα τέτοιο περιβάλλον, θέλουμε η πολιτική μας να δίνει λιγότερη προτίμηση στο να φτάσουμε καθώς θα μας απομακρύνει από τον στόχο μας. Επίσης, θέλουμε η πολιτική μας να δίνει μεγαλύτερη προτίμηση στην βέλτιστη ενέργεια που θα μας φέρει πιο κοντά στον στόχο μας. Αλλά μια τέτοια προτίμηση μπορεί να δοθεί μόνο όταν ξέρουμε πόσο κοντά μπορεί να μας οδηγήσει αυτή η κατάσταση στο τέλος. Καθοριστικό ρόλο σε αυτό παίζει η Action value function όπου:

- Action-Value Function: (value|state,action) που να ενημερώνεται για να γνωρίζουμε πόσο πρέπει να προτιμάμε τις ενέργειες στην παρούσα κατάσταση. Αυτή η «προτίμηση» γίνεται γενικά με την εκτίμηση των μελλοντικών ανταμοιβών που μπορεί να λάβουμε. $\text{Return} = \text{Reward}(R_1 + aR_2 + a^2R_3 + \dots | \text{Given State, Chosen Action})$ όπου «a» είναι ο συντελεστής έκπτωσης (είδος εκθετικού βάρους, όσο μεγαλύτερη είναι η ανταμοιβή, μείον το βάρος). Οι μελλοντικές ανταμοιβές έχουν μικρότερο βάρος, καθώς δεν τις έχουμε λάβει, αλλά υποθέτοντας ότι μπορεί να τις λάβουμε. Reward() υποδηλώνει την αναμενόμενη τιμή που δημιουργεί μια τυχαία τιμή που καθορίζει εάν θα ακολουθηθεί η πολιτική ή εάν θα επιλεγεί μια τυχαία κατάσταση.
- Dynamic Programming: χρησιμοποιείται για να δημιουργηθούν ανταμοιβές για μελλοντικές πολιτικές.

➤ Εξίσωση Bellman

Η εξίσωση Bellman αποτελεί μία βασική εξίσωση στο πλαίσιο της ενισχυτικής μάθησης. Πρόκειται για μία αναδρομική εξίσωση που συνδέει την αξία μιας κατάστασης-ενέργειας ζεύγους με την αναμενόμενη ανταμοιβή που μπορεί να ληφθεί σε αυτήν την κατάσταση, καθώς και την αναμενόμενη αξία των επόμενων καταστάσεων. Η εξίσωση Bellman μπορεί να γραφεί με τη μορφή:

$$V(s) = R(s) + \gamma * \max[Q(s, a)]$$

όπου:

$V(s)$: αναπαριστά την αξία της κατάστασης s ,

$R(s)$: αναπαριστά την αμεσότητα ανταμοιβή που μπορεί να ληφθεί στην κατάσταση s ,

γ : είναι ο συντελεστής έκπτωσης που καθορίζει την σημασία των μελλοντικών ανταμοιβών,

$\max[Q(s, a)]$: αναπαριστά τη μέγιστη αξία της ενέργειας a που μπορεί να εκτελεστεί στην κατάσταση s σύμφωνα με την συνάρτηση Q .

Η εξίσωση Bellman χρησιμοποιείται για τον υπολογισμό των αξιών καταστάσεων στο ενισχυτικό μάθηση και για την εκτίμηση των βέλτιστων πολιτικών δράσης. Αποτελεί θεμελιώδη έννοια σε αλγορίθμους όπως οι Q-Learning, SARSA και Value Iteration, που επιλύουν προβλήματα ενισχυτικής μάθησης (Watkins C. J., 1992).

Επαναλαμβάνοντας αυτή τη διαδικασία για πολλές επαναλήψεις, ο πράκτορας μαθαίνει σταδιακά τη βέλτιστη στρατηγική για την πραγματοποίηση κινήσεων σε διαφορετικές διαμορφώσεις του περιβάλλοντος.

3.1.2 Monte Carlo method

Ο Monte Carlo απαιτούν μόνο εμπειρία και δείγματα ακολουθιών καταστάσεων, ενεργειών και ανταμοιβών από πραγματική ή προσομοιωμένη αλληλεπίδραση με ένα περιβάλλον. Η μάθηση από την πραγματική εμπειρία είναι εντυπωσιακή γιατί δεν

απαιτεί προηγούμενη γνώση της δυναμικής του περιβάλλοντος, ωστόσο μπορεί κανείς να επιτύχει τη βέλτιστη συμπεριφορά. Είναι μια μέθοδος εκτίμησης Value-action(Value|State, Action) ή Value function(Value|State) που χρησιμοποιεί ορισμένα δείγματα από το περιβάλλον για το οποίο υπολογίζεται η συνάρτηση. Ο μέσος όρος των ανταμοιβών που λαμβάνονται ανά κατάσταση (state) να είναι μια λύση και για προβλήματα state. Ο Μόντε κάρλο έχει 2 τύπους που μαθαίνουν για τον τρόπο υπολογισμού του μέσου όρου των μελλοντικών ανταμοιβών:

- First Visit Monte Carlo: Αθροίζουμε όλες τις ακόλουθες ανταμοιβές που έρχονται μετά από τη προηγούμενη.
- Every Visit Monte Carlo: δημιουργείται έναν νέο όρο άθροισης προσθέτοντας όλες τις ανταμοιβές που έρχονται μετά από κάθε εμφάνιση του πρώτου συνόλου συμπεριλαμβανομένου και του πρώτου.

3.1.3 TD Temporal Difference Learning algorithms

To Temporal Difference Learning (TD) learning είναι ένας συνδυασμός από τον Monte Carlo και δυναμικού προγραμματισμού (Dynamic Programming). Το Temporal Difference Learning δεν απαιτεί πληροφορίες για το περιβάλλον (όπως το Μόντε Κάρλο) , ενημερώνει τις εκτιμήσεις που βασίζονται εν μέρει σε άλλες γνωστές από την εκπαίδευση εκτιμήσεις, χωρίς να περιμένετε ένα τελικό αποτέλεσμα. Στο TD, αποφασίζουμε επίσης πόσες αναφορές χρειαζόμαστε από τις μελλοντικές τιμές για να ενημερώσουμε την τρέχουσα Value-Action-Function. Σημαίνει ότι μπορούμε να ενημερώσουμε την τρέχουσα Αξία-Δράση-Λειτουργία χρησιμοποιώντας όσες μελλοντικές ανταμοιβές θέλουμε. Μπορεί να είναι μόνο μία μελλοντική ανταμοιβή TD(0) από την αμέσως επόμενη μελλοντική κατάσταση ή μπορεί να είναι 5 μελλοντικές

ανταμοιβές από τις επόμενες 5 μελλοντικές καταστάσεις, π.χ. TD(5). Το βάρος είναι εντελώς στην κρίση μας.

3.1.4 SARSA

Ο SARSA (State-Action-Reward-State-Action) είναι μια μέθοδος εντός πολιτικής που χρησιμοποιείται για την εκμάθηση μιας πολιτικής σε μια διαδικασία απόφασης Markov (MDP). Το SARSA είναι ένας τύπος μάθησης χρονικών διαφορών, που σημαίνει ότι μαθαίνει ενημερώνοντας τις εκτιμήσεις του με βάση τις παρατηρούμενες διαφορές μεταξύ διαδοχικών καταστάσεων. Ο αλγόριθμος SARSA ακολουθεί μια επαναληπτική διαδικασία αλληλεπίδρασης με το περιβάλλον, ενημέρωσης των εκτιμήσεων δράσης-αξίας και προσαρμογής της πολιτικής ανάλογα. Το βασικό βήμα στο SARSA είναι η ενημέρωση της συνάρτησης Q , η οποία ακολουθεί την εξίσωση:

όπου:

$Q(s, a)$ είναι η εκτιμώμενη τιμή του ζεύγους κατάστασης-ενέργειας (s, a) .

α είναι ο ρυθμός εκμάθησης που καθορίζει το μέγεθος του βήματος της ενημέρωσης.

r είναι η παρατηρούμενη ανταμοιβή μετά την ανάληψη δράσης a στην κατάσταση s .

Το γ είναι ο παράγοντας έκπτωσης που εξισορροπεί τη σημασία των άμεσων και μελλοντικών ανταμοιβών.

$Q(s', a')$ είναι η εκτιμώμενη τιμή του επόμενου ζεύγους κατάστασης-ενέργειας (s', a') .

Η πολιτική συνήθως ενημερώνεται χρησιμοποιώντας μια στρατηγική εξερεύνησης-εκμετάλλευσης, όπως το epsilon-greedy, για να εξισορροπηθεί μεταξύ της εξερεύνησης νέων ενεργειών και της εκμετάλλευσης της γνώσης που αποκτήθηκε.

3.1.5 Q Learning

Είναι μια μέθοδος εκμάθησης χρονικών διαφορών εκτός πολιτικής, που ακολουθούμε διαφορετικές πολιτικές για την επιλογή της δράσης που θα αναληφθεί τόσο για τις σημερινές όσο και για τις μελλοντικές καταστάσεις. Ας υποθέσουμε ότι έχουμε 2 πολιτικές $P1=e\text{-greedy}$ (για την παρούσα κατάσταση), $P2=greedy$ (για μια μελλοντική κατάσταση, όπου επιλέγει την ενέργεια με την υψηλότερη ανταμοιβή).

3.2 Επεξήγηση Όρων πριν την Εισαγωγή στους Αλγορίθμους

Για να μιλήσουμε πιο συγκεκριμένα για το τι κάνει η RL, πρέπει να εισαγάγουμε πρόσθετη ορολογία. Πρέπει να αναφερθούμε στα εξής:

- Πολιτικές (Policies)

Μια πολιτική είναι ένας κανόνας που χρησιμοποιείται από έναν πράκτορα για να αποφασίσει ποιες ενέργειες θα λάβει χωρίζονται σε ντετερμινιστικές και στοχαστικές. Σε περίπτωση που είναι ντετερμινιστικό, συνήθως συμβολίζεται με (μ) : , ή μπορεί να είναι στοχαστική, οπότε συνήθως συμβολίζεται με (π) : .

Στο Deep RL, ασχολούμαστε με παραμετροποιημένες πολιτικές: πολιτικές των οποίων οι έξοδοι είναι υπολογίσιμες συναρτήσεις που εξαρτώνται από ένα σύνολο παραμέτρων (π.χ. τα βάρη και ορισμοί ενός νευρωνικού δικτύου) τις οποίες μπορούμε να προσαρμόσουμε για να αλλάξουμε τη συμπεριφορά μέσω κάποιου αλγορίθμου βελτιστοποίησης.

Συχνά δηλώνουμε τις παραμέτρους μιας τέτοιας πολιτικής με (θ) :) και .

- Ανταμοιβή και Επιστροφή (Reward and Return)

Η συνάρτηση ανταμοιβής R είναι εξαιρετικά σημαντική στην ενισχυτική μάθηση. Εξαρτάται από την τρέχουσα κατάσταση του κόσμου, τη δράση που μόλις έγινε και την επόμενη κατάσταση του κόσμου:

Ο στόχος του πράκτορα είναι να μεγιστοποιήσει την ανταμοιβή, αλλά αυτό στην πραγματικότητα μπορεί να σημαίνει μερικά πράγματα.

Ένα είδος απόδοσης είναι η μη προ εξοφλημένη απόδοση πεπερασμένου ορίζοντα(finite-horizon undiscounted return), η οποία είναι απλώς το άθροισμα των ανταμοιβών που λαμβάνονται σε ένα σταθερό παράθυρο βημάτων: .

Ένα άλλο είδος απόδοσης είναι η προεξοφλημένη απόδοση άπειρου ορίζοντα(infinite-horizon discounted return), η οποία είναι το άθροισμα όλων των ανταμοιβών που έλαβε ποτέ ο πράκτορας, αλλά με έκπτωση από το πόσο μακριά θα αποκτηθούν στο μέλλον. Αυτή η διατύπωση ανταμοιβής περιλαμβάνει έναν συντελεστή έκπτωσης gamma : .

- Παρατηρήσεις (States and Observations)

Ένα State είναι μια πλήρης περιγραφή της κατάστασης του περιβάλλοντος . Δεν υπάρχουν πληροφορίες για τον κόσμο που είναι κρυμμένο από το State. Observation είναι μια μερική περιγραφή μιας κατάστασης, η οποία μπορεί να περιέχει σημαντικές πληροφορίες.

Στο Deep RL, σχεδόν πάντα αντιπροσωπεύουμε καταστάσεις και παρατηρήσεις με real-valued vector, matrix, or higher-order tensor. Για παράδειγμα, μια οπτική παρατήρηση θα μπορούσε να αναπαρασταθεί από εικόνες RGB των τιμών των εικονοστοιχείων της, π.χ η κατάσταση ενός ρομπότ μπορεί να αντιπροσωπεύεται από τις γωνίες και τις ταχύτητες των αρθρώσεων του.

Όταν ο πράκτορας είναι σε θέση να παρατηρήσει την πλήρη κατάσταση του περιβάλλοντος, λέμε ότι το περιβάλλον παρατηρείται πλήρως(fully observed). Όταν ο πράκτορας μπορεί να δει μόνο μια μερική παρατήρηση, λέμε ότι το περιβάλλον παρατηρείται μερικώς(partially observed).

Ο συμβολισμός της κατάστασης (state) συνήθως συμβολίζεται με (s), και το observation με (o).

- Χώροι Δράσης (Action Spaces)

Διαφορετικά περιβάλλοντα επιτρέπουν διαφορετικά είδη ενεργειών. Το σύνολο όλων των έγκυρων ενεργειών σε ένα δεδομένο περιβάλλον ονομάζεται συχνά χώρος δράσης. Ορισμένα περιβάλλοντα, όπως το Atari και το Go, έχουν διακριτούς χώρους δράσης, όπου μόνο ένας πεπερασμένος αριθμός κινήσεων είναι διαθέσιμος στον πράκτορα. Άλλα περιβάλλοντα, όπως όπου ο πράκτορας ελέγχει ένα ρομπότ σε έναν φυσικό κόσμο, έχουν χώρους συνεχούς δράσης. Σε συνεχείς χώρους, οι ενέργειες είναι διανύσματα πραγματικής αξίας.

Αυτή η διάκριση έχει μερικές πολύ βαθιές συνέπειες για τις μεθόδους σε βαθιά RL. Ορισμένες οικογένειες αλγορίθμων μπορούν να εφαρμοστούν απευθείας μόνο στη μία περίπτωση και θα πρέπει να επαναληφθούν ουσιαστικά για την άλλη.

- Value Functions

Με τον όρο τιμή (value) , εννοούμε την αναμενόμενη απόδοση εάν ξεκινήσετε σε αυτήν την κατάσταση ή το ζεύγος κατάστασης-ενέργειας και στη συνέχεια ενεργήσετε σύμφωνα με μια συγκεκριμένη πολιτική για πάντα. Οι συναρτήσεις τιμών χρησιμοποιούνται, με τον ένα ή τον άλλο τρόπο, σχεδόν σε κάθε αλγόριθμο RL.

Υπάρχουν τέσσερις κύριες λειτουργίες σημείωσης εδώ.

On-Policy Value Function, που δίνει την αναμενόμενη απόδοση ξεκινώντας από την κατάσταση s και ενεργεί πάντα σύμφωνα με την πολιτική π :

On-Policy Action-Value Function που δίνει την αναμενόμενη απόδοση εάν ξεκινήσει στην κατάσταση s , και προβεί σε μια αυθαίρετη ενέργεια a (η οποία μπορεί να μην προέρχεται από την πολιτική) και, στη συνέχεια, ενεργήσει σύμφωνα με την πολιτική π :

Optimal Value Function δίνει την αναμενόμενη απόδοση αφού ξεκινήσει σε κατάσταση s και ενεργεί πάντα σύμφωνα με τη βέλτιστη πολιτική στο περιβάλλον:

Optimal Action-Value Function που δίνει την αναμενόμενη απόδοση στην κατάσταση s , προβεί σε αυθαίρετη ενέργεια a και, στη συνέχεια ενεργεί σύμφωνα με τη βέλτιστη πολιτική στο περιβάλλον:

- Advantage Functions

Η Advantage function καταγράφει πόσο καλύτερη είναι μια ενέργεια σε σύγκριση με τις άλλες σε μια δεδομένη κατάσταση, ενώ όπως γνωρίζουμε η συνάρτηση τιμής καταγράφει πόσο καλό είναι να είσαι σε αυτήν την κατάσταση. Αντί να έχουμε τον κριτή να μάθει τις τιμές Q , τον κάνουμε να μάθει τις τιμές Advantage. Με αυτόν τον τρόπο η αξιολόγηση μιας δράσης βασίζεται όχι μόνο στο πόσο καλή είναι η δράση, αλλά και στο πόσο καλύτερη μπορεί να είναι. Το πλεονέκτημα της συνάρτησης πλεονέκτημα είναι ότι μειώνει την υψηλή διακύμανση των δικτύων πολιτικής και σταθεροποιεί το μοντέλο.

Η συνάρτηση πλεονεκτήματος που αντιστοιχεί σε μια πολιτική (π) περιγράφει πόσο καλύτερο είναι να κάνετε μια συγκεκριμένη ενέργεια a στην κατάσταση s , από την τυχαία επιλογή μιας ενέργειας σύμφωνα με το π , υποθέτοντας ότι ενεργείτε σύμφωνα με το (π).

Μαθηματικά, η συνάρτηση πλεονεκτήματος ορίζεται από

3.3 Αλγόριθμοι Ενισχυτικής Μάθησης

3.3.1 Ο αλγόριθμος Actor-Critic (A2C)

Ο αλγόριθμος Actor-Critic (A2C) είναι ένας δημοφιλής αλγόριθμος ενισχυτικής μάθησης (RL) που συνδυάζει τα πλεονεκτήματα τόσο των μεθόδων που βασίζονται στην πολιτική όσο και των μεθόδων που βασίζονται στην αξία (Mnih V. e., 2016). Ο A2C χρησιμοποιεί μια αρχιτεκτονική δράστη-κριτικού, όπου ο δράστης μαθαίνει την πολιτική και επιλέγει ενέργειες, και ο κριτικός εκτιμά τη συνάρτηση αξίας. Αυτός ο αλγόριθμος έχει εφαρμοστεί ευρέως σε διάφορους τομείς, αναδεικνύοντας την αποτελεσματικότητά του στην επίλυση σύνθετων εργασιών RL.


Ο A2C χρησιμοποιεί τη συνάρτηση πλεονεκτήματος (advantage function), η οποία μετρά το πλεονέκτημα της ανάληψης μιας συγκεκριμένης ενέργειας σε σύγκριση με τη μέση τιμή των ενεργειών σε μια δεδομένη κατάσταση. Αυτή η εκτίμηση του πλεονεκτήματος βοηθά τον πράκτορα να λαμβάνει πιο τεκμηριωμένες αποφάσεις και επιταχύνει τη μάθηση. Ο αλγόριθμος χρησιμοποιεί τη κλιμακωτή άνοδο για την ενημέρωση των παραμέτρων πολιτικής, χρησιμοποιώντας το πλεονέκτημα ως βάση για τη μείωση της διακύμανσης στις ενημερώσεις πολιτικής (Lillicrap T. P., 2015).

Ένα από τα αξιοσημείωτα πλεονεκτήματα του A2C είναι ο παραλληλισμός και η αποδοτικότητα στη χρήση των υπολογιστικών πόρων. Με την ταυτόχρονη αλληλεπίδραση με πολλαπλές περιπτώσεις του περιβάλλοντος, το A2C συλλέγει πιο διαφορετικές εμπειρίες και βελτιώνει την αποτελεσματικότητα του δείγματος (Schulman J. e., 2015). Επιπλέον, η ικανότητα του A2C να ενημερώνει την πολιτική με διαδικτυακό τρόπο επιτρέπει τη συνεχή μάθηση και την ταχύτερη σύγκλιση (Schulman J. e., 2017).

Το A2C έχει εφαρμοστεί με επιτυχία σε ένα ευρύ φάσμα εφαρμογών. Στον τομέα της ρομποτικής, το A2C έχει χρησιμοποιηθεί για την εκπαίδευση ελεγκτών ρομπότ για εργασίες όπως η σύλληψη αντικειμένων, η μετακίνηση και ο χειρισμός. Στον τομέα των παιχνιδιών, το A2C έχει επιδείξει αξιοσημείωτες επιδόσεις στην εκμάθηση πολύπλοκων

βιντεοπαιχνιδιών, όπως τα παιχνίδια Atari και το Dota 2. Το A2C έχει επίσης εφαρμοστεί σε εργασίες επεξεργασίας φυσικής γλώσσας, συμπεριλαμβανομένων των συστημάτων διαλόγου και της δημιουργίας γλωσσών (Hessel, 2018).

Ο αλγόριθμος Actor-Critic (A2C) είναι ένας δημοφιλής αλγόριθμος ενισχυτικής μάθησης (RL) που συνδυάζει τα πλεονεκτήματα τόσο των μεθόδων που βασίζονται στην πολιτική όσο και των μεθόδων που βασίζονται στην επιβράβευση (Mnih V. e., 2016). Ο αλγόριθμος Advantage Actor Critic (A2C) συνδυάζει δύο τύπους αλγορίθμων Ενισχυτικής μάθησης (Policy Based and Value Based). Οι πράκτορες που βασίζονται σε πολιτικές μαθαίνουν απευθείας μια πολιτική (μια κατανομή πιθανοτήτων ενεργειών) αντιστοιχίζοντας τις καταστάσεις εισόδου σε ενέργειες εξόδου. Οι αλγόριθμοι με βάση την τιμή μαθαίνουν να επιλέγουν ενέργειες με βάση την προβλεπόμενη τιμή της κατάστασης ή της ενέργειας εισόδου.




Εικόνα 3 Training cycle A2C

- Value Based: Προσπαθεί να βρει ή να προσεγγίσει τη συνάρτηση βέλτιστης τιμής, η οποία είναι μια αντιστοίχιση μεταξύ μιας ενέργειας και μιας τιμής. Όσο μεγαλύτερη είναι η τιμή, τόσο καλύτερη είναι η δράση. Ο πιο διάσημος αλγόριθμος είναι το Q Learning και όλες οι βελτιώσεις του όπως Deep Q Networks, Double Dueling Q Networks κ.λπ.

- Policy Based: Οι αλγόριθμοι που βασίζονται σε πολιτικές, όπως το Policy Gradients και το REINFORCE, προσπαθούν να βρουν τη βέλτιστη πολιτική απευθείας χωρίς την τιμή Q ως μεσάζων.

Ο αλγόριθμος αποτελείται από δύο δίκτυα (τον ηθοποιό (actor) και τον κριτή (critic) που συνεργάζονται για να λύσουν ένα συγκεκριμένο πρόβλημα. Σε υψηλό επίπεδο, η συνάρτηση Advantage Function υπολογίζει το TD Error or Prediction Error (σφάλμα ή το σφάλμα πρόβλεψης του πράκτορα).



Εικόνα 4 Value function A2C

Για συνεχή και στοχαστικά περιβάλλοντα, έχει ταχύτερη σύγκλιση η μέθοδος policy based ενώ με value based είναι πιο αποτελεσματικές και σταθερές στο δείγμα.

Η κύρια ιδέα είναι να χωριστεί το μοντέλο στα δύο, ένα για τον υπολογισμό μιας ενέργειας που βασίζεται σε μια κατάσταση και ένα άλλο για την παραγωγή των τιμών Q της ενέργειας.

Ο πράκτορας παίρνει ως είσοδο την κατάσταση και βγάζει την καλύτερη δράση. Ελέγχει ουσιαστικά πώς συμπεριφέρεται ο πράκτορας μαθαίνοντας τη βέλτιστη πολιτική (βασισμένη σε πολιτικές). Ο κριτικός, από την άλλη πλευρά, αξιολογεί τη δράση

υπολογίζοντας τη συνάρτηση τιμής (βασισμένη σε τιμή). Αυτά τα δύο μοντέλα συμμετέχουν σε ένα παιχνίδι όπου και τα δύο βελτιώνονται στον δικό τους ρόλο όσο περνάει ο καιρός. Το αποτέλεσμα είναι ότι η συνολική αρχιτεκτονική θα μάθει να παίζει το παιχνίδι πιο αποτελεσματικά από τις δύο μεθόδους ξεχωριστά. Ουσιαστικά είναι μία ιδέα για να αλληλεπιδρούν (ή να ανταγωνίζονται) δύο μοντέλα μεταξύ τους. Όσο περνάει ο καιρός, ο ηθοποιός μαθαίνει να παράγει όλο και καλύτερες ενέργειες (αρχίζει να μαθαίνει την πολιτική) και ο κριτικός γίνεται όλο και καλύτερος στην αξιολόγηση αυτών των ενεργειών. Είναι σημαντικό να παρατηρήσετε ότι η ενημέρωση των βαρών γίνεται σε κάθε βήμα (TD Learning) και όχι στο τέλος του επεισοδίου, σε αντίθεση με τις κλίσεις πολιτικής. Το δίκτυο ενεργειών επιλέγει μια ενέργεια σε κάθε χρονικό βήμα και το κριτικό δίκτυο αξιολογεί την ποιότητα ή την τιμή Q μιας δεδομένης κατάστασης εισόδου. Καθώς το δίκτυο κριτικών μαθαίνει ποιες καταστάσεις είναι καλύτερες ή χειρότερες, ο ηθοποιός χρησιμοποιεί αυτές τις πληροφορίες για να διδάξει στον πράκτορα να αναζητά καλές καταστάσεις και να αποφεύγει τις κακές καταστάσεις.

3.3.2 Ο αλγόριθμος Proximal Policy Optimization (PPO)

Το 2017, οι Schulman et al. εισήγαγε το Proximal Policy Optimization (PPO), βασιζόμενο στα θεμέλια του TRPO. Με όλες τις βασικές πληροφορίες που δίνονται, τι κάνει το PPO καλύτερα και διαφορετικά από τους προηγούμενους αλγόριθμους. Ο αλγόριθμος Proximal Policy Optimization (PPO) είναι ένας δημοφιλής και αποτελεσματικός αλγόριθμος τελευταίας τεχνολογίας που έχει δείξει πολλά υποσχόμενα αποτελέσματα σε διάφορους τομείς. Ο αλγόριθμος PPO έχει σχεδιαστεί για να βελτιώσει τις μεθόδους ενισχυτικής μάθησης με βάση την πολιτική, αντιμετωπίζοντας τις ανησυχίες για τη σταθερότητα και την αποτελεσματικότητα του δείγματος. Λειτουργεί συλλέγοντας επαναληπτικά εμπειρίες,

βελτιστοποιώντας μια υποκατάστατη αντικειμενική συνάρτηση και ενημερώνοντας τις παραμέτρους πολιτικής (Schulman J. e., 2017).

Ο PPO χρησιμοποιεί μια υποκατάστατη αντικειμενική συνάρτηση που προσεγγίζει τη βελτίωση της πολιτικής, διασφαλίζοντας παράλληλα ότι η ενημέρωση της πολιτικής παραμένει εντός μιας καθορισμένης περιοχής εμπιστοσύνης. Ελέγχοντας την έκταση των ενημερώσεων πολιτικής, η PPO επιτυγχάνει μια ισορροπία μεταξύ εξερεύνησης και εκμετάλλευσης, οδηγώντας σε πιο σταθερή και στιβαρή μάθηση (Schulman J. e., 2015)

Ένα από τα βασικά πλεονεκτήματα του PPO είναι η δειγματοληπτική του αποτελεσματικότητα, καθιστώντας τον κατάλληλο για εφαρμογές του πραγματικού κόσμου με περιορισμένη διαθεσιμότητα δεδομένων. Ο PPO το πετυχαίνει αυτό αξιοποιώντας αποτελεσματικά τις συλλεγμένες εμπειρίες και βελτιστοποιώντας την πολιτική μέσω πολλαπλών επαναλήψεων και είναι γνωστός για τις καλές ιδιότητες σύγκλισης και την ικανότητά του να χειρίζεται περιβάλλοντα συνεχούς δράσης.

- Είναι ένας αλγόριθμος βελτιστοποίησης κλίσης πολιτικής, δηλαδή, σε κάθε βήμα υπάρχει μια ενημέρωση μιας υπάρχουσας πολιτικής για την αναζήτηση βελτίωσης σε ορισμένες παραμέτρους
- Εξασφαλίζει ότι η ενημέρωση δεν είναι πολύ μεγάλη, δηλαδή η παλιά πολιτική δεν είναι πολύ διαφορετική από τη νέα πολιτική (το κάνει ουσιαστικά «ψαλιδίζοντας» την περιοχή ενημέρωσης σε ένα πολύ στενό εύρος)
- Η συνάρτηση πλεονέκτημα είναι η διαφορά μεταξύ του μελλοντικού μειωμένου αθροίσματος ανταμοιβών σε μια συγκεκριμένη κατάσταση και δράση και της συνάρτησης αξίας αυτής της πολιτικής.
- Ο λόγος δειγματοληψίας σημασίας ή ο λόγος της πιθανότητας σύμφωνα με τις νέες και παλιές πολιτικές αντίστοιχα, χρησιμοποιείται για ενημέρωση

- Το ϵ είναι μια υπερ παράμετρος που υποδηλώνει το όριο του εύρους εντός του οποίου επιτρέπεται η ενημέρωση

Αυτό που μπορούμε να παρατηρήσουμε είναι ότι μικρές παρτίδες παρατήρησης χρησιμοποιούνται για ενημέρωση, μέχρις ότου ενσωματωθεί μια νέα νέα παρτίδα παρατηρήσεων, γνωστή και ως «minibatch».

Όπου:

θ είναι η πολιτική

E_t υποδηλώνει την εμπειρική προσδοκία σε χρονικά βήματα


r_t είναι η αναλογία της πιθανότητας σύμφωνα με τη νέα και την παλιά πολιτική, αντίστοιχα

A_t είναι το εκτιμώμενο πλεονέκτημα τη χρονική στιγμή t

ϵ είναι μια υπερ παράμετρος, συνήθως 0,1 ή 0,2

Υπολογίζουμε μια προσδοκία για τουλάχιστον δύο όρους: κανονικό στόχο PG και αντικειμενικό στόχο PG. Το βασικό συστατικό προέρχεται από τον δεύτερο όρο όπου ένας κανονικός στόχος PG περικόπτεται με μια λειτουργία αποκοπής μεταξύ $1-\epsilon$ και $1+\epsilon$, με το ϵ να είναι η υπερ παράμετρος.

Λόγω της λειτουργίας $\min$, αυτός ο στόχος συμπεριφέρεται διαφορετικά όταν η εκτίμηση του πλεονεκτήματος είναι θετική ή αρνητική.



Εικόνα 5 Διαγραμματική αναπαράστασή της συνάρτησης L_{clip}

Το παραπάνω διαγράμματα δείχνουν έναν όρο μίας χρονικής περιόδου της συνάρτησης ως συνάρτηση του λόγου πιθανότητας r για θετικά πλεονεκτήματα (αριστερά) και αρνητικά πλεονεκτήματα (δεξιά). Ο κόκκινος κύκλος δείχνει το σημείο εκκίνησης για τη βελτιστοποίηση.

Το σχήμα που απεικονίζει το θετικό πλεονέκτημα: η περίπτωση που η επιλεγμένη ενέργεια είχε καλύτερη επίδραση από το αναμενόμενο στο αποτέλεσμα. Στο γράφημα, η συνάρτηση απώλειας ισοπεδώνεται όταν το r γίνεται πολύ υψηλό ή όταν η ενέργεια είναι πολύ πιο πιθανή σύμφωνα με την τρέχουσα πολιτική από ό,τι στην παλιά πολιτική. Δεν θέλουμε να παρακάνουμε την ενημέρωση ενεργειών κάνοντας ένα βήμα πολύ μακριά, γι' αυτό βάζουμε τον στόχο για να το αποτρέψουμε καθώς και να μπλοκάρουμε την κλίση με μια επίπεδη γραμμή. Το ίδιο ισχύει για τον σωστό αριθμό όταν η εκτίμηση του πλεονεκτήματος είναι αρνητική. Η συνάρτηση απώλειας θα ισοπεδωθεί όταν το r πλησιάζει το μηδέν, που σημαίνει ότι η συγκεκριμένη ενέργεια είναι πολύ λιγότερο πιθανή στην τρέχουσα πολιτική. Αυτός ο στόχος υλοποιεί έναν τρόπο για να ενημερώσεις που είναι συμβατή με το Stochastic Gradient Descent και υλοποιεί τον αλγόριθμο αφαιρώντας την ποινή KL. Σε δοκιμές, αυτός ο αλγόριθμος έχει εμφανίσει την καλύτερη απόδοση σε εργασίες συνεχούς ελέγχου και σχεδόν ταιριάζει με την απόδοση του ACER στο Atari, παρόλο που είναι πολύ πιο απλός στην εφαρμογή του.

Η ΡΡΟ λύνει το θέμα με ρεαλιστικό τρόπο. Θέτει μια «απόκλιση στόχου» δ , όπου οι ενημερώσεις βρίσκονται κάπου κοντά σε αυτήν την απόκλιση. Η απόκλιση στόχου πρέπει να είναι αρκετά μεγάλη ώστε να τροποποιεί ουσιαστικά την πολιτική, αλλά αρκετά μικρή ώστε οι ενημερώσεις να είναι σταθερές.

Μετά από κάθε ενημέρωση, ο ΡΡΟ ελέγχει το μέγεθος της ενημέρωσης. Εάν η πραγματοποιηθείσα απόκλιση υπερβαίνει την απόκλιση στόχο περισσότερο από 1,5, για την επόμενη επανάληψη τιμωρούμε την απόκλιση σκληρότερα διπλασιάζοντας το β . Το αντίστροφο, μειώνουμε το β στο μισό εάν οι ενημερώσεις είναι πολύ μικρές, επεκτείνοντας ουσιαστικά την περιοχή εμπιστοσύνης.

Ο διπλασιασμός και η μείωση του β με βάση την υπέρβαση 1,5 φορές κάποιου ορίου στόχου δεν είναι αποτέλεσμα περίτεχνη απόδειξης. Θα παραβιάζουμε τον περιορισμό από εποχή σε εποχή, αλλά τον διορθώνουμε αρκετά γρήγορα προσαρμόζοντας το β . Εμπειρικά, το ΡΡΟ φαίνεται να είναι αρκετά αναίσθητο στις αριθμητικές ρυθμίσεις. Συνοψίζοντας, θυσιάζουμε

Αντί να ασχολούμαστε με την αλλαγή των ποινών με την πάροδο του χρόνου, απλώς περιορίζουμε το εύρος εντός του οποίου μπορεί να αλλάξει η πολιτική. Καθώς τα πλεονεκτήματα που επιτυγχάνονται από ενημερώσεις εκτός του εύρους αποκοπής δεν χρησιμοποιούνται για σκοπούς ενημέρωσης, παρέχουμε ένα κίνητρο για να παραμείνουμε σχετικά κοντά στην υπάρχουσα πολιτική. Η αντικειμενική συνάρτηση εξακολουθεί να εξαρτάται από το υποκατάστατο πλεονέκτημα, αλλά τώρα μοιάζει με την παρακάτω:

όπου ρ :

Οι όροι $(1-\epsilon) \cdot A$ και $(1+\epsilon) \cdot A$ δεν εξαρτώνται από το θ , αποδίδοντας έτσι μια διαβάθμιση 0. Κατά συνέπεια, δείγματα εκτός της αξιόπιστης περιοχής απορρίπτονται αποτελεσματικά, αποθαρρύνοντας τις υπερβολικά μεγάλες ενημερώσεις. Ως αποτέλεσμα, δεν περιορίζουμε ρητά την ίδια την ενημέρωση πολιτικής, αλλά απλώς αγνοούμε τα πλεονεκτήματα που προκύπτουν από υπερβολικά αποκλίνουσες πολιτικές. Όπως και πριν, μπορούμε απλά να χρησιμοποιήσουμε έναν βελτιστοποιητή όπως το ADAM για να εκτελέσουμε τις ενημερώσεις.

Ratio	Advantage	Update signal	Clipped objective	Gradient $\neq 0$
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} \in [1 - \epsilon, 1 + \epsilon]$	$A_t > 0$	$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} A_t$	No	Yes
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} \in [1 - \epsilon, 1 + \epsilon]$	$A_t < 0$	$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} A_t$	No	Yes
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} < 1 - \epsilon$	$A_t > 0$	$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} A_t$	No	Yes
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} < 1 - \epsilon$	$A_t < 0$	$(1 - \epsilon) A_t$	Yes	No
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} > 1 + \epsilon$	$A_t > 0$	$(1 + \epsilon) A_t$	Yes	No
$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} > 1 + \epsilon$	$A_t < 0$	$\frac{\pi_{\theta_k}(s_t, a_t)}{\pi_{\theta}(s_t, a_t)} A_t$	No	Yes

Εικόνα 6 Πίνακας διακύμανσης βάση πολιτικής PPO

Από την εισαγωγή του το 2017, ο PPO καθιερώθηκε γρήγορα ως ο αλγόριθμος που χρησιμοποιείται για προβλήματα συνεχούς ελέγχου. Ο PPO έχει βρει εφαρμογές σε διάφορους τομείς. Στη ρομποτική, ο PPO έχει χρησιμοποιηθεί για την εκπαίδευση ρομποτικών πρακτόρων για εργασίες όπως η σύλληψη, η μετακίνηση και η πλοήγηση. Στο παιχνίδι, η PPO έχει επιτύχει αξιοσημείωτες επιδόσεις στην εκμάθηση σύνθετων παιχνιδιών όπως το Dota 2 και επιτραπέζιων παιχνιδιών όπως το Go (Silver D. e., 2017). Η PPO έχει επίσης εφαρμοστεί στην αυτόνομη οδήγηση, στα συστήματα διαλόγου και στα χρηματοοικονομικά, αναδεικνύοντας την ευελιξία της σε διάφορους τομείς (Pathak, 2017).

3.3.3 Ο αλγόριθμος TD3

Ο αλγόριθμος TD3 (Twin Delayed Deep Deterministic Policy Gradient) είναι ένας υπερσύγχρονος αλγόριθμος που ανήκει στην οικογένεια των μεθόδων actor-critic. Η

παρουσίαση του αρχικά προτάθηκε σε μια εργασία με τίτλο "Addressing Function Approximation Error in Actor-Critic Methods" από τους Scott Fujimoto, Herke van Hoof και David Meger το 2018.

Ο TD3 είναι ο διάδοχος του Deep Deterministic Policy Gradient (DDPG) (Lillicrap et al, 2016). Μέχρι πρόσφατα, ο DDPG ήταν ένας από τους πιο χρησιμοποιούμενους αλγόριθμους για προβλήματα συνεχούς ελέγχου όπως η ρομποτική και η αυτόνομη οδήγηση. Αν και το DDPG είναι ικανό να παρέχει εξαιρετικά αποτελέσματα, έχει τα μειονεκτήματά του. Όπως πολλοί αλγόριθμοι RL εκπαίδευσης, το DDPG μπορεί να είναι ασταθές και να εξαρτάται σε μεγάλο βαθμό από την εύρεση των σωστών υπερ παραμέτρων. Αυτό προκαλείται από τον αλγόριθμο που υπολογίζει συνεχώς τις τιμές Q του δικτύου κριτικής (τιμής).

Αυτά τα σφάλματα εκτίμησης συσσωρεύονται με την πάροδο του χρόνου και μπορεί να οδηγήσουν τον πράκτορα να πέσει σε ένα τοπικό βέλτιστο ή να βιώσει καταστροφική λήθη. Το TD3 αντιμετωπίζει αυτό το ζήτημα εστιάζοντας στη μείωση της μεροληψίας υπερεκτίμησης που παρατηρήθηκε σε προηγούμενους αλγόριθμους. Αυτό γίνεται με την προσθήκη 3 βασικών χαρακτηριστικών:

- Χρησιμοποιώντας ένα ζευγάρι δικτύων κριτικής (pair of critic networks)
- Καθυστέρηση στις ενημερώσεις πολιτικής και στόχων (Delayed Policy and Target Updates)
- Εξομάλυνση πολιτικής (Target Policy Smoothing)

Pair of critic networks

Το πρώτο χαρακτηριστικό που προστέθηκε στο TD3 είναι η χρήση δύο κριτών. Αυτό εμπνεύστηκε από την τεχνική που παρατηρήθηκε στο Deep Reinforcement Learning with Double Q-learning (Van Hasselt et al., 2016) που περιλαμβάνει την εκτίμηση της τρέχουσας

τιμής Q χρησιμοποιώντας μια ξεχωριστή συνάρτηση τιμής στόχου, μειώνοντας έτσι την προκατάληψη. Ωστόσο, η τεχνική δεν λειτουργεί τέλεια για μεθόδους actor critic. Αυτό συμβαίνει επειδή η πολιτική και τα δίκτυα στόχων ενημερώνονται τόσο αργά που μοιάζουν πολύ, γεγονός που επαναφέρει την προκατάληψη στην εικόνα. Αντίθετα, χρησιμοποιείτε μια παλαιότερη υλοποίηση που εμφανίζεται στο Double Q Learning (Van Hasselt, 2010). Το TD3 χρησιμοποιεί κομμένη διπλή εκμάθηση Q όπου παίρνει τη μικρότερη τιμή από τα δύο δίκτυα κριτικής.




Εικόνα 7 Actor Critic Model of TD3

Όπως υποδεικνύεται στο σχήμα παραπάνω, ο TD3 χρησιμοποίησε συνολικά έξι νευρωνικά δίκτυα, συγκεκριμένα, δύο κριτές Q1Q1 και Q2Q2 με παραμέτρους $\theta_{1\theta 1}$ και $\theta_{2\theta 2}$, δύο κριτές στόχου Q1'Q1' και Q2'Q2' με παραμέτρους $\theta_{1'\theta 1'}$ και $\theta_{2'\theta 2'}$ και ένας ηθοποιός π'π' (που αναπαρίσταται επίσης ως μ'μ' μερικές φορές, όπως στο χαρτί DDPG) και αντίστοιχος στόχος π'π' με παραμέτρους $\phi'\phi'$ και $\phi'\phi'$ αντίστοιχα.

Σε σύγκριση, ο TD3 βασίζεται στις έννοιες που εισάγονται στο Double Q-learning. Για το περιβάλλον, το Double Q-learning χρησιμοποιεί δύο ξεχωριστές εκτιμήσεις τιμών, έτσι ώστε κάθε τιμή Q να ενημερώνεται χρησιμοποιώντας την εκτίμηση της άλλης όπως φαίνεται παρακάτω:

$$y_1 = r + \gamma \cdot Q_2(s', Q_1(s', a)) \quad y_1 = r + \gamma \cdot Q_2(s', Q_1(s', a))$$

$$y_2 = r + \gamma \cdot Q_1(s', Q_2(s', a)) \quad y_2 = r + \gamma \cdot Q_1(s', Q_2(s', a))$$



Εικόνα 8 Explain double Q-Learning of TD3

Αυτή η μέθοδος ευνοεί την υποεκτίμηση των τιμών Q. Αυτή η προκατάληψη υποεκτίμησης δεν αποτελεί πρόβλημα, καθώς οι χαμηλές τιμές δεν θα διαδοθούν μέσω του αλγόριθμου, σε αντίθεση με τις τιμές υπερεκτίμησης. Αυτό παρέχει μια πιο σταθερή προσέγγιση, βελτιώνοντας έτσι τη σταθερότητα ολόκληρου του αλγορίθμου.

Αυτή η διατύπωση του Double Q-Learning βασίζεται στην προϋπόθεση ότι τα Q1Q1 και Q2Q2 είναι εντελώς ανεξάρτητα και ενημερώνονται σε ξεχωριστά σύνολα, οδηγώντας έτσι σε μια αμερόληπτη εκτίμηση.

Ωστόσο, στη ρύθμιση του DDPG, χρησιμοποιείται μια προσωρινή μνήμη επανάληψης για τη δειγματοληψία των εμπειριών για να μάθουμε, επομένως, η συνθήκη δεν είναι εγγυημένη. Για να αντιμετωπιστεί αυτό, οι συγγραφείς προτείνουν μια "κομμένη" έκδοση του Double Q-learning όπως συνοψίζεται στην παραπάνω εικόνα, λαμβάνοντας τις ελάχιστες από τις δύο τιμές Q για τον υπολογισμό του στόχου. Επιπρόσθετα, για τη μείωση του υπολογιστικού κόστους, προτείνεται η χρήση δύο κριτικών Q1Q1 και Q2Q2 με τα αντίστοιχα δίκτυα-στόχους Q1'Q1' και Q2'Q2', αλλά, με μόνο έναν παράγοντα π'π' βελτιστοποιημένο έναντι του Q1Q1. Αυτό οδηγεί στη δημιουργία ενός ενιαίου TD-Target (γ) που στη συνέχεια χρησιμοποιείται για την ενημέρωση τόσο του Q1Q1 όσο και του Q2Q2. Έτσι, η τελική διατύπωση του βήματος εκμάθησης για το TD3 μπορεί να εκφραστεί ως:

$$y=r+\gamma\cdot\min\{Q1'(s',\pi'(s')),Q2'(s',\pi'(s'))\}y=r+\gamma\cdot\min\{Q1'(s',\pi'(s')),Q2'(s',\pi'(s'))\}$$


$$L_{critic1}=MSE(y-Q1(s,a))L_{critic1}=MSE(y-Q1(s,a))$$

$$L_{critic2}=MSE(y-Q2(s,a))L_{critic2}=MSE(y-Q2(s,a))$$

➤ Delayed Policy and Target Updates

Οι προσεγγίσεις συναρτήσεων, όπως τα νευρωνικά δίκτυα, εισάγουν θόρυβο στις εκτιμήσεις τιμών, οδηγώντας σε αποκλίνουσες συμπεριφορές κατά την εκπαίδευση. Τα δίκτυα στόχων εισήχθησαν για την αντιμετώπιση αυτού του ζητήματος. Τα δίκτυα στόχων ενημερώνονται σε τακτά χρονικά διαστήματα, παρέχοντας έναν σταθερό στόχο για ενημερώσεις σε κάθε βήμα.

Ενώ τα δίκτυα στόχων χρησιμοποιούνται επίσης στο DDPG, οι δημιουργοί του TD3 σημειώνουν ότι η αλληλεπίδραση μεταξύ του πράκτορα και του κριτικού σε τέτοιες ρυθμίσεις μπορεί επίσης να αποτελέσει λόγο αποτυχίας. Οι εκτιμήσεις των τιμών αποκλίνουν λόγω υπερεκτίμησης όταν η πολιτική είναι κακή και η πολιτική θα γίνει μη βέλτιστη αν η ίδια η εκτίμηση των τιμών είναι ανακριβής.



Εικόνα 9 Explain Delayed Policy TD3


Για να μετριαστεί αυτό, συνιστάται να διατηρείται ο δράστης σταθερός για έναν ορισμένο αριθμό βημάτων, ενώ και οι δύο κριτικοί ενημερώνονται σε κάθε βήμα, όπως φαίνεται στην παραπάνω εικόνα. Αυτό επιτρέπει στις τιμές Q που υπολογίζονται από τα δίκτυα

κριτικών να συγκλίνουν, μειώνοντας τα σφάλματα τιμών, γεγονός που με τη σειρά του επιτρέπει πιο σταθερές ενημερώσεις πολιτικής από ό,τι μόνο ο παράγοντας.

Για να αντιμετωπιστεί αυτό, είναι απλώς απαραίτητο να ενημερώνεται το δίκτυο πολιτικής λιγότερο συχνά από το δίκτυο τιμών. Αυτό επιτρέπει στο δίκτυο τιμών να γίνει πιο σταθερό και να μειώσει τα σφάλματα πριν χρησιμοποιηθεί για την ενημέρωση του δικτύου πολιτικής. Στην πράξη, το δίκτυο πολιτικής ενημερώνεται μετά από μια καθορισμένη χρονική περίοδο, ενώ το δίκτυο τιμών συνεχίζει να ενημερώνεται μετά από κάθε χρονικό βήμα. Αυτές οι λιγότερο συχνές ενημερώσεις πολιτικής έχουν ως αποτέλεσμα εκτιμήσεις αξιών με μικρότερη διακύμανση και επομένως αναμένεται να οδηγήσουν σε καλύτερες πολιτικές. Το TD3 χρησιμοποιεί καθυστερημένες ενημερώσεις του δικτύου δρώντων, ενημερώνοντάς το μόνο κάθε 2 χρονικά βήματα αντί για κάθε χρονικό βήμα, με αποτέλεσμα πιο σταθερή και αποτελεσματική εκπαίδευση.

➤ **Target Policy Smoothing**

Σε ένα περιβάλλον συνεχούς δράσης, σε αντίθεση με το αντίστοιχο διακριτό, οι δράσεις έχουν έμμεσες σημασίες και σχέσεις. Για παράδειγμα, θεωρήστε έναν πράκτορα RL που ελέγχει ένα όχημα καθορίζοντας τη γωνία διεύθυνσης. Οι ενέργειες για τον έλεγχο του συστήματος διεύθυνσης μπορεί να κυμαίνονται από -1 έως 1, όπου οι ενέργειες -0,01, 0,0 και +0,01 είναι όλες πολύ κοντά και θα πρέπει να έχουν παρόμοιες τιμές κατάστασης-ενέργειας για μια δεδομένη κατάσταση. Αν δεν αντιμετωπιστεί, αυτό μπορεί να οδηγήσει σε εύθραυστες πολιτικές που ευνοούν υπερβολικά ορισμένες ενέργειες, ειδικά σε ντετερμινιστικές πολιτικές.



Εικόνα 10 Target Policy Smoothing TD3

Για να αντιμετωπιστεί αυτό, προτείνεται η προσθήκη ενός μικρού θορύβου γύρω από την ενέργεια, έτσι ώστε όλες οι ενέργειες εντός αυτού του μικρού εύρους να έχουν παρόμοιες τιμές κατάστασης-δράσης, μειώνοντας έτσι τη διακύμανση στις εκτιμήσεις των τιμών. Η εργασία το επιτυγχάνει αυτό εφαρμόζοντας θόρυβο μηδενικού μέσου με μικρή τυπική απόκλιση στην ενέργεια που παράγεται από την πολιτική στόχου, η οποία στη συνέχεια χρησιμεύει ως είσοδος στους κριτικούς στόχους για τον υπολογισμό της τιμής TD-στόχου. Το TD3 μειώνει αυτή τη διακύμανση προσθέτοντας μια μικρή ποσότητα τυχαίου θορύβου στον στόχο και υπολογίζοντας τον μέσο όρο σε μίνι-πακέτα. Το εύρος του θορύβου ψαλιδίζεται για να διατηρηθεί η τιμή του στόχου κοντά στην αρχική τιμή της δράσης. Προσθέτοντας αυτόν τον πρόσθετο θόρυβο στην εκτίμηση της αξίας, οι πολιτικές τείνουν να είναι πιο σταθερές, καθώς η τιμή στόχος επιστρέφει υψηλότερη τιμή για ενέργειες που είναι πιο ανθεκτικές σε θόρυβο και παρεμβολές. Έτσι, ο υπολογισμός του TD-Target γγ μπορεί να ενημερωθεί ως :

$$\gamma = r + \gamma \cdot \min\{Q1'(s', \pi'(s') + \epsilon), Q2'(s', \pi'(s') - \epsilon)\} \gamma = r + \gamma \cdot \min\{Q1'(s', \pi'(s') + \epsilon), Q2'(s', \pi'(s') - \epsilon)\}$$

$$\epsilon \sim \text{clip}(N(0, \sigma^*), -c, c) \epsilon \sim \text{clip}(N(0, \sigma), -c, c)$$

Έτσι, μέχρι τώρα είδαμε ότι ο θόρυβος στις ενημερώσεις τιμών μπορεί να είναι επιζήμιος για την απόδοση των ενημερώσεων RL, για τις οποίες το TD3 εισάγει δύο κριτές και έναν παράγοντα, και στοχεύει δίκτυα που σχετίζονται με καθένα από αυτά, οδηγώντας έτσι σε

συνολικά έξι δίκτυα. Εξετάσαμε πώς ενημερώθηκαν οι κριτές, πώς ρυθμίστηκαν οι τιμές Q και πόσο συχνά ενημερώνεται τα δίκτυα ηθοποιών και στόχων.

➤ Updates of the actor



Εικόνα 11 Update value of the actor TD3

Όπως και με το DDPG, ο στόχος του ηθοποιού είναι να μεγιστοποιήσει την αναμενόμενη απόδοση στην τρέχουσα κατάσταση. Έτσι, ο ηθοποιός ενημερώνεται όπως απεικονίζεται στο σχήμα παραπάνω λαμβάνοντας το αρνητικό (επειδή πρέπει να μεγιστοποιήσουμε) του μέσου όρου της τιμής που επιστρέφει ο κριτής στις ενέργειες που επιλέγονται ντετερμινιστικά (χωρίς θόρυβο) από τον ηθοποιό. Έτσι, η απώλεια ηθοποιού μπορεί να διατυπωθεί ως εξής:

$$L_{actor} = -Q_1(s, \pi(s))$$

Το TD3 στοχεύει να μάθει μια ντετερμινιστική πολιτική, ωστόσο, η πρόκληση σε ένα τέτοιο περιβάλλον είναι ότι ο πράκτορας δεν εξερευνά επαρκώς το περιβάλλον. Το DDPG και το TD3 έχουν σχεδιαστεί για εκμάθηση εκτός πολιτικής, δηλαδή, η πολιτική που χρησιμοποιείται για τη δημιουργία της συμπεριφοράς δεν χρειάζεται να είναι η ίδια με την πολιτική που μαθαίνει ο φορέας.

Ο TD3 έχει δείξει σημαντικές βελτιώσεις σε σχέση με προηγούμενους αλγόριθμους σε διάφορες εργασίες συνεχούς ελέγχου, επιτυγχάνοντας επιδόσεις αιχμής σε εργασίες αναφοράς, όπως το OpenAI Gym. Αντιμετωπίζει τα ζητήματα της υπερεκτίμησης και της αστάθειας που συναντώνται συνήθως σε μεθόδους κριτικής ηθοποιών, καθιστώντας το μια δημοφιλή επιλογή για εργασίες ενίσχυσης μάθησης.

3.3.4 Ο αλγόριθμος DDPG

Ο DDPG είναι ένας αλγόριθμος που δεν έχει μοντέλα, εκτός πολιτικής, ο οποίος συνδυάζει το Deep Q Learning (DQN) και το DPG. Το πρωτότυπο DQN λειτουργεί σε έναν διακριτό χώρο δράσης και το DPG το επεκτείνει στον χώρο συνεχούς δράσης ενώ μαθαίνει μια ντετερμινιστική πολιτική. Καθώς είναι ένας αλγόριθμος εκτός πολιτικής, χρησιμοποιεί δύο ξεχωριστές πολιτικές για την εξερεύνηση και τις ενημερώσεις. Χρησιμοποιεί μια πολιτική στοχαστικής συμπεριφοράς για την εξερεύνηση και ντετερμινιστική πολιτική για την ενημέρωση στόχου. Ο DDPG είναι ένας αλγόριθμος κριτικού ηθοποιού. έχει δύο δίκτυα: ηθοποιό και κριτικό. Τεχνικά, ο ηθοποιός παράγει τη δράση για εξερεύνηση. Κατά τη διαδικασία ενημέρωσης του ηθοποιού, χρησιμοποιείται σφάλμα TD από έναν κριτικό. Το κρίσιμο δίκτυο ενημερώνεται με βάση το σφάλμα TD παρόμοιο με τον κανόνα ενημέρωσης Q-learning. Μάθαμε το γεγονός ότι το ζήτημα της αστάθειας που μπορεί να προκύψει στην Q-learning με το βαθύ νευρωνικό δίκτυο ως λειτουργική προσέγγιση. Για να λυθεί αυτό, χρησιμοποιούνται δίκτυα επανάληψης εμπειρίας και στόχου.

Ο DDPG (Deep Deterministic Policy Gradient) είναι ένας δημοφιλής αλγόριθμος ενισχυτικής μάθησης που συνδυάζει το πλαίσιο actor-critic με βαθιά νευρωνικά δίκτυα. Ο DDPG δημιουργήθηκε από τον DQN όπου λειτουργεί μόνο σε διακριτό χώρο δράσης και έτσι επιχειρεί να καλύψει αυτό το κενό εισάγοντας μερικά "tweaks" που επιτρέπουν στο DQN να επεκταθεί σε χώρο συνεχούς δράσης. Είναι ειδικά σχεδιασμένος για την επίλυση


εργασιών συνεχούς ελέγχου, όπου ο χώρος δράσης είναι συνεχής. Το δίκτυο ηθοποιών είναι ένα βαθύ νευρωνικό δίκτυο που παίρνει την κατάσταση ως είσοδο και εξάγει μια συνεχή ενέργεια. Μαθαίνει μια ντετερμινιστική πολιτική, χαρτογραφώντας τις καταστάσεις σε ενέργειες. Το δίκτυο κριτή είναι ένα άλλο βαθύ νευρωνικό δίκτυο που λαμβάνει και την κατάσταση και τη δράση ως είσοδο και εκτιμά την αναμενόμενη αθροιστική ανταμοιβή. Ο DDPG έχει εφαρμοστεί με επιτυχία σε διάφορες εργασίες συνεχούς ελέγχου, όπως ο ρομποτικός χειρισμός και η μετακίνηση, και έχει επιδείξει καλή απόδοση και σταθερότητα δείγματος σε σύγκριση με άλλους αλγόριθμους. Έχει ανοίξει το δρόμο για επακόλουθες προόδους, συμπεριλαμβανομένου του TD3, το οποίο βελτιώνει περαιτέρω την απόδοση και τη σταθερότητα των μεθόδων που ασκούν κριτική σε ρυθμίσεις συνεχούς ελέγχου.

Το DDPG βασίζεται στο ντετερμινιστικό σκηνικό ηθοποιού-κριτή εκτός πολιτικής και χρειάζεται συνολικά 4 δίκτυα για να τρέξουμε αυτόν τον αλγόριθμο. Ένας ηθοποιός μμ, ένας κριτής QQ και οι αντίστοιχοι στόχοι τους, μ' και $Q'Q'$.

Όντας εκτός πολιτικής, το DDPG επωφελείται επίσης από τη χρήση ενός 'Replay Buffer', παρόμοιου με το DQN. Η προσωρινή μνήμη επανάληψης είναι μια προσωρινή μνήμη πεπερασμένου μεγέθους που αποθηκεύει προηγούμενες εμπειρίες από τις οποίες λαμβάνονται δείγματα παρτίδων ομοιόμορφα τυχαία για εκπαίδευση και ο κριτής έχει την αποστολή να υπολογίσει την Q-τιμή $Q(s,a)$ του δεδομένου ζεύγους κατάστασης-δράσης.

Εφόσον το DDPG αναθέτει την ευθύνη της πρόβλεψης της ενέργειας και του προσδιορισμού της «καλής» αυτής της ενέργειας σε δύο διαφορετικά δίκτυα, ο κριτής πρέπει να υπολογίσει μόνο την τιμή Q με βάση την ενέργεια που έχει επιλεγεί από το άλλο δίκτυο. Έτσι, η είσοδος στον κριτή, εδώ, είναι η κατάσταση και η προβλεπόμενη ενέργεια,

ενώ το επίπεδο εξόδου του δικτύου έχει έναν μόνο νευρώνα που παράγει την τιμή Q του δεδομένου ζεύγους κατάστασης-δράσης.



Εικόνα 12 DQN vs DDPG

Το δίκτυο κριτή υπολογίζεται βάση του Mean-Squared Bellman Error, παρόμοιο με το DQN. Έτσι, η απώλεια υπολογίζεται ως το μέσο τετράγωνο σφάλμα μεταξύ του TD-Target και της εκτίμησης Q-value της τρέχουσας κατάστασης και της αντίστοιχης ενέργειας. Το TD-Target y' χρησιμοποιεί τα δίκτυα προορισμού. Η επόμενη κατάσταση s' και η σχετική ενέργεια που προβλέπεται από τον παράγοντα στόχο μ' παρέχονται ως είσοδος στον κριτικό στόχο Q' . Αυτό μπορεί να διατυπωθεί ως εξής:

$$y = r + \gamma \cdot Q'(s', \mu'(s'))$$



DDPG model


➤ DDPG Actor

Βασισμένος στο DPG, ο πράκτορας DDPG μαθαίνει μια ντετερμινιστική πολιτική. Αυτό σημαίνει ότι το δίκτυο μαθαίνει να χαρτογραφεί μια δεδομένη κατάσταση σε μια συγκεκριμένη ενέργεια, αντί για μια κατανομή πιθανότητας στις ενέργειες, όπως γίνεται σε

αλγόριθμους που μαθαίνουν μια στοχαστική πολιτική. Έτσι, το Actor-Network παίρνει ως είσοδο το διάνυσμα κατάστασης και εξάγει την ενέργεια που πρέπει να εκτελεστεί, με το μέγεθος να εξαρτάται από το μέγεθος του χώρου ενεργειών.

Το δίκτυο ηθοποιών βελτιώνεται με βάση την «κριτική» του δικτύου κριτών. Έτσι, με βάση το θεώρημα της ντετερμινιστικής κλίσης πολιτικής, το δίκτυο δρα μαθαίνοντας να εκτελεί μια βαθμιδωτή ανάβαση, σε σχέση με την πολιτική, κατά μήκος της κατεύθυνσης που υποδεικνύει ο κριτικός. Αυτό μπορεί να διατυπωθεί ως εξής:

$$L_{actor} = -Q(s, \mu(s))$$



Εικόνα 13 Actor critic DDPG

➤ Updating the DDPG Targets

Δεδομένου ότι οι ενημερώσεις κριτών στο DDPG εξαρτώνται από το σφάλμα Bellman, τα δίκτυα προορισμού καθίστανται απαραίτητα. Ωστόσο, οι δύο αλγόριθμοι διαφέρουν ως προς τον τρόπο με τον οποίο ενημερώνονται οι στόχοι. Το DQN λειτουργεί εφαρμόζοντας σκληρές ενημερώσεις, δηλαδή περιοδικά τα βάρη του κύριου δικτύου αντιγράφονται απευθείας στο δίκτυο προορισμού. Αντίθετα, το DDPG εκτελεί «soft updates» σε κάθε βήμα εκπαίδευσης. Όπως υποδεικνύεται παρακάτω, ο μέσος όρος Polyak χρησιμοποιείται για αυτό:

$$\theta' \leftarrow \tau \cdot \theta + (1 - \tau) \cdot \theta'$$


$$\phi' \leftarrow \tau \cdot \phi + (1 - \tau) \cdot \phi'$$

Εδώ, τα θ και θ' αντιπροσωπεύουν τις παραμέτρους των δικτύων κριτικού και στόχου αντιστοίχως, ενώ τα ϕ και ϕ' αντιπροσωπεύουν τις παραμέτρους του δράστη και του στόχου του. Η υπερπαραμέτρος $\tau \in [0,1]$ έχει οριστεί σε μια εξαιρετικά μικρή τιμή για να διασφαλιστεί ότι οι στόχοι ενημερώνονται πολύ αργά.

➤ **Exploration in DDPG**

Η ντετερμινιστική φύση της μαθημένης πολιτικής απαιτεί από το DDPG να εφαρμόσει μια στρατηγική για να διασφαλίσει ότι το δίκτυο δεν θα κολλήσει σε ένα τοπικό ελάχιστο κατά τη διάρκεια της εκπαίδευσης. Εφόσον το DDPG μαθαίνει εκτός πολιτικής, μπορούμε να ενθαρρύνουμε την εξερεύνηση χρησιμοποιώντας μια πολιτική στοχαστικής συμπεριφοράς. Αυτό υλοποιείται προσθέτοντας μια μικρή ποσότητα θορύβου στις ενέργειες που προβλέπονται από το δίκτυο ηθοποιών κατά τη διάρκεια της εκπαίδευσης και μπορεί να διατυπωθεί ως εξής:

$$a = \mu(s) + \epsilon$$



Αυτή η προσέγγιση συνδέεται στενά με την Q-learning και έχει το ίδιο κίνητρο: εάν γνωρίζετε τη βέλτιστη συνάρτηση τιμής δράσης $Q^*(s,a)$, τότε σε οποιαδήποτε δεδομένη κατάσταση, η βέλτιστη ενέργεια $a^*(s)$ μπορεί να βρεθεί με επίλυση:

Το DDPG παρεμβαίνει στην εκμάθηση ενός προσεγγιστή με το $Q^*(s,a)$ με την εκμάθηση ενός προσεγγιστή με το $a^*(s)$, και το κάνει με τρόπο που είναι ειδικά προσαρμοσμένος για περιβάλλοντα με χώρους συνεχούς δράσης. Τι σημαίνει όμως ότι το DDPG είναι προσαρμοσμένο ειδικά για περιβάλλοντα με χώρους συνεχούς δράσης; Σχετίζεται με τον τρόπο με τον οποίο υπολογίζουμε τις μέγιστες ενέργειες στο $\max_a Q^*(s,a)$.

Όταν υπάρχει ένας πεπερασμένος αριθμός διακριτών ενεργειών, το μέγιστο δεν δημιουργεί πρόβλημα, επειδή μπορούμε απλώς να υπολογίσουμε τις τιμές Q για κάθε ενέργεια ξεχωριστά και να τις συγκρίνουμε απευθείας. (Αυτό μας δίνει επίσης αμέσως την ενέργεια που μεγιστοποιεί την τιμή Q .) Αλλά όταν ο χώρος δράσης είναι συνεχής, δεν μπορούμε να αξιολογήσουμε εξαντλητικά τον χώρο και η επίλυση του προβλήματος βελτιστοποίησης είναι εξαιρετικά μη τετριμμένη. Η χρήση ενός κανονικού αλγόριθμου βελτιστοποίησης θα έκανε τον υπολογισμό του $\max_a Q^*(s,a)$ μια επώδυνη ακριβή υπορουτίνα. Και δεδομένου ότι θα έπρεπε να εκτελείται κάθε φορά που ο πράκτορας θέλει να κάνει μια ενέργεια στο περιβάλλον, αυτό είναι απαράδεκτο.

Επειδή ο χώρος δράσης είναι συνεχής, η συνάρτηση $Q^*(s,a)$ θεωρείται ότι είναι διαφορίσιμη σε σχέση με το όρισμα δράσης. Αυτό μας επιτρέπει να δημιουργήσουμε έναν αποτελεσματικό κανόνα μάθησης που βασίζεται σε κλίση για μια πολιτική $\mu(s)$ που εκμεταλλεύεται αυτό το γεγονός. Στη συνέχεια, αντί να εκτελούμε μια ακριβή υπορουτίνα βελτιστοποίησης κάθε φορά που θέλουμε να υπολογίσουμε το $\max_a Q^*(s,a)$ μπορούμε να το προσεγγίσουμε με $\max_a Q^*(s,a) \approx Q(s, \mu(s))$.

3.4 Πλεονεκτήματα της Ενισχυτικής Μάθησης

Τα πλεονεκτήματα της ενισχυτικής μάθησης (RL) την καθιστούν μια επιτυχημένη στρατηγική μηχανικής μάθησης. Έχει εφαρμοστεί αποτελεσματικά σε πολυάριθμες εφαρμογές και επιτρέπει στους πράκτορες να μαθαίνουν τους καλύτερους κανόνες απόφασης μέσω της αλληλεπίδρασης με το περιβάλλον τους (Watkins C. J., 1992). Ακολουθούν μερικά από τα κύρια πλεονεκτήματα της ενισχυτικής μάθησης και των αλγορίθμων:

- **Προσαρμοστικότητα και ευελιξία:** Η ρομποτική, τα βιντεοπαιχνίδια και τα συστήματα ελέγχου είναι μερικά μόνο παραδείγματα των προβληματικών πεδίων στα οποία μπορεί να εφαρμοστεί η ενισχυτική μάθηση. Οι αλγόριθμοι RL μπορούν να προσαρμόζονται σε μεταβαλλόμενα περιβάλλοντα και να βρίσκουν την καλύτερη τακτική μέσω δοκιμής και σφάλματος (Mnih V. e., 2015).
- **Διαχείριση πολύπλοκων καταστάσεων:** Οι αλγόριθμοι RL είναι εξαιρετικοί στη διαχείριση πολύπλοκων καταστάσεων με τεράστιες περιοχές καταστάσεων και ενεργειών. Είναι αρκετά καλοί στο χειρισμό τόσο συνεχών όσο και διακριτών χώρων δράσης. εφαρμογές στον πραγματικό κόσμο με πολλές δυνατότητες δράσης (Kaelbling, 1996).
- **Ικανότητα μάθησης από ανταμοιβές:** Οι αλγόριθμοι ενισχυτικής μάθησης έχουν κατασκευαστεί για να μπορούν να μαθαίνουν από κίνητρα όπου ο πράκτορας λαμβάνει μόνο περιστασιακά ανατροφοδότηση. Μπορούν να εξερευνήσουν με επιτυχία τον κόσμο, να βρουν ικανοποιητικές καταστάσεις και να αποκτήσουν καλές στρατηγικές ακόμη και κάτω από δύσκολες συνθήκες. (Sutton, 2018).
- **Συμβιβασμός μεταξύ εξερεύνησης και εκμετάλλευσης:** Οι αλγόριθμοι RL αντιμετωπίζουν το συμβιβασμό μεταξύ εξερεύνησης και εκμετάλλευσης

εξισορροπώντας τη διερεύνηση νέων δραστηριοτήτων με την εκμετάλλευση της γνώσης. Αυτό επιτρέπει στους πράκτορες να βελτιώνουν συνεχώς τους κανόνες τους και να λαμβάνουν σοφές αποφάσεις σε αβέβαιες συνθήκες.

- **Γενίκευση και εκμάθηση μεταφοράς**: Οι αλγόριθμοι ενισχυτικής μάθησης μπορούν να χρησιμοποιούν τεχνικές γενίκευσης για τη μεταφορά γνώσης από μια εργασία σε μια άλλη. Αυτό επιταχύνει τη μάθηση σε νέα περιβάλλοντα και βελτιώνει τη γενίκευση της πολιτικής. (Silver D. e., 2016).

3.5 Μειονεκτήματά της Ενισχυτικής Μάθησης

Η ενισχυτική μάθηση (RL) έχει πολλά πλεονεκτήματα, αλλά έχει επίσης σημαντικά μειονεκτήματα και περιορισμούς. Όταν χρησιμοποιείτε αλγορίθμους RL, είναι κρίσιμο να γνωρίζετε αυτά τα μειονεκτήματα προκειμένου να κάνετε σοφές επιλογές. Ένα από αυτά είναι η υψηλή υπολογιστική πολυπλοκότητα των συστημάτων. Οι τεχνικές RL είναι μερικές φορές υπολογιστικά δαπανηρές όταν εργάζονται με μεγάλους χώρους καταστάσεων και ενεργειών. Σε σύγκριση με άλλες τεχνικές μηχανικής μάθησης, το trade-off εξερεύνησης-εκμετάλλευσης και η ανάγκη για επαναληπτικές ενημερώσεις καθιστούν τους αλγορίθμους RL πιο δύσκολους υπολογιστικά και χρονοβόρους.

Οι αλγόριθμοι μάθησης σε πραγματικό χρόνο (RL) συχνά απαιτούν μεγάλο αριθμό αλληλεπιδράσεων με το περιβάλλον λόγω της δειγματοληπτικής τους αποτελεσματικότητας για k μάθηση βέλτιστων πολιτικών. Αυτή η υψηλή δειγματοληπτική πολυπλοκότητα μπορεί να αποτελέσει πρόκληση σε εφαρμογές του πραγματικού κόσμου, επειδή κάθε αλληλεπίδραση είναι ξεχωριστή θα μπορούσε να είναι χρονοβόρα ή δαπανηρή.

Ενώ οι αλγόριθμοι RL έχουν επιτύχει σε πρακτικές εφαρμογές, συχνά στερούνται στέρεων θεωρητικών εγγυήσεων. Η συμπεριφορά των αλγορίθμων RL μπορεί να είναι εξαιρετικά

ευαίσθητη στην επιλογή υπερπαραμέτρων, στη δόμηση της ανταμοιβής και σε άλλους παράγοντες, καθιστώντας δύσκολη την πρόβλεψη της επιτυχίας τους σε πολλά πλαίσια.

Επίσης, οι δυσκολίες στην εξισορρόπηση της εξερεύνησης και της εκμετάλλευσης μπορεί να είναι δύσκολες. Είναι δύσκολο έργο να εξασφαλιστεί επαρκής εξερεύνηση για την αποκάλυψη βέλτιστων πολιτικών, αποφεύγοντας παράλληλα την υπερβολική εξερεύνηση που μπορεί να οδηγήσει σε αναποτελεσματικότητα ή κινδύνους ασφάλειας.

Τέλος, για την επίτευξη βέλτιστης απόδοσης, οι αλγόριθμοι RL συχνά απαιτούν προσεκτική προσαρμογή των υπερπαραμέτρων. Η απόδοση ενός αλγορίθμου RL μπορεί να διαφέρει σημαντικά ανάλογα με τις υπερπαραμέτρους που χρησιμοποιούνται και ο προσδιορισμός του καλύτερου συνδυασμού μπορεί να είναι χρονοβόρος.

3.6 Βασικές Προκλήσεις και Ερευνητικά ερωτήματα στη Μάθηση Ενίσχυσης

Η ανάπτυξη της ενισχυτικής μάθησης (RL) ως ένα ισχυρό πλαίσιο για τη διδασκαλία ευφυών οντοτήτων πώς να λαμβάνουν διαδοχικές αποφάσεις σε μεταβαλλόμενα περιβάλλοντα. Για την περαιτέρω ενίσχυση των αλγορίθμων RL, πρέπει να επιλυθούν ορισμένα ζητήματα και αναπάντητα ερευνητικά προβλήματα στον τομέα (Sutton, 2018).

Η αποτελεσματικότητα των δειγμάτων είναι ένα σημαντικό ζήτημα, επειδή η εκμάθηση βέλτιστων πολιτικών με τη χρήση αλγορίθμων RL συχνά περιλαμβάνει πολλές αλληλεπιδράσεις με το περιβάλλον. Για να μειωθεί ο χρόνος και οι πόροι που απαιτούνται για την εκπαίδευση των πρακτόρων RL, πρέπει να βελτιωθεί η αποτελεσματικότητα του δείγματος. Για την αντιμετώπιση αυτού του προβλήματος, οι ερευνητές εξετάζουν μεθόδους που περιλαμβάνουν το RL που βασίζεται σε μοντέλα, τη μάθηση μεταφοράς και τη μετα-μάθηση. Η εφαρμογή των πολιτικών που μαθαίνονται σε διάφορες εργασίες και καταστάσεις είναι μια άλλη σημαντική δυσκολία. Η αδυναμία των αλγορίθμων RL να γενικεύσουν πέρα από το στενό φάσμα καταστάσεων στις οποίες εκπαιδεύτηκαν

περιορίζει τη χρησιμότητά τους. Επί του παρόντος διεξάγεται έρευνα για την εξεύρεση στρατηγικών που θα βοηθήσουν τους πράκτορες RL να γενικεύσουν και να μεταφέρουν την τεχνογνωσία τους σε άλλες εργασίες ή πλαίσια. (Dulac-Arnold, 2019)

Μια βασική δυσκολία στην RL είναι ο συμβιβασμός μεταξύ εξερεύνησης και εκμετάλλευσης. Προκειμένου να μεγιστοποιήσουν τις ανταμοιβές, οι πράκτορες πρέπει να βρουν μια ισορροπία μεταξύ της εξερεύνησης του περιβάλλοντός τους για νέες, πιθανώς επικερδείς πράξεις και της αξιοποίησης προηγούμενων επιτυχημένων ενεργειών. Η έρευνα εξακολουθεί να γίνεται για την ανάπτυξη επιτυχημένων τεχνικών εξερεύνησης που εξετάζουν το χώρο κατάστασης-δράσης.

Μια άλλη δυσκολία στην RL είναι η δημιουργία ανταμοιβών. Μπορεί να αποτελέσει πρόκληση η δημιουργία κατάλληλων συναρτήσεων κινήτρων που κατευθύνουν τους πράκτορες RL προς επιθυμητές συμπεριφορές. Ένας τομέας έρευνας που χρειάζεται εστίαση είναι η εύρεση ανταμοιβών που αντικατοπτρίζουν αποτελεσματικά τους επιδιωκόμενους στόχους και προσφέρουν σημαντικά σήματα μάθησης. Επιπλέον, η αντιμετώπιση του προβλήματος των αραιών κινήτρων, κατά το οποίο σημαντικά βραβεία κερδίζονται σπάνια, είναι μια επίμονη δυσκολία στην RL (Christodoulou, 2019).

Η ασφάλεια και η ηθική, η επεκτασιμότητα σε εφαρμογές του πραγματικού κόσμου, η ερμηνευσιμότητα και η επεξηγηματικότητα, καθώς και η διαχείριση πολύπλοκων περιοχών συνθηκών και συμπεριφορών αποτελούν περαιτέρω ζητήματα της RL. Η ανάπτυξη και η ευρεία χρήση των αλγορίθμων ενισχυτικής μάθησης θα βοηθηθεί από την αντιμετώπιση αυτών των ζητημάτων και την εξέταση των ανοικτών ερευνητικών ζητημάτων.

Οι γενικοί στόχοι της τρέχουσας έρευνας είναι η βελτίωση της αποτελεσματικότητας των δειγμάτων, των δυνατοτήτων γενίκευσης και μεταφοράς, του συμβιβασμού εξερεύνησης-εκμετάλλευσης, του σχεδιασμού της συνάρτησης ανταμοιβής, της ασφάλειας και της

ηθικής, του χειρισμού της πολυπλοκότητας του πραγματικού κόσμου και της ερμηνείας στην ενισχυτική μάθηση.

Κεφάλαιο 4^ο Εφαρμογές που χρησιμοποιούν αλγορίθμους Ενισχυτικής Μάθησης

4.1 Εργαλεία και περιβάλλοντα που χρησιμοποιήθηκαν

Υπάρχουν πολλά εργαλεία και βιβλιοθήκες που μπορούν να χρησιμοποιηθούν σε συνδυασμό για την ανάπτυξη αλγορίθμων ενισχυτικής μάθησης. Για την υλοποίηση αυτής της εργασίας και συνεπώς την πειραματική αξιολόγηση των αλγορίθμων χρησιμοποιήσαμε εργαλεία και βιβλιοθήκες που μπορούν να χρησιμοποιηθούν σε συνδυασμό για να φέρουμε το επιθυμητό αποτέλεσμα. Πιο συγκεκριμένα η βιβλιοθήκη που χρησιμοποιήθηκε για την δημιουργία των περιβαλλόντων (παιχνιδιών) είναι το Gym. Το OpenAI Gym είναι μια βιβλιοθήκη Python ανοιχτού κώδικα που παρέχει μια συλλογή προκατασκευασμένων περιβαλλόντων. Εκτός από τα περιβάλλοντα, το Gym παρέχει ένα σύνολο εργαλείων για εργασία με αλγόριθμους RL, συμπεριλαμβανομένου ενός απλού API για εκπαιδευτικούς πράκτορες, μετρήσεων αξιολόγησης και υποστήριξης για παραλληλοποίηση. Η βιβλιοθήκη υποστηρίζει επίσης την ενοποίηση με δημοφιλή πλαίσια βαθιάς μάθησης όπως το TensorFlow και το PyTorch, επιτρέποντας στους ερευνητές να συνδυάζουν τεχνικές βαθιάς μάθησης με RL.

Επίσης χρησιμοποιήθηκε η βιβλιοθήκη Stable Baselines, μια βιβλιοθήκη Python που έχει δημιουργηθεί πάνω από το OpenAI Gym που παρέχει μια συλλογή αξιόπιστων και καλά εφαρμοσμένων αλγορίθμων ενισχυτικής μάθησης (RL). Το Stable Baselines υποστηρίζει την παράλληλη εκτέλεση, επιτρέποντας ταχύτερη εκπαίδευση χρησιμοποιώντας πολλαπλούς πυρήνες CPU. Μάς επιτρέπει να αποθηκεύσετε και να φορτώσουν εκπαιδευμένα μοντέλα, καθιστώντας βολικό να συνεχίσετε την εκπαίδευση ή να αναπτύξετε έναν πράκτορα RL στην παραγωγή. Τα αποθηκευμένα μοντέλα μπορούν εύκολα να φορτωθούν και να

χρησιμοποιηθούν για συμπεράσματα ή περαιτέρω λεπτομέρεια, προσφέρει ένα API υψηλού επιπέδου που αφαιρεί την πολυπλοκότητα των αλγορίθμων RL, επιτρέποντας στους χρήστες να επικεντρωθούν στον πειραματισμό με διαφορετικές τεχνικές, στο σχεδιασμό προσαρμοσμένων περιβαλλόντων και στην αξιολόγηση της απόδοσης των πρακτόρων RL. Η βιβλιοθήκη υλοποιεί μια σειρά από δημοφιλείς και προηγμένους αλγόριθμους RL, συμπεριλαμβανομένων:

- Proximal Policy Optimization (PPO)
- Deep Q-Networks (DQN)
- Advantage Actor-Critic (A2C)
- Trust Region Policy Optimization (TRPO)
- Twin Delayed DDPG (TD3)
- Soft Actor-Critic (SAC)
- Proximal Value Optimization (PPO2)

Για την οπτικοποίηση των δεδομένων από την εκπαίδευση των μοντέλων χρησιμοποιήθηκε το εργαλείο Tensorboard.

Οι editor που χρησιμοποιήθηκαν είναι το Visual Studio Code και το Jupyter notebook. Επίσης για τις ανάγκες της εργασίας δημιουργήθηκε μια βιβλιοθήκη η οποία αναρτήθηκε στο github η οποία μας βοηθάει να εκπαιδεύουμε μοντέλα, να αξιολογούμε περιβάλλοντα, να παίρνουμε διάφορες χρήσιμες μετρικές και να αξιολογούμε τους αλγόριθμους μας.

4.2 Κριτήρια Επιλογής Αλγορίθμων

4.2.1 Κριτήρια Επιλογής περιβάλλοντος (Environment)

Για την σωστή επιλογή αλγορίθμου, είναι σημαντικό να λάβουμε υπόψη τα χαρακτηριστικά και τις απαιτήσεις του περιβάλλοντος. Τα περιβάλλοντα που μελετήθηκαν είναι διακριτά ή συνεχής (continuous or discrete). Τα διακριτά περιλαμβάνουν ένα πεπερασμένο σύνολο πιθανών ενεργειών, τα συνεχής επιτρέπουν μια σειρά τιμών. Με τις λύσεις που μας δίνει το stable baselines είδαμε ότι:

- **Χώρος δράσης (Action Space)** : Εάν ο χώρος δράσης είναι διακριτός αλγόριθμοι όπως ο DQN και ο A2C είναι κατάλληλοι, ενώ αλγόριθμοι όπως ο DDPG και ο SAC είναι σχεδιασμένοι για χώρους συνεχούς δράσης.
- **Χώρος Παρατήρησης (Observation space)**: Αλγόριθμοι όπως ο DQN και ο PPO2 λειτουργούν καλά με διακριτούς χώρους παρατήρησης, ενώ αλγόριθμοι όπως ο DDPG και ο SAC διαχειρίζονται καλύτερα χώρους συνεχούς παρατήρησης.
- **Ανταμοιβές (Rewards)**: Εάν το περιβάλλον παρέχει αραιές ανταμοιβές, που σημαίνει ότι το σήμα ανταμοιβής είναι σπάνιο ή παρέχεται μόνο σε ορισμένα ορόσημα τότε αλγόριθμοι όπως οι DQN, PPO2 και A2C είναι αποτελεσματικοί στην αντιμετώπιση αραιών ανταμοιβών χρησιμοποιώντας τεχνικές όπως η επανάληψη της εμπειρίας ή η προσέγγιση συνάρτησης τιμών.
- **Εξερεύνηση έναντι εκμετάλλευσης**: Αποδοτικότητα δείγματος: Εξετάστε την αποτελεσματικότητα του δείγματος του αλγορίθμου, ειδικά εάν το περιβάλλον έχει περιορισμούς στον αριθμό των αλληλεπιδράσεων ή είναι δαπανηρή η προσομοίωση. Οι αλγόριθμοι που βασίζονται σε μοντέλα, όπως ο DDPG και ο SAC, μπορούν να είναι πιο αποδοτικοί ως προς το δείγμα χρησιμοποιώντας ένα μαθημένο μοντέλο του περιβάλλοντος.
- **Παράλληλα περιβάλλοντα**: Εάν το περιβάλλον υποστηρίζει την παραλληλοποίηση, επιτρέποντας την ταυτόχρονη εκτέλεση πολλαπλών παρουσιών του περιβάλλοντος

ο A2C και ο PPO2 μπορούν να διαχειριστούν παράλληλα περιβάλλοντα για να επιταχύνουν την εκπαίδευση.

4.2.2 Κριτήρια Επιλογής του Κατάλληλου Αλγορίθμου για την Εκπαίδευση του Μοντέλου

Ακολουθούν ορισμένοι βασικοί παράγοντες που πρέπει να λάβετε υπόψη κατά την επιλογή ενός αλγορίθμου καθώς και ο παραπάνω πίνακας που μας παρέχεται από την από την ιστοσελίδα του Stable baselines σχετικά με την υλοποίηση του κάθε αλγορίθμου:

Name	Box	Discrete
ARS ¹	✓	✓
A2C	✓	✓
DDPG	✓	✗
DQN	✗	✓
HER	✓	✓
PPO	✓	✓
QR-DQN ¹	✗	✓
RecurrentPPO ¹	✓	✓
SAC	✓	✗
TD3	✓	✗
TQC ¹	✓	✗
TRPO ¹	✓	✓
Maskable PPO ¹	✗	✓

Εικόνα 15 Suitability of Algorithms proven by StableBaselines

- **Τύπος προβλήματος:** Προσδιορίζοντας τον τύπο προβλήματος που προσπαθούμε να αναγνωρίσουμε κάποια στοιχεία όπως διακριτούς ή συνεχές, episodic or continuing tasks, single or multi-agent settings κ.λπ.

- **Δυνατότητες αλγορίθμου:** Κατανοώντας τα δυνατά και τα αδύνατα σημεία κάθε αλγορίθμου. Ορισμένοι αλγόριθμοι είναι πιο κατάλληλοι για συγκεκριμένα σενάρια ή έχουν συγκεκριμένες ιδιότητες που τους καθιστούν πιο κατάλληλους. Για παράδειγμα, το DQN είναι γνωστό για το χειρισμό χώρων καταστάσεων υψηλών διαστάσεων, ενώ το PPO αποδίδει καλά με χώρους συνεχούς δράσης.
- **Αποδοτικότητα δείγματος:** Εξετάζοντας την αποτελεσματικότητα του αλγορίθμου όσον αφορά τις απαιτήσεις δείγματος. Εάν η συλλογή δεδομένων είναι δαπανηρή ή χρονοβόρα, μπορεί να είναι προτιμότεροι αλγόριθμοι που απαιτούν λιγότερες αλληλεπιδράσεις με το περιβάλλον ή χρησιμοποιούν προσεγγίσεις που βασίζονται σε μοντέλα.
- **Εξερεύνηση έναντι εκμετάλλευσης:** Προσδιορίζοντας την ισορροπία μεταξύ εξερεύνησης και εκμετάλλευσης που απαιτείται για την εργασία σας. Ορισμένοι αλγόριθμοι δίνουν εγγενώς προτεραιότητα στην εξερεύνηση, ενώ άλλοι επιτυγχάνουν μια ισορροπία. Εάν το πρόβλημά σας έχει αραιές ανταμοιβές ή απαιτεί σημαντική εξερεύνηση, μπορούν να είναι κατάλληλοι αλγόριθμοι όπως ο DQN ή ο PPO2 με στρατηγικές εξερεύνησης (π.χ. epsilon-greedy or entropy regularization).
- **Πολυπλοκότητα μοντέλου:** Αξιολογώντας την πολυπλοκότητα του μοντέλου που σκοπεύετε να χρησιμοποιήσετε. Ορισμένοι αλγόριθμοι, όπως ο DDPG ή ο SAC, έχουν σχεδιαστεί για χώρους συνεχούς δράσης και μπορούν να χειριστούν πολύπλοκα μοντέλα, ενώ απλούστεροι αλγόριθμοι όπως ο DQN ή ο A2C λειτουργούν καλά με διακριτούς χώρους ενεργειών και έχουν μικρότερο υπολογιστικό κόστος.
- **Παραλληλισμός:** Σκεπτόμενοι εάν το περιβάλλον υποστηρίζει την παραλληλοποίηση. Αλγόριθμοι όπως ο A2C και ο PPO2 μπορούν να επωφεληθούν από παράλληλα

περιβάλλοντα, επιταχύνοντας την προπόνηση συλλέγοντας ταυτόχρονα εμπειρία από πολλές περιπτώσεις.

- **Προηγούμενη γνώση**: Λαμβάνοντας υπόψη τυχόν προηγούμενες γνώσεις ή υποθέσεις σχετικά με το πρόβλημά σας που θα μπορούσαν να καθοδηγήσουν την επιλογή αλγορίθμου. Για παράδειγμα, εάν το πρόβλημά σας έχει μια γνωστή υποκείμενη δομή, μπορείτε να επιλέξετε έναν αλγόριθμο που βασίζεται σε μοντέλα για να εκμεταλλευτείτε αποτελεσματικά αυτήν τη δομή.
- **Υπολογιστικοί πόροι**: Αξιολογώντας τους υπολογιστικούς πόρους που είναι διαθέσιμοι για την εκπαίδευση του μοντέλου σας. Ορισμένοι αλγόριθμοι απαιτούν περισσότερη υπολογιστική ισχύ ή μνήμη από άλλους, επομένως επιλέξτε έναν αλγόριθμο που ταιριάζει στους περιορισμούς πόρων σας.
- **Υποστήριξη κοινότητας**: Λαμβάνοντας υπόψη τη διαθεσιμότητα τεκμηρίωσης, εκμάθησης και υποστήριξης κοινότητας για τον αλγόριθμο που εξετάζετε. Οι καθιερωμένοι αλγόριθμοι με ενεργές κοινότητες μπορούν να παρέχουν χρήσιμους πόρους και βοήθεια κατά την εφαρμογή σας.
- **Πειραματική Επανάληψη**: Είναι συχνά ωφέλιμο να δοκιμάζονται πολλούς αλγόριθμους και να συγκρίνονται την απόδοσή τους ώστε να βρεθεί αυτός που λειτουργεί καλύτερα για τη συγκεκριμένη εργασία.

4.2.3 Κριτήρια Επιλογής του Κατάλληλου Μοντέλου

- **Υπερπαραμέτροι**: Κάθε αλγόριθμος έχει το δικό του σύνολο υπερπαραμέτρων που πρέπει να ρυθμιστούν για βέλτιστη απόδοση. Παραδείγματα περιλαμβάνουν τον ρυθμό μάθησης, τον συντελεστή προεξόφλησης (γάμμα), τον ρυθμό εξερεύνησης, τον συντελεστή κανονικοποίησης εντροπίας, τον αριθμό επιπέδων και μονάδων στο

νευρωνικό δίκτυο κ.λπ. Ο πειραματισμός με διαφορετικές τιμές υπερπαραμέτρων μπορεί να επηρεάσει σημαντικά την απόδοση του μοντέλου σας.

- **Αρχιτεκτονική δικτύου**: Ανάλογα με την πολυπλοκότητα του προβλήματος, η αρχιτεκτονική του νευρωνικού δικτύου μπορεί να χρειαστεί να προσαρμοστεί (ρυθμός εξερεύνησης, συντελεστής κανονικοποίησης εντροπίας, αριθμός στρωμάτων και μονάδων στο νευρωνικό δίκτυο κ.λπ.) Για παράδειγμα, η αύξηση του αριθμού των στρωμάτων ή των μονάδων στο δίκτυο μπορεί να ενισχύσει την αναπαραστατική του ικανότητα, αλλά μπορεί επίσης να αυξήσει τον χρόνο εκπαίδευσης και τις απαιτήσεις μνήμης. Η εξισορρόπηση της πολυπλοκότητας του δικτύου με τους διαθέσιμους πόρους είναι ζωτικής σημασίας.
- **Διάρκεια εκπαίδευσης**: Καθορισμός του κατάλληλου αριθμού επαναλήψεων ή επεισοδίων εκπαίδευσης για το μοντέλο σας. Είναι σημαντικό να βρεθεί μια ισορροπία μεταξύ της εκπαίδευσης για επαρκή διάρκεια ώστε να αποτυπωθεί η βέλτιστη απόδοση και της αποφυγής της υπερβολικής προσαρμογής σε συγκεκριμένα περιστατικά εκπαίδευσης. Η παρακολούθηση των καμπυλών μάθησης και των μετρήσεων απόδοσης κατά τη διάρκεια της εκπαίδευσης μπορεί να βοηθήσει στον προσδιορισμό του βέλτιστου σημείου διακοπής.
- **Εξερεύνηση έναντι εκμετάλλευσης**: Εάν το πρόβλημα απαιτεί ισορροπία μεταξύ διερεύνησης και εκμετάλλευσης, η στρατηγική διερεύνησης θα πρέπει να οριστεί ανάλογα. Για παράδειγμα, ο ρυθμός εξερεύνησης μπορεί να μειωθεί σταδιακά με την πάροδο του χρόνου (π.χ. στρατηγική epsilon-greedy) ή ο συντελεστής εντροπίας μπορεί να ρυθμιστεί (για αλγορίθμους όπως ο PPO) για τον έλεγχο του επιπέδου εξερεύνησης.
- **Διαμόρφωση ανταμοιβής**: Σε ορισμένες περιπτώσεις, μπορεί να είναι απαραίτητη η διαμόρφωση της συνάρτησης ανταμοιβής για να παρέχεται πιο κατατοπιστική

ανατροφοδότηση στον πράκτορα. Η διαμόρφωση της ανταμοιβής μπορεί να βοηθήσει στην καθοδήγηση του πράκτορα προς την επιθυμητή συμπεριφορά ή να παρέχει κίνητρα για συγκεκριμένες ενέργειες.

- **Παρακολούθηση και αξιολόγηση**: Συνεχής παρακολούθηση της απόδοσης του μοντέλου κατά τη διάρκεια της εκπαίδευσης με τη χρήση μετρήσεων όπως η μέση ανταμοιβή, η διάρκεια του επεισοδίου ή το ποσοστό επιτυχίας. Χρήση δειγμάτων αξιολόγησης για την αξιολόγηση των δυνατοτήτων γενίκευσης του μοντέλου. Η συχνότητα της αξιολόγησης και ο αριθμός των δειγμάτων αξιολόγησης θα πρέπει να προσαρμόζονται ανάλογα με τις απαιτήσεις του χρήστη.
- **Οπτικοποίηση και ανάλυση σφαλμάτων**: Αξιοποίηση εργαλείων και τεχνικών οπτικοποίησης για την απόκτηση γνώσεων σχετικά με τη συμπεριφορά του πράκτορα και τη διαδικασία μάθησης. Εργαλεία όπως το TensorBoard μπορούν να παρέχουν οπτικοποιήσεις διαφόρων μετρήσεων, συμπεριλαμβανομένων των ανταμοιβών, των απωλειών και των στατιστικών στοιχείων εξερεύνησης, βοηθώντας σας να κατανοήσετε και να αντιμετωπίσετε τυχόν προβλήματα που προκύπτουν.
- **Πειραματική επανάληψη**: Η μάθηση ενίσχυσης είναι μια επαναληπτική διαδικασία που συχνά απαιτεί πειραματισμό με διαφορετικές διαμορφώσεις, υπερπαραμέτρους και τεχνικές. Παρακολουθείτε τα πειράματα, συμπεριλαμβανομένων των τιμών των παραμέτρων και των αποτελεσμάτων, για να καθοδηγείτε μελλοντικές επαναλήψεις και βελτιώσεις.

4.2.4 Κριτήρια Αξιολόγησης Αλγορίθμου

Κατά την αξιολόγηση του μοντέλου, υπάρχουν αρκετοί σημαντικοί παράγοντες που πρέπει να ληφθούν υπόψη. Στη συνέχεια αναφέρονται ορισμένοι παράγοντες στους οποίους είναι σημαντικό να δοθεί προσοχή:

- **Μετρήσεις απόδοσης:** Αξιολόγηση του μοντέλου με βάση τις κατάλληλες μετρήσεις απόδοσης για το συγκεκριμένο πρόβλημά. Οι συνήθεις μετρήσεις περιλαμβάνουν τη μέση ανταμοιβή ανά επεισόδιο, τη διάρκεια επεισοδίου, το ποσοστό επιτυχίας ή οποιαδήποτε άλλη μέτρηση για συγκεκριμένη εργασία που υποδεικνύει την επιθυμητή συμπεριφορά. Στη συνέχεια ακολουθεί σύγκριση των μετρήσεων με τα προκαθορισμένα κριτήρια επιτυχίας ή την απόδοση βάσης.
- **Γενίκευση:** Αξιολόγηση της ικανότητας του μοντέλου να γενικεύει τη συμπεριφορά του που έχει μάθει σε αόρατα περιβάλλοντα ή σενάρια. Εκτελώντας αποσπάσματά αξιολόγησης σε διαφορετικά περιβάλλοντα ή με παραλλαγές στις αρχικές συνθήκες μπορεί να διασφαλιστεί ότι η απόδοση του πράκτορα δεν είναι συγκεκριμένη για το περιβάλλον εκπαίδευσης.
- **Σταθερότητα:** Ελέγχοντας τη σταθερότητα της εκμαθημένης πολιτικής αξιολογώντας την απόδοσή της σε πολλαπλές σειρές ή επεισόδια. Διακυμάνσεις στην απόδοση ή ασυνέπεια μπορεί να υποδηλώνουν αστάθεια ή προβλήματα σύγκλισης. Εάν το μοντέλο εμφανίζει υψηλή διακύμανση στην απόδοση, πρέπει να εξεταστεί ενδεχόμενο προσαρμογής των υπερ παραμέτρων, αύξησης της διάρκειας εκπαίδευσης ή χρησιμοποίησης τεχνικών όπως η αποκοπή ανταμοιβής ή η τακτοποίηση της συνάρτησης αξίας.
- **Καμπύλη μάθησης:** Σχεδιάζοντας και αναλύοντας την καμπύλη μάθησης του μοντέλου κατά τη διάρκεια της εκπαίδευσης. Αναζητώντας τάσεις στη βελτίωση της απόδοσης με την πάροδο του χρόνου. Η σταθερή βελτίωση υποδηλώνει αποτελεσματική μάθηση, ενώ η μείωση ή η μείωση των αποδόσεων μπορεί να υποδηλώνουν προβλήματα σύγκλισης ή την ανάγκη για περαιτέρω προσαρμογές.

- **Υπολογιστικοί Πόροι:** Εξετάζοντας τους υπολογιστικούς πόρους που απαιτούνται για την αξιολόγηση. Πρέπει να βεβαιωθούμε ότι η διαδικασία αξιολόγησης είναι εφικτή εντός των διαθέσιμων πόρων, συμπεριλαμβανομένης της μνήμης, της επεξεργαστικής ισχύος και του χρόνου.
- **Επαναληπτική βελτίωση:** Χρησιμοποιώντας τα αποτελέσματα της αξιολόγησης για την επαναληπτική βελτίωση του μοντέλου σας. Αναλύοντας τις ελλείψεις ή τις αδυναμίες που εντοπίστηκαν κατά την αξιολόγηση και επαναλαμβάνοντας το μοντέλο, τις υπερπαραμέτρους ή τη διαδικασία εκπαίδευσης για να αντιμετωπίσετε αυτά τα ζητήματα.

4.3 Περιβάλλοντα Πειραματισμού

4.3.1 Atari game “breakout”

Το πρώτο περιβάλλον αξιολόγησης είναι το περιβάλλον ATARI 2600 και πιο συγκεκριμένα το “Breakout-v0”. Η λογική είναι παρόμοια με το πινγκ-πονγκ: Μετακινείται ένα κουπί και χτυπάτε την μπάλα σε έναν τοίχο από τούβλα στο πάνω μέρος της οθόνης. Ο στόχος σας είναι να καταστρέψετε τον τοίχο από τούβλα.

Ο χώρος παρατήρησης (observation space) είναι μια εικόνα RGB που αντιπροσωπεύει την οθόνη του παιχνιδιού. Από προεπιλογή, έχει σχήμα (210, 160, 3) pixel. Η εικόνα δείχνει τα τούβλα, το κουπί και την μπάλα, μαζί με το περιβάλλον φόντο. Από προεπιλογή, το περιβάλλον επιστρέφει την εικόνα RGB που εμφανίζεται στους παίκτες. Ωστόσο, είναι δυνατόν να παρατηρηθεί.


- Τα 128 Byte RAM της κονσόλας

- Μια εικόνα σε κλίμακα του γκρι αντί αυτού. Οι αντίστοιχοι χώροι παρατήρησης είναι $\text{Box}([0 \dots 0], [255 \dots 255], (128, \dots), \text{uint8})$, $\text{Box}([[0 \dots 0] \dots [0 \dots 0]], [[255 \dots 255] \dots [255 \dots 255]], (250, 160), \text{uint8})$ αντίστοιχα.

Ο χώρος δράσης (action space) αποτελείται από διακριτές ενέργειες. Ο πράκτορας μπορεί να επιλέξει από τις ακόλουθες ενέργειες: μετακινήστε το κουπί προς τα αριστερά, μετακινήστε το κουπί προς τα δεξιά ή δεν κάνετε τίποτα. Όλες οι ενέργειες που μπορούν να εκτελεστούν σε αυτό το περιβάλλον είναι οι εξής: (0 - NOOP, 1 - FIRE, 2 - RIGHT, 3 - LEFT).

Το παιχνίδι παρέχει ένα αραιό σήμα ανταμοιβής (rewards). Ο πράκτορας λαμβάνει μια θετική ανταμοιβή +1 για κάθε τούβλο που σπάει. Το επεισόδιο τελειώνει όταν όλα τα τούβλα καθαρίζονται ή ο πράκτορας χάνει όλη του τη ζωή. Αν ο πράκτορας χάσει τη μπάλα και αυτή χτυπήσει στο κάτω μέρος της οθόνης, χάνει μια ζωή. Το παιχνίδι δίνει επίσης μια μικρή αρνητική ανταμοιβή (-1) για κάθε χρονικό βήμα για να ενθαρρύνει τον πράκτορα να λύσει γρήγορα το παιχνίδι.

Το "Breakout-v0" θεωρείται ένα απαιτητικό περιβάλλον λόγω του αραιού σήματος ανταμοιβής και της ανάγκης για ακριβείς κινήσεις κουπιών για να χτυπήσει την μπάλα και να σπάσει αποτελεσματικά τα τούβλα. Ο πράκτορας πρέπει να μάθει να προβλέπει την τροχιά της μπάλας και να παίρνει στρατηγικές αποφάσεις για να μεγιστοποιήσει το σκορ της.



Εικόνα 16 Atari Breakout environment

4.3.2 Gym game “LunarLanderContinuous-v2”

Το LunarLander, είναι ένα αντικείμενο-αεροσκάφος όπου η αποστολή του είναι να προσεδαφιστεί σε μια καθορισμένη τοποθεσία προσγείωσης. Το περιβάλλον διαθέτει τόσο διακριτό χώρο δράσης όσο και εκδόσεις χώρου συνεχούς δράσης. Τα παρακάτω παρουσιάζουν κυρίως την offline έκδοση χώρου δράσης του lunarlander. Οι ενέργειες του αεροσκάφους (observation space) είναι οι εξής. (αδράνεια, κίνηση αριστερής μηχανής, κίνηση δεξιάς μηχανής, κίνηση πάνω) και είναι ένα διάνυσμα 8 διαστάσεων: οι συντεταγμένες του lander σε x & y , οι γραμμικές του ταχύτητες σε x & y , η γωνία του, η γωνιακή του ταχύτητα και δύο booleans που αντιπροσωπεύουν εάν κάθε σκέλος είναι σε επαφή με το έδαφος ή όχι . Η ανταμοιβή για τη μετάβαση από την κορυφή της οθόνης στο σημείο προσγείωσης και τη μηδενική ταχύτητα είναι περίπου 100...140 πόντοι. Εάν ο πράκτορας ταξιδεύει προς μια κατεύθυνση μακριά από το σημείο προσγείωσης, χάνει την ανταμοιβή. Εάν ο πράκτορας πέσει ή σταματήσει, το επεισόδιο τελειώνει, κερδίζοντας

επιπλέον -100 ή +100 πόντους. Η επαφή εδάφους για κάθε σκέλος είναι ένα μπόνους +10. Η κύρια μηχανή εκτόξευσης είναι -0,3 μπόνους ανά καρέ. Μια επιτυχημένη προσγείωση στο σημείο προσγείωσης είναι 200 βαθμοί. Είναι δυνατή η προσγείωση εκτός του συστήματος προσγείωσης.



Εικόνα 17 LunarLander Gym Environment

4.3.2 Atari game “Atlantis-v4”

Το Atlantis ανήκει στο είδος παιχνιδιών σκοποβολής που ήταν δημοφιλείς στις αρχές της δεκαετίας του 1980. Ο παίκτης ελέγχει τρία κανόνια τα οποία έχουν την δυνατότητα να καταστρέψουν τα αντίπαλα πλοία πριν αυτά προλάβουν να ρίξουν βόμβες σε έναν από τους οικισμούς. Τα εχθρικά πλοία περνούν μπρος-πίσω από αριστερά προς τα δεξιά τέσσερις φορές προτού εισέλθουν στο πεδίο βομβαρδισμού.

Ο χώρος δράσης (action space) αποτελείται από διακριτές ενέργειες. Ο πράκτορας μπορεί Οι ενέργειες που μπορούν να εκτελεστούν σε αυτό το περιβάλλον είναι οι εξής: (0 - NOOP, 1 - FIRE, 2 - RIGHT, 3 - LEFT).Ο χώρος παρατήρησης (observation space) είναι μια εικόνα RGB που αντιπροσωπεύει την

οθόνη του παιχνιδιού. Από προεπιλογή, έχει σχήμα (210, 160, 3) pixel. Το

περιβάλλον επιστρέφει την εικόνα RGB που εμφανίζεται στους παίκτες. Ωστόσο, είναι

δυνατόν να παρατηρηθεί.

Τα 128 Byte RAM της κονσόλας

Μια εικόνα σε κλίμακα του γκρι αντί αυτού. Οι αντίστοιχοι χώροι παρατήρησης

είναι `Box([0 ... 0], [255 ... 255], (128,), uint8)` , `Box([[0 ... 0] ... [0 ... 0]], [[255 ... 255]`

`... [255 ... 255]], (250, 160), uint8)` αντίστοιχα. Ως ανταμοιβή κερδίζουμε πόντους για την

καταστροφή των εχθρικών πλοίων.

Κεφάλαιο 5° Πειράματα και Αξιολογήσεις

Σε αυτό το κεφάλαιο θα αναλύσουμε και θα περιγράψουμε την συμπεριφορά που έχει ο κάθε αλγόριθμος σε συγκεκριμένα περιβάλλοντα που αξιολογούμε καθώς και την συμπεριφορά που έχει αλλάζοντας τις πολιτικές τους καθώς και διάφορους παραμέτρους όπως (learning rate, gamma).

Σε συνέχεια θα συγκρίνουμε τα αποτελέσματα που έχουμε πάρει από τους αλγόριθμους καθώς και θα προσπαθήσουμε να περιγράψουμε το γιατί κάποιος συνδυασμός (αλγόριθμου, πολιτικής και λοιπών παραμέτρων), έχει καλύτερη απόδοση από τους υπόλοιπους.

Για την διευκόλυνση μας δημιουργήθηκε μια βιβλιοθήκη μέσω python η οποία μας επιτρέπει να βλέπουμε διάφορες πληροφορίες σχετικά με το περιβάλλον, να εκπαιδεύσουμε το μοντέλο μας και έπειτα να αξιολογούμε κατάλληλα τον αλγόριθμο μας. Η βιβλιοθήκη είναι opensource στο github <https://github.com/kiriakos19/AlgorithmAssessment>.

5.1 Περιγραφή βοηθητικής βιβλιοθήκης για την αξιολόγηση των αλγορίθμων

Στο συγκεκριμένο κεφάλαιο γίνεται μια αναλυτική περιγραφή της βιβλιοθήκης που υλοποιήθηκε για τις ανάγκες της εκπαίδευσης των πολλαπλών μοντέλων ώστε να προκύψουν τα αποτελέσματα τα οποία θα παρουσιαστούν παρακάτω. Η βιβλιοθήκη έχει αναρτηθεί στο github στον ακόλουθο σύνδεσμο <https://github.com/kiriakos19/AlgorithmAssessment> με λεπτομερή σχολιασμό του κώδικα.

Οι λειτουργίες της βιβλιοθήκης έχουν βασικό στόχο να βοηθήσουν τον χρήστη να δει και να χρησιμοποιήσει τις χρήσιμες πληροφορίες σχετικά με το περιβάλλον που επέλεξε για την εκπαίδευση του μοντέλου, έτσι ώστε να καταφέρει να επιτύχει στην καταχώριση των σωστών παραμέτρων, επιλογή κατάλληλου αλγόριθμου για το περιβάλλον, κ.α. Έπειτα υπάρχουν αρκετές επιπρόσθετες λειτουργίες έτσι ώστε ο χρήστης να εκπαιδεύει και να αξιολογεί το κάθε μοντέλο ξεχωριστά ή και μαζικά, ανάλογα τον στόχο του, θέτοντας μόνο κάποιες παραμέτρους, εκ των οποίων κάποιες βοηθάνε στον πειραματισμό αλλά και στα καλύτερα αποτελέσματα του μοντέλου.

Δημιουργήθηκε μια κλάση που κάνει όλο τον κύκλο αξιολόγησης του ενός μοντέλου, την “CompleteModelReview”. Αρχικά, πρέπει να θέσουμε τις παρακάτω παραμέτρους όπως βλέπουμε στο παρακάτω παράδειγμα.

- `enviroment_name = 'Seaquest-v4'`
- `policy = 'CnnPolicy'`
- `algorithm = 'PPO'`
- `n_envs=4`
- `n_stack=4`
- `total_timesteps=1000000`
- `seed=0`
- `verbose=1`
- `environment_type = "Atari"`
- `learning_rate = None`
- `gamma = None`
- `is_image_based = True`
- `eval_episodes = 10`

Αφού ολοκληρωθεί αυτή η διαδικασία δημιουργείται το μοντέλο που επιθυμούμε και δίνονται οι λειτουργίες της ανάλυσης (`analyzeEnv()`) του περιβάλλοντος (που μας επιστρέφει μια Boolean μεταβλητή που βοηθάει στο επόμενο στάδιο της εκπαίδευσης του μοντέλου), στην εκπαίδευση (`trainModel()`) και στην αξιολόγηση (`evaluateModel()`) όπως αποτυπώνεται και στην παρακάτω εικόνα με το block του κώδικα.

```
newModel = CompleteModelReview(enviroment_name, algorithm, policy, n_envs, n_stack, seed,
                               verbose, total_timesteps, environment_type, learning_rate, gamma, is_image_based, eval_episodes)
is_imageBased = newModel.analyzeEnv()
newModel.is_image_based = is_imageBased
newModel.trainModel()
newModel.evaluateModel()
```

Εικόνα 18 Code Block for example of analyze, training and evaluate Model

Έπειτα, σε κάθε function γίνονται οι απαραίτητοι έλεγχοι βάση των παραμέτρων που θέσαμε παραπάνω έτσι ώστε να δημιουργηθεί κατάλληλα ο αλγόριθμος για την εκπαίδευση του. Στο τελικό στάδιο της εκπαίδευσης του μοντέλου, αποθηκεύεται στον τοπικό δίσκο ένα αρχείο με τα logs το οποίο μπορεί να αναπαραχθεί με το εργαλείο tensorboard που αναφέρθηκε παραπάνω, για να μας βοηθήσει να αντιληφθούμε και να κατανοήσουμε σε βάθος την πορεία εκπαίδευσης του μοντέλου ώστε να καταφέρουμε να το χειριστούμε με τον βέλτιστο δυνατό τρόπο. Κατά την ολοκλήρωση της εκπαίδευσης, καλούμε την μέθοδο evaluateModel() η οποία μας επιστρέφει το σκορ που πέτυχε ο αλγόριθμος στο συγκεκριμένο περιβάλλον.

Στην συνέχεια, δημιουργήθηκαν άλλες τρεις λειτουργίες που υλοποιούν μεμονωμένα την επανεκπαίδευση ενός μοντέλου, την αξιολόγηση του και μια ακόμα λειτουργία εκπαίδευσης και σύγκρισης πολλαπλών αλγορίθμων σε ένα συγκεκριμένο περιβάλλον.

5.2 Αξιολόγηση μοντέλων


5.2.1 Ο Αλγόριθμος A2C στο παιχνίδι Atari

Οι αρχικές μας μετρήσεις ήταν σε στο περιβάλλον “Breakout” με τις προκαθορισμένες τιμές της βιβλιοθήκης stable baselines. Το μοντέλο εκπαιδεύτηκε με τις πολιτικές CnnPolicy και MlpPolicy. Επίσης πειραματιστήκαμε με τις παραμέτρους learning rate και gamma σε διάφορες τιμές όπως θα δούμε στον παρακάτω πίνακα.

Timesteps	Learning rate	Gamma	Policy	episodes	average reward	std reward
	100000	0.0007	0.99 CnnPolicy	50	7.3	2.3086
	300000	0.0007	0.99 MlpPolicy	50	2.14	1.2
	300000	0.0007	0.99 CnnPolicy	50	10.12	3.9377
	300000	0.007	0.99 CnnPolicy	50	9.5	3.62
	300000	0.0007	1 CnnPolicy	50	11	3.72
	500000	0.0007	0.99 CnnPolicy	50	11.15	4.35
	1000000	0.0007	0.99 CnnPolicy	50	18.82	6.1796
	1000000	0.001	0.99 CnnPolicy	50	16.16	5.91

Εικόνα 19 Πίνακας αποτελεσμάτων αξιολόγησης A2C

Σύμφωνα με τον παραπάνω πίνακα αλλά και με τα γραφήματα παρακάτω (η μπλε καμπύλη είναι με CnnPolicy και η πορτοκαλί με MlpPolicy), παίρνοντας σαν γνώμονα ένα εκπαιδευμένο μοντέλο στις 300000 φορές με ίδιες παραμέτρους (learning_rate, gamma), βλέπουμε την διαφορά αποτελέσματος όταν αλλάζουμε πολιτική από CnnPolicy σε MlpPolicy. Αυτό συμβαίνει γιατί η CnnPolicy είναι κατάλληλη για περιβάλλοντα με χώρους εισόδου υψηλών διαστάσεων, όπως και περιβάλλοντα που η εκτίμηση τους γίνεται βάση εικόνας.




Εικόνα 20 Γραφήματα μοντέλων A2C (αριστερά) σε MlpPolicy και (δεξιά) σε CnnPolicy

Χρησιμοποιεί συνελκτικά/ νευρωνικά επίπεδα για την επεξεργασία οπτικών πληροφοριών και την εξαγωγή χαρακτηριστικών από τις εικόνες εισόδου και ο πράκτορας πρέπει να λαμβάνει αποφάσεις με βάση τις μη επεξεργασμένες τιμές pixel.

Μία άλλη ενδιαφέρουσα παρατήρηση βλέπουμε στα παρακάτω μοντέλα με εκπαίδευση στις 300000 όπου:

- μπλε: gamma = 0.99, learning_rate = 0.007
- κόκκινο: gamma = 0.99, learning_rate = 0.0007 (default from library)
- μαύρο: gamma = 1, learning_rate = 0.0007


φαίνονται να έχουν σχεδόν την ίδια συμπεριφορά με ελαφρώς καλύτερα αποτελέσματα στο μοντέλο με διαφορετικό gamma.



Εικόνα 21 Γραφήματα μοντέλων A2C με διαφορετικούς παραμέτρους

Στα παρακάτω γραφήματα διακρίνουμε πως το default μοντέλο δείχνει μία σταθερότητα όσον αφορά το entropy_loss και αυτό αποτυπώνεται στο γράφημα που αποτυπώνει τον χρόνο ολοκλήρωσης της εκπαίδευσης με αποτέλεσμα να είναι και ο πιο γρήγορος και μάλιστα οι χρόνοι ολοκλήρωσης τους είναι:

- μαύρος: 2.30hr
- κόκκινος: 53min
- μπλε: 58min




Γραφήματα μοντέλων entropy_loss και time A2C

Σε μία άλλη ανάλυση μοντέλων, αυτή την φορά εκπαιδευμένα σε 1.000.000 φορές διακρίναμε και πάλι πως ο default αλγόριθμος της βιβλιοθήκης φέρει τα καλύτερα αποτελέσματα τόσο σε χρόνο εκτέλεσης όσο και στο μέσο όρο επιβράβευσης.

- μωβ: gamma:0.99 , learning_rate: 0.0007 (default)

➤ πράσινο: gamma:0.99 learning_rate: 0.001



Εικόνα 22 Γραφήματα μοντέλων απόδοσης A2C 1.000.000 εποχές

Έπειτα από τις παραπάνω αναλύσεις είδαμε πως το μοντέλο με τις 1.000.000 φορές εκπαίδευσης εξακολουθεί να δείχνει σταδιακή αύξηση της καμπύλης απόδοσης πράγμα το οποίο μας επιτρέπει να συνεχίσουμε την εκπαίδευση μας φέρνοντας θετικά αποτελέσματα και χωρίς να παρουσιάζεται το φαινόμενο υπερ-εκπαίδευσης. Οι πειραματισμοί μας αλλάζοντας τις υπερπαραμέτρους μας έδειξε πως τα μοντέλα μας δεν παρουσιάζουν βελτίωση και πως η MlpPolicy πολιτική δεν ταιριάζει σε discrete περιβάλλοντα.


5.2.2 Ο Αλγόριθμος PPO στο παιχνίδι Atari “Breakout”

Και σε αυτό το μοντέλο χρησιμοποιούμε τις πολιτικές CnnPolicy και MlpPolicy. Επίσης και εδώ πειραματιστήκαμε με τις παραμέτρους learning rate και gamma.

Παρακάτω θα δούμε τις καμπύλες τών μοντέλων όπου :

- κίτρινη: (policy: MlpPolicy, gamma:0.99, learning_rate:0.0003)
- πορτοκαλί: (policy: CnnPolicy, gamma:0.99, learning_rate:0.003)
- πράσινο: (policy: CnnPolicy, gamma:0.99, learning_rate:0.00003)
- μωβ : (policy: CnnPolicy, gamma:1, learning_rate:0.0003)
- ροζ : (policy: CnnPolicy, gamma:0.99, learning_rate:0.0003)

Και σε αυτό το πείραμα διακρίνουμε καλύτερα αποτελέσματα στο μοντέλο με τις default τιμές που μας δίνει η βιβλιοθήκη του stable baselines, εδώ και εδώ διακρίνουμε την χαμηλή επίδοση του μοντέλου με την MlpPolicy για τους λόγους που αναφέραμε παραπάνω. Άλλη μια αναφορά που μπορούμε να κάνουμε είναι πως συγκρίνοντας τα 2 μοντέλα που πειραματιστήκαμε με το (learning_rate) , βλέπουμε το μοντέλο με την μικρότερη τιμή (πράσινο = 0.00003) ενώ δεν ξεκινάει με καλά αποτελέσματα, μετά τις 150000 εποχές δείχνει ανοδική τάση και ξεπερνάει το αντίστοιχο μοντέλο (πορτοκαλί = 0.003), το οποίο μένει στάσιμο μετά τις 150000 εποχές.




Εικόνα 23 Πίνακας αποτελεσμάτων αξιολόγησης PPO

Τώρα όσον αφορά τον χρόνο εκτέλεσης παρατηρούμε ότι το μοντέλο με την παραμετροποιημένη τιμή του gamma ($\mu\beta = 1$) εκτελείται σε ποιο σύντομο χρονικό διάστημα.

Εικόνα 24 Γράφημα μοντέλων απόδοσης PPO 300.000 εποχές

- κίτρινη: 1:32h
- πορτοκαλί: 4:10h
- πράσινο: 2:10h
- μωβ :1:35
- ροζ : 1:45




Εικόνα 25 Γράφημα time μοντέλων PPO

Στα παρακάτω γραφήματα διακρίνουμε σταθερότητα και βέλτιστες τιμές στα μοντέλα τον οποίον είναι η default και το μοντέλο με την πειραγμένη τιμή του gamma.



Εικόνα 26 Γραφήματα μοντέλων διάφορων μετρικών PPO

Αφού είδαμε παραπάνω ότι η μικρή αλλαγή που κάναμε στο gamma δεν επηρέασε και πολύ το μοντέλο μας, δοκιμάσαμε να αυξήσουμε σε (1.4) και είδαμε ότι τελικά ήταν λάθος αυτή η επιλογή (πράσινη καμπύλη)και μάλιστα ολοκληρώθηκε η εκπαίδευση στο διπλάσιο χρόνο σε σχέση με τα default μοντέλα.



Παρατηρώντας τα αποτελέσματα εκπαίδευσης μοντέλων πάνω στον αλγόριθμο PPO παρατηρούμε παρόμοια συμπεράσματα και συμπεριφορές με τα μοντέλα που εφαρμόσαμε τον αλγόριθμο A2C.

5.2.3 Ο Αλγόριθμος TD3

Στην περίπτωση χρήσης του TD3 για την υλοποίηση του, εκτός από τους γνωστούς παραμέτρους που ορίσαμε από τα παραπάνω παραδείγματα χρειάστηκε να ορίσουμε και το `action_noise` γιατί ο αλγόριθμος TD3 χρησιμοποιεί ντετερμινιστική πολιτική.

```
n_actions = env.action_space.shape[-1]
```

```
action_noise = NormalActionNoise(mean=np.zeros(n_actions), sigma=0.1 * np.ones(n_actions))
```


Ο αλγόριθμος TD3 από Stable Baselines δεν υποστηρίζει τη χρήση πολιτικών CnnPolicy γιατί έχει σχεδιαστεί για εργασίες συνεχούς ελέγχου, όπου ο χώρος δράσης είναι συνεχής και συνήθως εφαρμόζεται σε περιβάλλοντα με συνεχείς αναπαραστάσεις κατάστασης καθώς και περιβάλλοντα τύπου BOX και όχι DISCRETE.

Για τους πειραματισμούς μας χρησιμοποιούμε παρακάτω το περιβάλλον “LunarLanderContinuous-v2” όπου υλοποιείται στο GYM σε box observation space.

Στα μοντέλα πειραματιστήκαμε με τις παραμέτρους (`gamma`, `learning_rate` και `noise`) και τα μοντέλα μας εκπαιδεύτηκαν σε 100000 εποχές:

- ροζ: (`gamma=0.95`, `learning_rate = 0.001`, `noise = 0.1`)
- μωβ: (`gamma=0.99`, `learning_rate = 0.0008`, `noise = 0.1`)
- πράσινο: (`gamma=0.99`, `learning_rate = 0.001`, `noise = 0.5`)
- γκρι: (`gamma=0.99`, `learning_rate = 0.001`, `noise = 0.1`) default

Καλύτερο μοντέλο αποδείχθηκε το μοντέλο με την παραμετροποιημένη τιμή του `noise`. Κατά το `evaluation` των μοντέλων σε γραφικό περιβάλλον επίσης παρατηρήθηκε πως τα μοντέλα γκρι και πράσινο παρατηρήθηκε πως ο πράκτορας έφτανε κατευθείαν στον στόχο σε σχέση με τα άλλα μοντέλα που δεν κατάφεραν να ολοκληρώσουν ούτε μια επιτυχής προσπάθεια στις 15 φορές που δοκιμάστηκαν, πράγμα το οποίο φαίνεται και από τα παρακάτω αποτελέσματα.




Εικόνα 28 Γραφήματα απόδοσης μοντέλων TD3

Όσον αφορά τους χρόνους εκτέλεσης :

- ροζ: 32m
- μωβ: 36m
- πρασινο: 25m
- γκρι: 30m (default)


διακρίνουμε πως το μοντέλο με την καλύτερη επίδοση ολοκλήρωσε την εκπαίδευση του σε ποιο σύντομο χρονικό διάστημα.



Εικόνα 29 Γραφήματα time (αριστερά) και actor_loss (δεξιά) μοντέλων TD3

5.2.4 Ο Αλγόριθμος DDPG


Για την αξιολόγηση και διάφορους πειραματισμούς του αλγόριθμου DDPG στο περιβάλλον “LunarLanderContinuous-v2” ακολουθήσαμε την ίδια τακτική με τον αλγόριθμο TD3 καθώς πληρούν τις ίδιες προϋποθέσεις εφαρμογής παραμέτρων και πολιτικών. έτσι και εδώ τα μοντέλα μας ήταν τα εξής:



Εικόνα 30 Γραφήματα απόδοσης μοντέλων DDPG

- γαλάζιο: (gamma=0.95, learning_rate = 0.001, noise = 0.5, time=29)
- μωβ: (gamma=0.99, learning_rate = 0.001, noise = 0.1, time= 26m)
- κόκκινο: (gamma=0.99, learning_rate = 0.0007, noise = 0.5, time=26)
- γκρι: (gamma=1.3, learning_rate = 0.001, noise = 0.1, time=22) default
- μωβ: (gamma=0.99, learning_rate = 0.003, noise = 0.1, time=28) default
- πορτοκαλί: (gamma=0.99, learning_rate = 0.001, noise = 0.1, time=28) default

Με βάση τα παραπάνω αποτελέσματα παρατηρούμε και εδώ πως το default μοντέλο έχει την καλύτερη απόδοση με βάση τον χρόνο/reward αλλά την καλύτερη επίδοση έχει το μοντέλο με την παραμετροποιημένη τιμή στο sigma.




Εικόνα 31 Γράφημα απόδοσης χρόνου DDPG


5.2.5 Συγκριση μοντέλων

➤ A2C vs PPO

Η πρώτη σύγκριση που πραγματοποιήθηκε ήταν στο περιβάλλον “Breakout” και συγκεκριμένα δύο μοντέλων (PPO, A2C) που και τα δύο είναι εκπαιδευμένα σε 1.000.000 εποχές και με τις default παραμέτρους που ορίζει το StableBaselines.

- Πράσινη καμπύλη : PPO
- Μωβ καμπύλη: A2C






Εικόνα 32 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C και PPO

Στις παραπάνω εικόνες αποδεικνύεται ότι την βέλτιστη απόδοση είχε το μοντέλο με τον αλγόριθμο A2C με τις επιδόσεις που καταγράφονται στον πίνακα παρακάτω. Σημειώνεται πως ο A2C έδειξε μέγιστο σκορ ανά κύκλο παιχνιδιού 39 βαθμούς. Επίσης παρατηρήθηκε πως ο χρόνος εκπαίδευσης του PPO ήταν στις 4:30 ώρες ενώ του A2C στις 3 ώρες.

Algorithm	Mean Reward	STD Reward
PPO	8.4	2.49
A2C	14.4	8.6

Πίνακας 1 Αποτελέσματα σύγκρισης A2C και PPO

Άλλη μια σύγκριση που πραγματοποιήθηκε ανάμεσα σε αυτούς τους 2 αλγόριθμους είναι στο περιβάλλον “Pac-Man”. Η διαφορά του “Pac-Man” με το “Breakout” είναι πως στο Pac-Man υπάρχουν διπλάσιες ενέργειες (4 - 8) που μπορεί να κάνει ο πράκτορας και διαφορετικός ο τρόπος ανταμοιβής. Σε αυτό το περιβάλλον καλύτερη απόδοση είχε ο PPO με σκορ 950 έναντι του A2C με σκόρ 480.



Εικόνα 33 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C και PPO σε περιβάλλον PACMAN

➤ A2C vs PPO vs TD3 vs DDPG

Στην συνέχεια θέλαμε να παρατηρήσουμε την συμπεριφορά όλων των αλγορίθμων και τις επιδόσεις τους στο ίδιο περιβάλλον. Όλα τα μοντέλα έχουν εκπαιδευτεί στις 350.000 εποχές. Αφού πειραματιστήκαμε με τον κάθε αλγόριθμο ξεχωριστά αποφασίσαμε να αφήσουμε τις default τιμές στις παραμέτρους των μοντέλων.


Στον πίνακα παρακάτω βλέπουμε τις επιδόσεις του κάθε μοντέλου-αλγορίθμου που εκπαιδεύτηκαν για 350.000 εποχές στο περιβάλλον “LunarLanderContinuous” στο οποίο action space είναι συνεχόμενο ή αλλιώς continuous(box) έτσι ώστε να μπορούν να αξιολογηθούν και οι τέσσερις αλγόριθμοι που όπως αναφέραμε και στα παραπάνω κεφάλαια οι (A2C , PPO) μπορούν να χρησιμοποιηθούν και στους 2 τύπους περιβάλλοντος ενώ ο TD3 και DDPG μόνο σε συνεχές περιβάλλοντα.

Model - Algorithm	Average Reward	Std Reward
PPO	74	112
A2C	-571	142
TD3	288	16
DDPG	227	83

Πίνακας 2 Πίνακας αποτελεσμάτων σύγκρισης μοντέλων A2C, PPO, DDPG, TD3

Τα μοντέλα με τους αλγόριθμους (DDPG και TD3) πέτυχαν το μεγαλύτερο, ο PPO είχε αρκετά μέτρια απόδοση, ενώ ο A2C δεν μπόρεσε να ανταπεξέλθει και είχε τα χειρότερα αποτελέσματα.


- μαύρη καμπύλη : TD3 => 1:34h
- πορτοκαλί καμπύλη : PPO => 11.5m
- ροζ καμπύλη : A2C => 18.3m
- γαλάζια καμπύλη : DDPG => 1:54h



Εικόνα 34 Γραφήματα αποτελεσμάτων σύγκρισης μοντέλων A2C, PPO, DDPG, TD3

➤ Retrain PPO


Σε συνέχεια των παραπάνω αποτελεσμάτων εκτός από την υψηλή απόδοση των TD3 και DDPG, είδαμε πως ο χρόνος εκτέλεσης διαφέρει κατά πολύ ανάμεσα σε αυτά τα δυο ζευγάρια. Έτσι επιλέξαμε να εκπαιδεύσουμε το μοντέλο - αλγόριθμο PPO έτσι ώστε να πλησιάσει χρονικά τους TD3 και DDPG. Έτσι, όπως βλέπουμε και στην παρακάτω εικόνα, εκπαιδεύτηκε στις 2.500.000 φορές και σε χρόνο 2.10h . Ωστόσο τα αποτελέσματα δεν ήταν και πάλι ικανοποιητικά και το μοντέλο μας δεν έπιασε πάνω από 120 βαθμούς reward.



Εικόνα 35 Γράφημα απόδοσης PPO μετά από επανεκπαίδευση

Ένα άλλο ένα σενάριο σύγκρισης των τεσσάρων αλγορίθμων πραγματοποιήθηκε στο περιβάλλον “Pendulum”. Το κάθε μοντέλο εκπαιδεύτηκε για 200.000 φορές με τις default παραμέτρους που ορίζει η βιβλιοθήκη του stable baselines.

Τα μοντέλα που υλοποιούν τους TD3 και DDPG έφτασαν στην βέλτιστη απόδοση μέσα σε λίγες εποχές (20.000) ενώ οι PPO και A2C δεν κατάφεραν να πιάσουν την απόδοσή τους. Και σε αυτό το παράδειγμα ο χρόνος εκτέλεσης των TD3 και DDPG είναι στα 55min ενώ στους PPO και A2C περίπου στα 12min.



Εικόνα 36 Γραφήματα σύγκρισης απόδοσης μοντέλων A2C,PPO,DDPG,TD3 σε περιβάλλον Pendulum

5.3 Εφαρμογή εκπαιδευμένων μοντέλων σε διαφορετικά περιβάλλοντα

Στα πλαίσια της ερευνητικής εργασίας εφαρμόστηκαν εκπαιδευμένα μοντέλα των αλγορίθμων που αναλύσαμε παραπάνω ώστε να παρατηρηθεί η συμπεριφορά τους καθώς

και μελετήθηκαν διάφορα ενδεχόμενα επανεκπαίδευσης των μοντέλων. Τα εκπαιδευμένα μοντέλα εφαρμόστηκαν και παρατηρήθηκαν σε διαφορετικά περιβάλλοντα με ίδια χαρακτηριστικά (observation spaces, action spaces) αλλά και με διαφορετικά επίσης. Ωστόσο παρά τις προσπάθειες τα αποτελέσματα δεν βγήκαν ικανοποιητικά σε μεγάλο βαθμό, σε οποιοδήποτε συνδυασμό μοντέλου - αλγορίθμου που δοκιμάστηκε, πράγμα που καταγράφεται στον πίνακα που ακολουθεί. Η ίδια διαδικασία συνέβει στην προσπάθεια εκπαίδευσης ενός μοντέλου σε διαφορετικό περιβάλλον. Για παράδειγμα ένα μοντέλο που ήταν εκπαιδευμένο με αλγόριθμο PPO και περιβάλλον "Breakout", επανεκπαιδεύτηκε σε περιβάλλον "Atlantis". Είναι σημαντικό να σημειωθεί ότι τα συγκεκριμένα περιβάλλοντα έχουν τα ακριβώς ίδια χαρακτηριστικά. Από τα αποτελέσματα της επανεκπαίδευσης που προέκυψαν, φάνηκε ότι η συγκεκριμένη μέθοδος δεν λειτούργησε με τον επιθυμητό τρόπο. Το ίδιο αποτέλεσμα πήραμε και με τα μοντέλα που αφορούσαν τους αλγόριθμους (A2C, TD3, DDPG) και αυτούς σε διαφορετικά περιβάλλοντα.

Main model	Evaluated environment	average reward	std reward
PPO + Breakout	Breakout	9.4	2.5
PPO + Breakout	Atlantis	1.8	0.87
PPO + Breakout + 100000 retrain in Atlantis	Atlantis	3.2	1.1
A2C + Atlantis	Atlantis	48000	9200
A2C + Atlantis	Breakout	2020	40
A2C + Atlantis + 100000 retrain in Breakout	Atlantis	12000	377

Πίνακας 3 Πίνακας απόδοσης μοντέλων A2C, PPO, TD3,DDPG

Όπως παρατηρείται και στον παραπάνω πίνακα των αποτελεσμάτων επιβεβαιώνεται το γεγονός ότι το πείραμα με την εφαρμογή εκπαιδευμένων μοντέλων σε διαφορετικά περιβάλλοντα δεν έφερε επιθυμητά και ικανοποιητικά αποτελέσματα. Ιδια εικόνα παρουσιάζουν και οι αντιστοιχίες εφαρμογής των μοντέλων με αλγόριθμους (TD3, DDPG).

Κεφάλαιο 6ο Συμπεράσματα

6.1 Συμπεράσματα

Καθώς το πεδίο της ενισχυτικής μάθησης (RL) συνεχίζει να εξελίσσεται, ερευνητές και επαγγελματίες προσπαθούν να μελετήσουν διάφορους αλγόριθμους RL για να αξιολογήσουν την απόδοση, την αποτελεσματικότητα και την καταλληλότητά τους για διαφορετικούς τομείς προβλημάτων καθώς και την προσαρμογή τους σε διάφορα περιβάλλοντα. Σε αυτήν την ανάλυση, παρουσιάσαμε μια ολοκληρωμένη αξιολόγηση αλγορίθμων RL στις βιβλιοθήκες (Stable Baselines και GYM), με στόχο να παρέχουμε πληροφορίες για τα δυνατά τους σημεία, τους περιορισμούς και τα βέλτιστα σενάρια εφαρμογής τους.

Κατανοώντας τα δυνατά σημεία, τις αδυναμίες και τα βέλτιστα σενάρια εφαρμογής κάθε αλγόριθμου, προσπαθούμε να συμβάλουμε στην πρόοδο και την πρακτική εφαρμογή της ενισχυτικής μάθησης σε διάφορα περιβάλλοντα του πραγματικού κόσμου. Οι παραπάνω αναλύσεις και πειραματισμοί μας οδήγησαν στην πολύ χρήσιμη και καθοριστική δημιουργία μιας βιβλιοθήκης, όπου είναι διαθέσιμη στο GitHub, η οποία μας βοήθησε στην μαζική δημιουργία, εκπαίδευση και αξιολόγησή των μοντέλων καθώς και αρκετές μεμονομένες λειτουργίες.

Από την δημιουργία και εφαρμογή των μοντέλων που παρουσιάσαμε παραπάνω, αλλά και πολλών ακόμα όπου τα αποτελέσματα τους είναι διαθέσιμα στο GitHub, διαπιστώσαμε πως η βιβλιοθήκη Stable baselines, κατά την υλοποίηση των αλγορίθμων που ασχοληθήκαμε στην παρούσα εργασία (PPO, A2C, TD3, DDPG) έχει θέσει τις default τιμές των παραμέτρων έτσι ώστε να φέρουν τα καλύτερα δυνατά αποτελέσματα κατά την αξιολόγηση τους. Επίσης μας παρέχει λεπτομερώς όλες τις λειτουργίες – functionalities ,

για την εκπαίδευση – αξιολόγησης ενός μοντέλου. Πάνω σε αυτές τις λειτουργίες αναπτύχθηκε και η βιβλιοθήκη που υλοποιήθηκε σε αυτή την εργασία και ο χρήστης μπορεί να υλοποιήσει τις παραπάνω λειτουργίες με ακόμα μεγαλύτερη ευκολία.

Καθοριστικό ρόλο έπαιξε η βιβλιοθήκη Gym όπου παρέχει πολλές πληροφορίες σχετικά με τα περιβάλλοντα τα οποία παρέχει. Οι πληροφορίες σχετικά με τα χαρακτηριστικά υπάρχουν στην κεντρική ιστοσελίδα του OpenAI GYM αλλά και κατά την εφαρμογή τους στον κώδικα όπου μέσω αυτών των πληροφοριών μας επιτρέπει να στήσουμε δυναμικά ένα μπλοκ κώδικα για την αυτόματη ορθή δημιουργία και εκπαίδευση του μοντέλου.

Η εργαλειοθήκη του TensorBoard ανοιχτού κώδικα εμφανίζει έναν πίνακα εργαλείων όπου τα μοντέλα που εκπαιδεύτηκαν μπορούν να απεικονιστούν ως γραφήματα, εικόνες, ιστογράμματα, ενσωματώσεις. Μας δίνει τη δυνατότητα να κατανοήσουμε την πρόοδο της εκπαίδευσης και να βελτιώσουμε την απόδοση του μοντέλου ενημερώνοντας τις υπερπαραμέτρους. Η συνεργασία του με το Stable baselines θεωρούμε πως είναι άψογη και έπαιξε καθοριστικό ρόλο στην υλοποίηση της εργασίας.

Σύμφωνα με όλα τις παραπάνω αναλύσεις διακρίναμε τις συμπεριφορές των αλγορίθμων που ασχοληθήκαμε σε περιβάλλοντα με continuous action spaces και σε discrete action spaces, την διαφορά στην απόδοση των μοντέλων αλλάζοντας διάφορες υπερπαραμέτρους, και πως τα χαρακτηριστικά των περιβαλλόντων παίζουν καθοριστικό ρόλο στην επιλογή του κατάλληλου αλγόριθμου για την δημιουργία ενός αποδοτικού μοντέλου.

6.2 Μελλοντικές Προβλέψεις

Η ενισχυτική μάθηση (RL) έχει δείξει πολλές δυνατότητες και συνεχίζει να ανοίγει το δρόμο για καινοτόμες εφαρμογές σε πολλές βιομηχανίες. Η RL έχει τη δυνατότητα να

μεταμορφώσει την υγειονομική περίθαλψη μέσω της βελτιστοποίησης των θεραπευτικών σχεδίων, της φαρμακευτικής δοσολογίας και της διαχείρισης ασθενειών. Για παράδειγμα, οι αλγόριθμοι RL μπορούν να εφαρμοστούν για την εξατομίκευση των θεραπειών καρκίνου για κάθε ασθενή και τη μείωση των παρενεργειών (Prasad, 2021). Προκειμένου να βελτιωθεί η αποδοτικότητα και τα αποτελέσματα των ασθενών, τα νοσοκομεία μπορούν να μεγιστοποιήσουν την κατανομή των πόρων με τη διαχείριση της ροής των ασθενών και τον προγραμματισμό των χειρουργικών επεμβάσεων, για παράδειγμα..

Ένας άλλος τομέας στον οποίο μπορεί να εφαρμοστεί η RL είναι η ρομποτική. Μπορεί να χρησιμοποιηθεί από τα ρομπότ και τα αυτόνομα συστήματα για να μαθαίνουν και να προσαρμόζονται στις μεταβαλλόμενες συνθήκες. Μπορεί να εφαρμοστεί στον ρομποτικό χειρισμό καθώς και σε εργασίες όπως η αυτόνομη πλοήγηση και η αναγνώριση αντικειμένων. Σκεφτείτε ότι οι αλγόριθμοι RL έχουν χρησιμοποιηθεί για την εκπαίδευση ρομποτικών βραχιόνων ώστε να εκτελούν σύνθετες εργασίες όπως η σύλληψη και ο χειρισμός αντικειμένων με επιδεξιότητα και ακρίβεια. (OpenAI Five, 2018).

Οι εφαρμογές στον τραπεζικό τομέα και το εμπόριο, όπου η RL μπορεί να βελτιώσει τη διαχείριση χαρτοφυλακίου, τις τακτικές αλγοριθμικών συναλλαγών και τη διαχείριση κινδύνου, παρουσιάζουν σημαντικές δυνατότητες. Ανταποκρινόμενοι συνεχώς στις μεταβαλλόμενες συνθήκες της αγοράς, οι αλγόριθμοι RL μπορούν να μάθουν να λαμβάνουν τις καλύτερες δυνατές αποφάσεις (Duan, 2016). Για παράδειγμα, τα συστήματα συναλλαγών που βασίζονται στην RL έχουν αποδειχθεί ικανά να προσαρμόζονται στις ακανόνιστες συνθήκες της αγοράς και να εντοπίζουν επικερδείς ευκαιρίες διαπραγμάτευσης.

Η βελτιστοποίηση των συστημάτων μεταφορών, όπως η διαχείριση της κυκλοφορίας, ο σχεδιασμός διαδρομών και η αυτόνομη οδήγηση, μπορεί να βοηθηθεί σημαντικά από την RL. Οι αλγόριθμοι λήψης αποφάσεων σε πραγματικό χρόνο (RL) μπορούν να μάθουν να λαμβάνουν αποφάσεις με βάση τις συνθήκες κυκλοφορίας και να μειώνουν τη συμφόρηση. Επιπλέον, η RL είναι απαραίτητη για τη διδασκαλία των αυτόνομων οχημάτων πώς να διαπραγματεύονται δύσκολες οδικές συνθήκες και να λαμβάνουν αποφάσεις που είναι τόσο ασφαλείς όσο και αποτελεσματικές (Chen J. L., 2019).

Επιπλέον, με την εξισορρόπηση της προσφοράς και της ζήτησης ενέργειας, τη μείωση του κόστους και τη βελτιστοποίηση της χρήσης ενέργειας, η γλώσσα RL μπορεί να βελτιστοποιήσει τα συστήματα διαχείρισης ενέργειας, όπως τα έξυπνα δίκτυα. Με βάση τα μεταβαλλόμενα πρότυπα ενεργειακού κόστους και ζήτησης, οι αλγόριθμοι RL μπορούν να μάθουν να λειτουργούν τα συστήματα παραγωγής και αποθήκευσης ενέργειας με προσαρμοστικό τρόπο, με αποτέλεσμα μια πιο αποτελεσματική και βιώσιμη χρήση της ενέργειας (Chen C. W., 2017).

Τέλος, μπορεί να εφαρμοστεί για τη βελτίωση εφαρμογών NLP, όπως η παραγωγή κειμένων, η μηχανική μετάφραση και τα συστήματα διαλόγου. Σύμφωνα με τον Bahdanau (2015), τα μοντέλα RL μπορούν να εκπαιδευτούν για να κάνουν απαντήσεις που μοιάζουν με τις ανθρώπινες, να ενισχύσουν τη συνοχή του λόγου και να αυξήσουν την ποιότητα της μετάφρασης. Οι εικονικοί πράκτορες μπορούν να εμπλακούν με τους χρήστες και να μάθουν από τα σχόλιά τους για να παρέχουν πιο προσαρμοσμένες και συνειδητοποιημένες στο πλαίσιο απαντήσεις χάρη επίσης στους αλγορίθμους RL (Bahdanau, 2015).

Μπορούμε να αναμένουμε περαιτέρω καινοτομίες και εφαρμογές που θα αλλάξουν το παιχνίδι, καθώς η έρευνα και η ανάπτυξη της RL προχωρούν, γεγονός που θα επηρεάσει το μέλλον πολλών τομέων.

Βιβλιογραφία

- Alpaydin, E. (2010). *Introduction to Machine Learning*. MIT Press. doi:ISBN: 9780262012119
- Arulkumaran, K. D. (2017). Deep Reinforcement Learning: A Brief Survey. *IEEE Signal Processing Magazine*, 34(6), σσ. 26-38. Ανάκτηση 04 2023, από <https://ieeexplore.ieee.org/document/8103164>
- Bahdanau, D. C. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. *International Conference on Learning Representations (ICLR)*. Ανάκτηση από <https://arxiv.org/abs/1409.0473>
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. Ανάκτηση από <http://users.isr.ist.utl.pt/~wurmd/Livros/school/Bishop%20-%20Pattern%20Recognition%20And%20Machine%20Learning%20-%20Springer%20%202006.pdf>
- Burges, C. J. (1998). A Tutorial on Support Vector Machines for Pattern Recognition. *Data Mining and Knowledge Discovery*, 2(2), σσ. 121-167. Ανάκτηση από <https://link.springer.com/article/10.1023/a:1009715923555>
- Chen, C. W. (2017). Reinforcement Learning Based Home Energy Management System in Smart Grid Environment. *IEEE Access*, 5.
- Chen, J. L. (2019). Reinforcement Learning for Autonomous Driving. *IEEE Transactions on Intelligent Transportation Systems*, 21(2), σσ. 774-783.
- Christodoulou, S. (2019). Advances and Open Problems in Transfer Learning.
- Cortes, C. &. (1995). Support-Vector Networks. *Machine Learning*, σσ. 273-297. Ανάκτηση 04 2023, από <https://link.springer.com/article/10.1007/bf00994018>

- Duan, Y. C. (2016). Benchmarking Deep Reinforcement Learning for Continuous Control. *International Conference on Machine Learning (ICML)*, , (σσ. 1329-1338).
- Dulac-Arnold, G. e. (2019). *Challenges of Real-World Reinforcement Learning*. In Proceedings of the 36th. Ανάκτηση 04 2023, από <https://arxiv.org/pdf/1904.12901.pdf>
- Goodfellow, I. B. (2016). *Deep Learning*. MIT Press. Ανάκτηση 04 2023, από <https://www.deeplearningbook.org/contents/ml.html>
- Hastie, T. T. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. *Springer*. Ανάκτηση 04 2023, από <https://link.springer.com/book/10.1007/978-0-387-84858-7>
- Hastie, T. T. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. (2d εκδ.). Springer. doi:ISBN: 978-0-387-84858-7
- Hessel, M. e. (2018). Rainbow: Combining Improvements in Deep Reinforcement Learning. *Thirty-Second AAAI Conference on Artificial Intelligence*, 32(1). Ανάκτηση 04 2023, από <https://ojs.aaai.org/index.php/AAAI/article/view/11796>
- Kaelbling, L. P. (1996). Reinforcement Learning: A Survey. *Journal of Artificial Intelligence Research*, 4, σσ. 237-285. Ανάκτηση 04 2023, από <https://arxiv.org/abs/cs/9605103>
- Koedinger, K. R. (2012). *Automated Instructional Design with Learning Factors Analysis* (Τόμ. 41(2)). Educational Researcher.
- Koltun, S. L. (2018). Learning Complex Neural Network Policies with Trajectory Optimization. Ανάκτηση από arXiv preprint arXiv:1810.11654
- Leonard, J. J. (2019). Autonomous Vehicle Navigation in Urban Environments. *Proceedings of the IEEE*.
- Lillicrap, T. P. (2015). Continuous control with deep reinforcement learning. *Cornell University*. Ανάκτηση 04 2023, από <https://arxiv.org/abs/1509.02971>

- Lillicrap, T. P. (2015). *Continuous Control with Deep Reinforcement Learning*. Ανάκτηση 04 2023, από Cornell University: <https://arxiv.org/abs/1509.02971>
- Luckin, R. H. (2016). *Intelligence Unleashed: An Argument for AI in Education*. Pearson.
- Mitchell, T. (1997). *Machine Learning*. McGraw-Hill.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw Hill. Ανάκτηση από <https://www.cin.ufpe.br/~cavmj/Machine%20-%20Learning%20-%20Tom%20Mitchell.pdf>
- Mnih, V. e. (2013). Playing Atari with Deep Reinforcement Learning. *Cornell University*. Ανάκτηση 05 2023, από <https://arxiv.org/abs/1312.5602>
- Mnih, V. e. (2015). Human-level Control through Deep Reinforcement Learning. *Nature*, 518(7540), 529-533. Ανάκτηση 04 2023, από <https://www.nature.com/articles/nature14236>
- Mnih, V. e. (2016). *Asynchronous Methods for Deep Reinforcement Learning*. Ανάκτηση 04 2023, από Cornell University: <https://arxiv.org/abs/1602.01783>
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press. Ανάκτηση 04 2023, από http://noiselab.ucsd.edu/ECE228/Murphy_Machine_Learning.pdf
- OpenAI Five. (2018). *OpenAI*. Ανάκτηση 05 2023, από <https://openai.com/research/openai-five>
- Pathak, D. e. (2017). Curiosity-driven Exploration by Self-supervised Prediction. *International Conference on Machine Learning (ICML)*. Ανάκτηση 05 2023, από <https://arxiv.org/abs/1705.05363>
- Prasad, N. C. (2021). Reinforcement Learning for Personalized Cancer Treatment. *Cancers*, 13(8), σ. 1775. Ανάκτηση από <https://www.mdpi.com/2072-6694/13/8/1775>
- Reiser, R. &. (2012). *Trends and issues in instructional design and technology* (Τόμ. 3rd ed.). Pearson.
- Schölkopf, B. &. (2002). *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press.

- Schulman, J. e. (2015). Trust Region Policy Optimization. *International Conference on Machine Learning (ICML)*. Ανάκτηση 04 2023, από <https://proceedings.mlr.press/v37/schulman15.html>
- Schulman, J. e. (2017). *Proximal Policy Optimization Algorithms*. Ανάκτηση 04 2023, από Cornell University <https://arxiv.org/>: <https://arxiv.org/abs/1707.06347>
- Siemen, G. &. (2011). *Penetrating the Fog: Analytics in Learning and Education*. (Τόμ. 46(5),). Educause Review. Ανάκτηση 04 2023, από <https://er.educause.edu/articles/2011/9/penetrating-the-fog-analytics-in-learning-and-education>
- Siemens G. (2013). Learning analytics: The emergence of a discipline. *American Behavioral Scientist*, 57(10), σσ. 1380-1400. doi:<https://doi.org/10.1177/0002764213498851>
- Siemens, G. &. (2012). Learning analytics and educational data mining: Towards communication and collaboration. In *Proceedings of the 2nd International Conference on Learning Analytics and Knowledge* (σσ. 252-254). ACM.
- Silver, D. e. (2016). Mastering the Game of Go with Deep Neural Networks and Tree Search. *Nature*, 529(7587), σσ. 484-489. Ανάκτηση 05 2023, από <https://www.nature.com/articles/nature16961>
- Silver, D. e. (2017). Mastering the Game of Go without Human Knowledge. *Nature*, 550(7676), σσ. 354-359. Ανάκτηση 05 2023, από <https://www.nature.com/articles/nature24270>
- Silver, D. e. (2018). A General Reinforcement Learning Algorithm that Masters Chess, Shogi, and Go through Self-Play. *Science*, 362(6419), σσ. 1140-1144. doi:DOI: 10.1126/science.aar6404
- Skinner, B. (1958, Oct 24). Teaching machines. *Science*, 128(3330), σσ. 969-977. doi:10.1126/science.128.3330.969
- Sutton, R. S. (2018). *Reinforcement Learning: An Introduction*. MIT Press. Ανάκτηση από <https://mitpress.mit.edu/9780262039246/reinforcement-learning/>

- Timothy P, L. e. (2015). "Continuous control with deep reinforcement learning. Ανάκτηση από arXiv preprint arXiv:1509.02971
- Unity Technologies. (n.d.). *Unity Machine Learning Agents Toolkit*. Ανάκτηση 05 2023, από <https://github.com/Unity-Technologies/ml-agents>
- Volodymyr, M. e. (2015). Human-level control through deep reinforcement learning. *Nature*, σσ. 529-533.
- Volodymyr, M. e. (2016). Asynchronous Methods for Deep Reinforcement Learning. Ανάκτηση από arXiv preprint arXiv:1602.01783
- Watkins, C. J. (1992). *Machine Learning*. Boston: Kluwer Academic Publisher. Ανάκτηση από <https://www.gatsby.ucl.ac.uk/~dayan/papers/cjch.pdf>
- Watkins, C. J. (1992). Q-Learning. *Machine Learning*, 8(3-4), 279-292. Ανάκτηση 05 2023, από <https://www.gatsby.ucl.ac.uk/~dayan/papers/wd92.html>
- Watkins, C. J. (1992). Q-Learning. *Machine Learning*. 8(3-4), σσ. 279-292. Ανάκτηση από <https://www.gatsby.ucl.ac.uk/~dayan/papers/cjch.pdf>